Tarea1_Garrido_Parra

May 5, 2025

Tarea 1 Nicolás Garrido Parra

Inicializamos las librerías

[1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
from scipy.stats import nbinom
import seaborn as sns
from statsmodels.iolib.summary2 import summary_col

import warnings
warnings.filterwarnings("ignore")

%matplotlib inline
```

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

[3]:
```
df = pd.read_csv('../../data/machine_failure_data.csv')
df2=df

df2 = df2.rename(columns={"Parameter1_Dir": "P1D",
                          "Parameter1_Speed": "P1S","Parameter2_9am":␣
 ↪"P29","Parameter2_3pm":"P23",
                          "Parameter3_9am": "P39","Parameter3_3pm":
 ↪"P33","Parameter4_9am": "P49",
                          "Parameter4_3pm":"P43","Parameter5_9am":␣
 ↪"P59","Parameter5_3pm":"P53",
                          "Parameter6_9am": "P69","Parameter6_3pm":
 ↪"P63","Parameter7_9am": "P79","Parameter7_3pm":"P73"})

print(df.dtypes)
```

```
##### dado que no podemos trabajar con Yes o No cambiamos esos valores por un␣
 ↪parametro binario que será uno si ocurrió falla y cero si no lo hizo y␣
 ↪eliminamos la columna Failure_today

df2["Falla"]=df2["Failure_today"].apply(lambda x:1 if x=="Yes" else 0)
df2=df2.drop(columns=["Failure_today"])
df2['Falla'] = df2['Falla'].astype(float)
df2["P59"]=df2["P59"]/1000
df2["P53"]=df2["P53"]/1000


##### eliminamos los valores null de las variables que no tienen tantos

df2 = df2.dropna(subset=['Min_Temp'])
df2 = df2.dropna(subset=['Max_Temp'])
df2 = df2.dropna(subset=['Leakage'])
df2 = df2.dropna(subset=['P1D'])
df2 = df2.dropna(subset=['P1S'])
df2 = df2.dropna(subset=['P29'])
df2 = df2.dropna(subset=['P23'])
df2 = df2.dropna(subset=['P39'])
df2 = df2.dropna(subset=['P33'])
df2 = df2.dropna(subset=['P49'])
df2 = df2.dropna(subset=['P43'])
df2 = df2.dropna(subset=['P59'])
df2 = df2.dropna(subset=['P53'])
df2 = df2.dropna(subset=['P79'])
df2 = df2.dropna(subset=['P73'])


##### cambiamos los nombres de algunos parametros por comodidad
df = df.rename(columns={"Parameter1_Dir": "P1D",
                        "Parameter1_Speed": "P1S","Parameter2_9am":␣
 ↪"P29","Parameter2_3pm":"P23",
                        "Parameter3_9am": "P39","Parameter3_3pm":
 ↪"P33","Parameter4_9am": "P49",
                        "Parameter4_3pm":"P43","Parameter5_9am":␣
 ↪"P59","Parameter5_3pm":"P53",
                        "Parameter6_9am": "P69","Parameter6_3pm":
 ↪"P63","Parameter7_9am": "P79","Parameter7_3pm":"P73"})

variables=["Location","Min_Temp","Max_Temp","Leakage","Evaporation","Electricity","P1D","P1S",

##### dado que las distribuciones son similares entre los parametros que se␣
 ↪tomaron en un horario u otro, vamos a usar uno el cual será el que tenga␣
 ↪menos desviación estandar
```

```
df2=df2.drop(columns=["P69","P33","P43","P59","P73"])

sns.boxplot(data=df2, orient='h')
df2.describe()
```

```
Date                 object
Location              int64
Min_Temp            float64
Max_Temp            float64
Leakage             float64
Evaporation         float64
Electricity         float64
Parameter1_Dir       object
Parameter1_Speed    float64
Parameter2_9am       object
Parameter2_3pm       object
Parameter3_9am      float64
Parameter3_3pm      float64
Parameter4_9am      float64
Parameter4_3pm      float64
Parameter5_9am      float64
Parameter5_3pm      float64
Parameter6_9am      float64
Parameter6_3pm      float64
Parameter7_9am      float64
Parameter7_3pm      float64
Failure_today        object
dtype: object
```

[3]:

	Location	Min_Temp	Max_Temp	Leakage
count	112925.000000	112925.000000	112925.000000	112925.000000
mean	24.936418	12.664721	23.655670	2.377892
std	14.453624	6.254135	6.982702	8.602968
min	1.000000	-8.200000	2.600000	0.000000
25%	12.000000	8.100000	18.300000	0.000000
50%	23.000000	12.400000	23.100000	0.000000
75%	38.000000	17.200000	28.700000	0.800000
max	49.000000	33.900000	48.100000	367.600000

	Evaporation	Electricity	P1S	P39
count	71781.000000	66646.000000	112925.000000	112925.000000
mean	5.593073	7.727338	40.786611	15.179163
std	4.208395	3.776340	13.321774	8.344304
min	0.000000	0.000000	7.000000	2.000000
25%	2.800000	5.000000	31.000000	9.000000
50%	4.800000	8.600000	39.000000	13.000000
75%	7.400000	10.700000	48.000000	20.000000

```
max       82.400000     14.500000     135.000000      87.000000

                P49            P53           P63            P79  \
count  112925.000000  112925.000000  74279.000000  112925.000000
mean       67.404162       1.015049      4.483111      17.462008
std        18.911610       0.006958      2.715840       6.355045
min         0.000000       0.977100      0.000000      -3.100000
25%        56.000000       1.010300      2.000000      12.700000
50%        68.000000       1.015000      5.000000      17.100000
75%        81.000000       1.019700      7.000000      22.000000
max       100.000000       1.039600      9.000000      40.200000

               Falla
count  112925.000000
mean        0.224654
std         0.417356
min         0.000000
25%         0.000000
50%         0.000000
75%         0.000000
max         1.000000
```

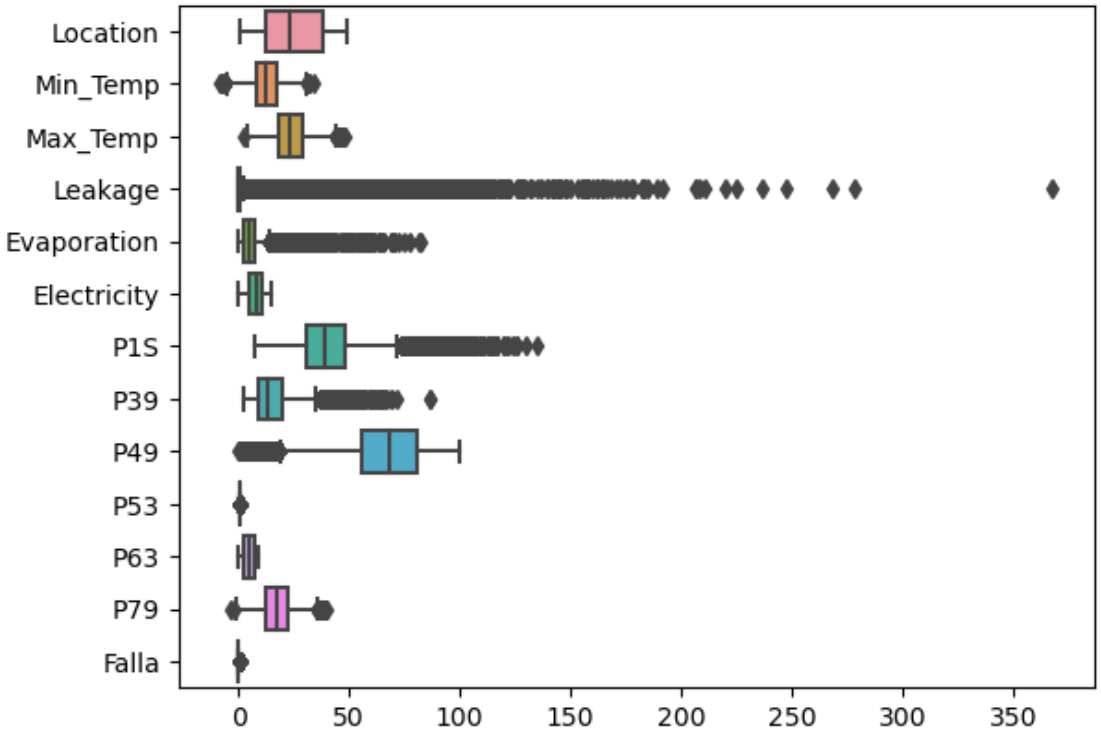

2. Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que

un dia se reporte fallo medido por sensor, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

Seleccionamos las variables independientes, para ello usaremos el criterio de realizar una matriz de correlación y ver cuales son las variables que se relacionan más con la variable dependiente, lo cual concluyó que filtraciones, P49, P1S, P39 y Min_Temp. Por otra parte, nuestra variable dependiente será la dicotómica "Falla". Luego de ejecutar OLS nos quedó que un 34.7% de la variabilidad de las fallas es explicada por nuestra variables independientes escogidas, las cuales son significativas de a cuerdo al criterio de p y su interpretación es : si la filtracion medida aumenta en una unidad, la probabilidad de falla aumentará, lo mismo para las otras variables con sus respectivos porcentajes.

[11]:
```
df3=df2
df3=df3.drop(columns=["Date","P29","P23","P1D","Location","P63"])
df3corre=df3.corr()

mask = np.triu(np.ones_like(df3corre, dtype=bool))
f, ax = plt.subplots(figsize=(11, 9))
cmap = sns.diverging_palette(230, 20, as_cmap=True)
sns.heatmap(df3corre, mask=mask, cmap=cmap, vmax=.3, center=0,
            square=True, linewidths=.5, cbar_kws={"shrink": .5})
##### notamos que las fallas se correlacionan principalmente son Leackage, P49
 ↪y Min_Temp
y=df3["Falla"]
X=df3.drop(['Falla','Max_Temp','Evaporation',"Electricity","P53","P79"], axis=1)
X=X*100
X=sm.add_constant(X)
model = sm.OLS(y, X)
results = model.fit(cov_type='HC0')
print(results.summary())

##### ols
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  Falla   R-squared:                       0.347
Model:                            OLS   Adj. R-squared:                  0.347
Method:                 Least Squares   F-statistic:                     6608.
Date:                jue, 24 abr. 2025   Prob (F-statistic):               0.00
Time:                        17:32:55   Log-Likelihood:                -37457.
No. Observations:              112925   AIC:                         7.493e+04
Df Residuals:                  112919   BIC:                         7.498e+04
Df Model:                           5
Covariance Type:                  HC0
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const         -0.5536      0.008    -67.320      0.000      -0.570      -0.537
Min_Temp    3.176e-05   1.81e-06     17.522      0.000    2.82e-05    3.53e-05
```

```
Leakage         0.0002   6.61e-06      28.820      0.000        0.000        0.000
P1S          3.789e-05   1.05e-06      36.080      0.000     3.58e-05     3.99e-05
P39          3.051e-05    1.6e-06      19.056      0.000     2.74e-05     3.36e-05
P49          7.298e-05   8.72e-07      83.694      0.000     7.13e-05     7.47e-05
==============================================================================
Omnibus:                    17763.127   Durbin-Watson:                   1.736
Prob(Omnibus):                  0.000   Jarque-Bera (JB):           113037.068
Skew:                           0.604   Prob(JB):                         0.00
Kurtosis:                       7.750   Cond. No.                     5.04e+04
==============================================================================

Notes:
[1] Standard Errors are heteroscedasticity robust (HC0)
[2] The condition number is large, 5.04e+04. This might indicate that there are
strong multicollinearity or other numerical problems.
```

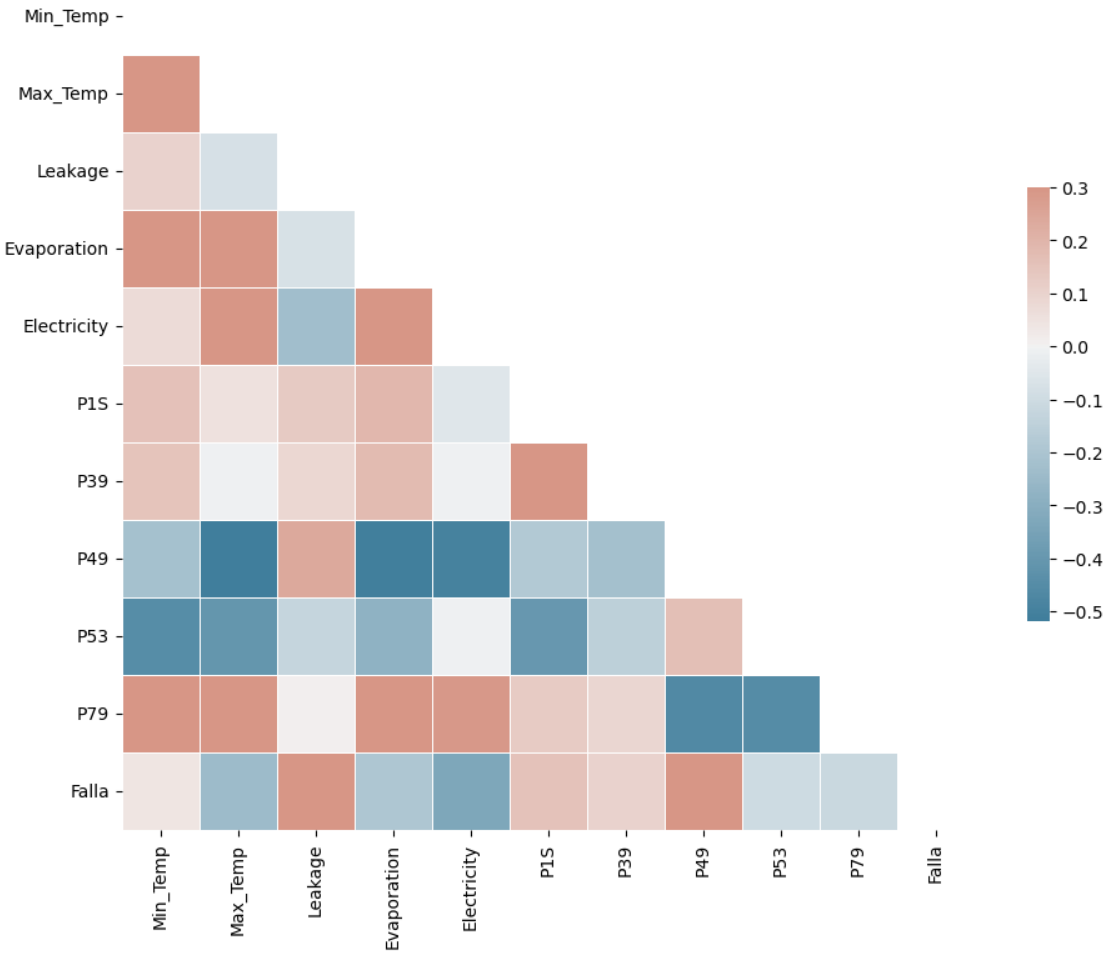

3. Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes

a incluir en el modelo final e interprete su significado.

Para este caso utilizaremos las mismas variables seleccionadas anteriormente (Falla para la dependiente y filtraciones, P1S, P39, P49, Min_Temp para las independientes), una vez realizada, obtuvimos que todas las variables eran significativas, dado que p< que 0.05. Sin embargo P1S y P49 tienen un valor de parámetro beta prácticamente despreciable, en el caso de las otras variables, las interpretamos de la siguiente manera

Min_Temp: La disminución de una unidad de esta variable, provocará una disminución en la probabilidad de fallar

Leakage: El aumento de una unidad provoca un amumento de la probabilidad de fallar

P39: el aumento de una unidad provoca un aumento en la probabilidad de fallar

[43]:
```
model = sm.Probit(y, X)
probit_model = model.fit(cov_type='HC0')
print(probit_model.summary())

mfxp = probit_model.get_margeff()
print(mfxp.summary())
```

```
Warning: Maximum number of iterations has been exceeded.
         Current function value: 0.000000
         Iterations: 35
                           Probit Regression Results
==============================================================================
Dep. Variable:                  Falla   No. Observations:               112925
Model:                         Probit   Df Residuals:                   112919
Method:                           MLE   Df Model:                            5
Date:                mié, 23 abr. 2025   Pseudo R-squ.:                   1.000
Time:                        18:03:53   Log-Likelihood:            -0.00050611
converged:                      False   LL-Null:                       -60159.
Covariance Type:                  HC0   LLR p-value:                     0.000
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
const        -96.8767      1.041    -93.081      0.000     -98.917     -94.837
Min_Temp      -0.0003   5.71e-05     -5.282      0.000      -0.000      -0.000
Leakage        0.9126      0.010     92.634      0.000       0.893       0.932
P1S        -5.888e-05   2.81e-05     -2.094      0.036      -0.000   -3.77e-06
P39            0.0002   3.35e-05      6.146      0.000       0.000       0.000
P49         9.023e-05   3.12e-05      2.889      0.004     2.9e-05       0.000
==============================================================================

Complete Separation: The results show that there iscomplete separation or
perfect prediction.
In this case the Maximum Likelihood Estimator does not exist and the parameters
are not identified.
       Probit Marginal Effects
```

```
====================================
Dep. Variable:                  Falla
Method:                           dydx
At:                            overall
================================================================================
                dy/dx    std err          z      P>|z|      [0.025      0.975]
--------------------------------------------------------------------------------
Min_Temp   -6.388e-12   1.84e-12     -3.470      0.001      -1e-11   -2.78e-12
Leakage     1.932e-08   3.06e-09      6.318      0.000    1.33e-08    2.53e-08
P1S        -1.246e-12   5.47e-13     -2.277      0.023   -2.32e-12   -1.73e-13
P39         4.354e-12   9.89e-13      4.404      0.000    2.42e-12    6.29e-12
P49          1.91e-12    8.2e-13      2.329      0.020    3.02e-13    3.52e-12
================================================================================
```

4. Ejecute un modelo *logit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

Podemos ver que esta vez la variable P39 no es significativa, mientras que las demás sí, por ende, excluimos P39, por otra parte. la interpretación de las demás variables es

Min_Temp: Por cada unidad de cambio la variable disminuye la probabilidad de fallar Leakage: por cada unidad de cambio se aumenta la probabilidad de falla P1S: Por cada unidad que disminuya, la probabilidad de falla aumenta
P49: Por cada unidad que aumente, la probabilidad de falla disminuye

[44]:
```
model = sm.Logit(y, X)
logit_model = model.fit(cov_type='HC0')
print(logit_model.summary())

mfxl = logit_model.get_margeff()
print(mfxl.summary())

params = logit_model.params
conf = logit_model.conf_int()
conf['Odds Ratio'] = params
conf.columns = ['Odds Ratio', '5%', '95%']
print("Odds Ratios")
print(np.exp(conf).iloc[1:17 , ])
```

```
Warning: Maximum number of iterations has been exceeded.
         Current function value: 0.000000
         Iterations: 35
                           Logit Regression Results
================================================================================
Dep. Variable:                  Falla   No. Observations:                112925
Model:                          Logit   Df Residuals:                    112919
Method:                           MLE   Df Model:                             5
Date:                mié, 23 abr. 2025   Pseudo R-squ.:                   1.000
Time:                        18:07:01   Log-Likelihood:           -3.1784e-06
converged:                      False   LL-Null:                      -60159.
```

```
Covariance Type:                  HC0   LLR p-value:                    0.000
================================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
--------------------------------------------------------------------------------
const       -375.8166      4.119    -91.240      0.000    -383.890    -367.744
Min_Temp      -0.0012      0.000     -3.763      0.000      -0.002      -0.001
Leakage        3.5922      0.039     91.174      0.000       3.515       3.669
P1S           -0.0002      0.000     -1.159      0.247      -0.000       0.000
P39         8.625e-05      0.000      0.397      0.692      -0.000       0.001
P49           -0.0003   8.38e-05     -3.396      0.001      -0.000      -0.000
================================================================================

Complete Separation: The results show that there iscomplete separation or
perfect prediction.
In this case the Maximum Likelihood Estimator does not exist and the parameters
are not identified.
        Logit Marginal Effects
=====================================
Dep. Variable:                   Falla
Method:                           dydx
At:                            overall
================================================================================
                dy/dx    std err          z      P>|z|      [0.025      0.975]
--------------------------------------------------------------------------------
Min_Temp   -3.239e-14        nan        nan        nan         nan         nan
Leakage     1.011e-10        nan        nan        nan         nan         nan
P1S        -4.975e-15        nan        nan        nan         nan         nan
P39         2.428e-15        nan        nan        nan         nan         nan
P49        -8.013e-15        nan        nan        nan         nan         nan
================================================================================
Odds Ratios
          Odds Ratio          5%         95%
Min_Temp    0.998252    0.999449    0.998850
Leakage    33.614060   39.227772   36.312597
P1S         0.999524    1.000122    0.999823
P39         0.999660    1.000513    1.000086
P49         0.999551    0.999880    0.999715
```

5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

Yo opino que la diferencia de los resultados se debe a la especialidad de cada modelo, pues el Logit y Probit, al ser de funciones de acumulación de distribución, suelen ser mejores prediciendo variables binarias. Por ende, yo me quedo con Logit, pues no puedo asumir que los errores se distribuyen de manera normal. Finalmente las variables más robustas resultaron ser Leackage y Min_Temp, pues en todos los modelos fueron significativas y en general contaban con los valores más altos en su párametro, por lo que aportan el mayor porcentaje de explicación a predecir si existe falla o no.

6. Agregue la data a nivel mensual, usando la data promedio de las variables (ignorando aquellas categoricas, como la direccion del viento). En particular, genere una variable que cuente la cantidad de fallos observados en un mes, utilice un valor de 0 si en ese mes no se reporto fallos en ningun dia. Use un modelo Poisson para explicar el numero de fallas por mes. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[ ]:

7. Determine sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

[ ]:
```
yy=df3['Falla']
xx=df3[[""]]
poisson=sm.GLM(yy,xx,family=sm.families.Poisson()).fit()
print(poisson.summary())

#T
aux=((yy-poisson.mu)**2-poisson.mu)/poisson.mu
auxr=sm.OLS(aux,poisson.mu).fit()
print(auxr.summary())
#print(np.exp())
```

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[ ]:
```
negbin=sm.GLM(yy,xx,family=sm.families.NegativeBinomial(alpha=0.786)).fit()
print(negbin.summary())
```

9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?