

# Tarea1\_Montero\_Medina

April 30, 2025

Se importan las librerías a utilizar

```
[201]: import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
from scipy.stats import nbinom
import seaborn as sns
from statsmodels.iolib.summary2 import summary_col

import warnings
warnings.filterwarnings("ignore")

%matplotlib inline
```

0.1 1.-

Lectura y limpieza de datos

```
[ ]: #Lectura del Dataframe
df= pd.read_csv('../data/machine_failure_data.csv')
```

```
[203]: #limpieza de datos
variables = df.columns.values.tolist() #visualizamos los nombres de las
↳variables
print(variables)
def contador_nulos(columnas):
    return columnas.isnull().sum() #analizamos cuales datos tienen
↳mayor cantidad de errores o nulos
for columnas in variables:
    a = contador_nulos(df[columnas])
    if contador_nulos(df[columnas])/len(df[columnas]) > 0.35:
        print(a/len(df[columnas]), 'porcentaje de nulos')
        print(f"-----la variable {columnas} tiene un alto porcentaje de
↳valores nulos-----")
total_data_len=len(df['Date'])
```

```

['Date', 'Location', 'Min_Temp', 'Max_Temp', 'Leakage', 'Evaporation',
'Electricity', 'Parameter1_Dir', 'Parameter1_Speed', 'Parameter2_9am',
'Parameter2_3pm', 'Parameter3_9am', 'Parameter3_3pm', 'Parameter4_9am',
'Parameter4_3pm', 'Parameter5_9am', 'Parameter5_3pm', 'Parameter6_9am',
'Parameter6_3pm', 'Parameter7_9am', 'Parameter7_3pm', 'Failure_today']
0.42789026182723483 porcentaje de nulos
-----la variable Evaporation tiene un alto porcentaje de valores nulos-----
0.47692924405561454 porcentaje de nulos
-----la variable Electricity tiene un alto porcentaje de valores nulos-----
0.3773533155640573 porcentaje de nulos
-----la variable Parameter6_9am tiene un alto porcentaje de valores
nulos-----
0.4015246882757942 porcentaje de nulos
-----la variable Parameter6_3pm tiene un alto porcentaje de valores
nulos-----

```

```

[204]: df.dropna(inplace=True) #eliminar filas con valores nulos
print('la cantidad de datos usables es:', len(df['Date'])/
      ↪total_data_len*100,'%')

```

la cantidad de datos usables es: 39.67846518464341 %

transformación de variables que representan el sentido del viento en un esquema de seno y coseno

```

[205]: df['Failure_today'] = df['Failure_today'].map({'No': 0, 'Yes': 1}) #mapear
      ↪valores de la columna Failure_today
direccion_en_grados = {'N': 0, 'NNE': 22.5, 'NE': 45, 'ENE': 67.5, #transformar
      ↪direcciones a grados
                      'E': 90, 'ESE': 112.5, 'SE': 135, 'SSE': 157.5,
                      'S': 180, 'SSW': 202.5, 'SW': 225, 'WSW': 247.5,
                      'W': 270, 'WNW': 292.5, 'NW': 315, 'NNW': 337.5}

df['Parameter1_Dir'] = df['Parameter1_Dir'].map(direccion_en_grados)
df['Parameter2_9am'] = df['Parameter2_9am'].map(direccion_en_grados)
df['Parameter2_3pm'] = df['Parameter2_3pm'].map(direccion_en_grados)

# Lista de columnas de dirección
dir_cols = ['Parameter1_Dir', 'Parameter2_9am', 'Parameter2_3pm']

for col in dir_cols:
    # Convierte a radianes
    df[f'{col}_rad'] = np.deg2rad(df[col])
    # Calcula seno y coseno
    df[f'{col}_sin'] = np.sin(df[f'{col}_rad'])
    df[f'{col}_cos'] = np.cos(df[f'{col}_rad'])

```

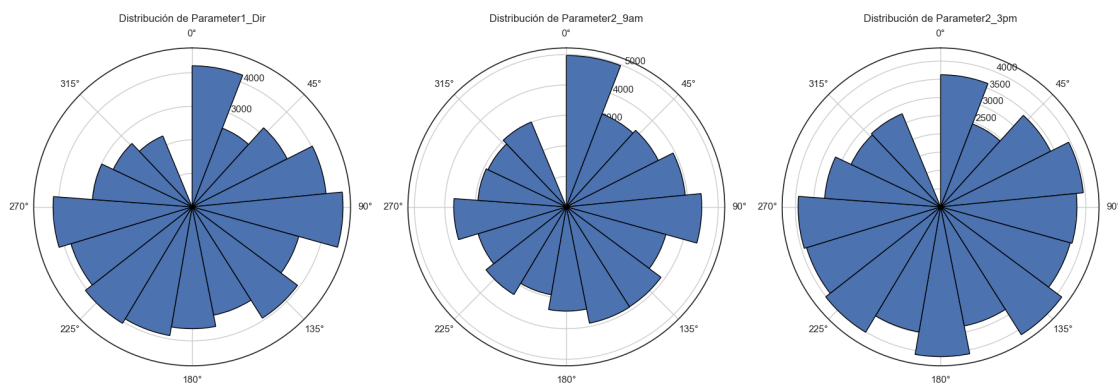
## 0.2 distribución de los sentidos del vientos para parametros 1 y 2

```
[206]: param_cols = [
        ('Parameter1_Dir_rad', 'Parameter1_Dir'),
        ('Parameter2_9am_rad', 'Parameter2_9am'),
        ('Parameter2_3pm_rad', 'Parameter2_3pm')
    ]
    titulos = [
        'Distribución de Parameter1_Dir',
        'Distribución de Parameter2_9am',
        'Distribución de Parameter2_3pm'
    ]

    # Crear la figura y los subplots polares
    fig, axs = plt.subplots(1, 3, subplot_kw=dict(polar=True), figsize=(18, 6))

    for i, (col_rad, col_name) in enumerate(param_cols):
        direcciones_radianes = df[col_rad]
        frecuencias, bins = np.histogram(direcciones_radianes, bins=16)
        axs[i].bar(bins[:-1], frecuencias, width=np.diff(bins), align='edge',
        ↪edgecolor='black')
        axs[i].set_theta_zero_location("N")
        axs[i].set_theta_direction(-1)
        axs[i].set_title(titulos[i], va='bottom')

    plt.tight_layout()
    plt.show()
```



```
[207]: # Asegúrate de que 'Date' es datetime
df['Date'] = pd.to_datetime(df['Date'])

# Agrupar por semanas y calcular la suma de fallas semanales
df['Week'] = df['Date'].dt.to_period('W').apply(lambda r: r.start_time)
```


```

fallas_semanales = df.groupby('Week')['Failure_today'].sum().reset_index()

# Agrupar por meses y calcular la suma de fallas mensuales
df['Month'] = df['Date'].dt.to_period('M').apply(lambda r: r.start_time)
fallas_mensuales = df.groupby('Month')['Failure_today'].sum().reset_index()

# Graficar las fallas mensuales
plt.figure(figsize=(10,5))
plt.plot(fallas_mensuales['Month'], fallas_mensuales['Failure_today'],
        label='Fallas Mensuales', color='#ff6361', alpha=0.7)
plt.xlabel('Mes')
plt.ylabel('Cantidad de Fallas')
plt.title('Fallas Mensuales en Función del Tiempo')
plt.legend()
plt.grid(True)
plt.show()

```



## Exploración de los datos

```

[208]: dfrelevante = df[['Min_Temp', 'Max_Temp', 'Evaporation', 'Electricity',
        'Parameter1_Speed', 'Parameter1_Dir_sin', 'Parameter1_Dir_cos',
        'Parameter2_9am_sin', 'Parameter2_9am_cos', 'Parameter2_3pm_sin',
        'Parameter2_3pm_cos',
        'Parameter3_9am', 'Parameter3_3pm', 'Parameter4_9am',
        'Parameter4_3pm', 'Parameter5_9am', 'Parameter5_3pm', 'Parameter6_9am',
        'Parameter6_3pm', 'Parameter7_9am', 'Parameter7_3pm',
        'Failure_today', 'Leakage', 'Date']]

```

```
print(dfrelevante.describe()) #estadísticas descriptivas de los datos
```

	Min_Temp	Max_Temp	Evaporation	Electricity \
count	56420.000000	56420.000000	56420.000000	56420.000000
mean	13.464770	24.219206	5.503135	7.735626
min	-6.700000	4.100000	0.000000	0.000000
25%	8.600000	18.700000	2.800000	5.000000
50%	13.200000	23.900000	5.000000	8.600000
75%	18.400000	29.700000	7.400000	10.700000
max	31.400000	48.100000	81.200000	14.500000
std	6.416689	6.970676	3.696282	3.758153

	Parameter1_Speed	Parameter1_Dir_sin	Parameter1_Dir_cos \
count	56420.000000	5.642000e+04	5.642000e+04
mean	40.877366	1.856414e-02	-5.689761e-02
min	9.000000	-1.000000e+00	-1.000000e+00
25%	31.000000	-7.071068e-01	-7.071068e-01
50%	39.000000	1.224647e-16	-1.836970e-16
75%	48.000000	7.071068e-01	7.071068e-01
max	124.000000	1.000000e+00	1.000000e+00
std	13.335232	7.213366e-01	6.900067e-01

	Parameter2_9am_sin	Parameter2_9am_cos	Parameter2_3pm_sin ... \
count	5.642000e+04	5.642000e+04	5.642000e+04 ...
mean	5.737015e-02	8.993245e-03	1.354252e-02 ...
min	-1.000000e+00	-1.000000e+00	-1.000000e+00 ...
25%	-7.071068e-01	-7.071068e-01	-7.071068e-01 ...
50%	1.224647e-16	6.123234e-17	1.224647e-16 ...
75%	7.071068e-01	7.071068e-01	7.071068e-01 ...
max	1.000000e+00	1.000000e+00	1.000000e+00 ...
std	7.041894e-01	7.076459e-01	7.184015e-01 ...

	Parameter4_3pm	Parameter5_9am	Parameter5_3pm	Parameter6_9am \
count	56420.000000	56420.000000	56420.000000	56420.000000
mean	49.601985	1017.239505	1014.795580	4.241705
min	0.000000	980.500000	977.100000	0.000000
25%	35.000000	1012.700000	1010.100000	1.000000
50%	50.000000	1017.200000	1014.700000	5.000000
75%	63.000000	1021.800000	1019.400000	7.000000
max	100.000000	1040.400000	1038.900000	8.000000
std	20.197040	6.909357	6.870892	2.797162

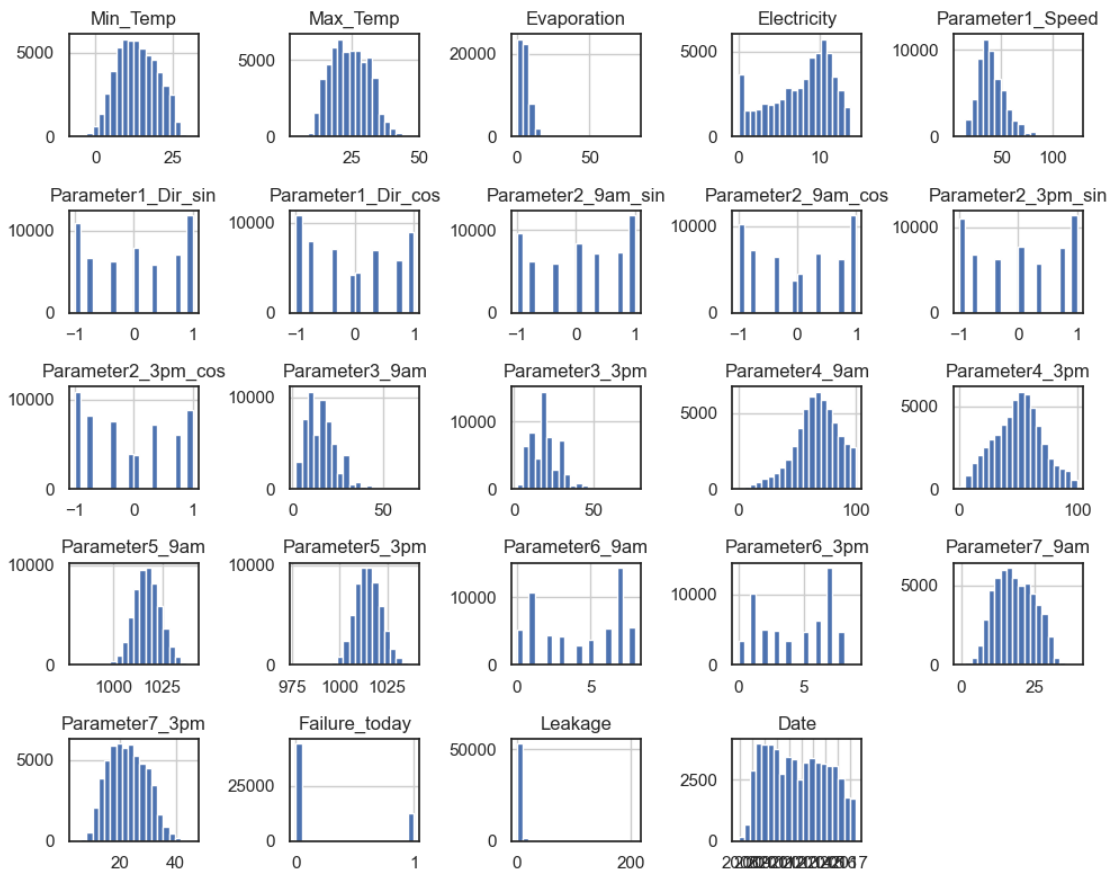
	Parameter6_3pm	Parameter7_9am	Parameter7_3pm	Failure_today \
count	56420.000000	56420.000000	56420.000000	56420.000000
mean	4.326515	18.204961	22.710333	0.220879
min	0.000000	-0.700000	3.700000	0.000000
25%	2.000000	13.100000	17.400000	0.000000

50%	5.000000	17.800000	22.400000	0.000000
75%	7.000000	23.300000	27.900000	0.000000
max	9.000000	39.400000	46.100000	1.000000
std	2.647251	6.567991	6.836543	0.414843

	Leakage	Date
count	56420.000000	56420
mean	2.130397	2012-09-17 06:16:13.952498944
min	0.000000	2007-11-01 00:00:00
25%	0.000000	2010-07-19 00:00:00
50%	0.000000	2012-07-28 00:00:00
75%	0.600000	2014-10-10 00:00:00
max	206.200000	2017-06-25 00:00:00
std	7.014822	NaN

[8 rows x 24 columns]

```
[209]: import matplotlib.pyplot as plt
dfrelevante.hist(figsize=(10,8), bins=20)
plt.tight_layout()
plt.show()
```



```
[210]: #exploración de datos
# for column in dfrelevante.select_dtypes(include=['float64', 'int64']).columns:
#     sns.kdeplot(dfrelevante[column], shade=True, label=column)
#     plt.legend()
#     plt.show()
```

```
[211]: # Calcula la matriz de correlación

df4=dfrelevante
corr = df4.corr()
mask = np.triu(np.ones_like(corr, dtype=bool))


# Estilo de seaborn
sns.set(style="white")

# Tamaño del gráfico
f, ax = plt.subplots(figsize=(14, 12))

# Paleta de colores mejorada
cmap = sns.diverging_palette(220, 10, as_cmap=True)

# Mapa de calor
sns.heatmap(
    corr, mask=mask, cmap=cmap, vmax=0.7, vmin=-0.7, center=0, square=True,
    ↳linewidths=0.4,
    cbar_kws={"shrink": 0.8, 'label': 'índice de Correlación'}, annot=True,
    ↳fmt=".2f",annot_kws={"size": 8}
)
plt.xticks(rotation=35, ha='right', fontsize=10)
plt.yticks(fontsize=10)
plt.title("Matriz de Correlación", fontsize=16, pad=20)
plt.tight_layout()
plt.show()
```

Matriz de Correlación



En función de esta matriz de correlación, podemos ver que el parametro 7 (9am y 3pm) presentan una correlación alta con otras variables. También así el parametro 6 (esto sumado a que la variable 6 presenta un gran número de valores nulos). Otra variable que presenta redundancia al momento de enriquecer el modelo es la de min\_Temp, que está altamente correlacionada con su variable alterna que es Max\_Temp, Y por último, el parametro5\_3pm tiene una alta correlación con parametro5\_9am, por lo que se quita para disminuir la multicolinealidad. También es necesario quitar la variable leakage ya que esta directamente relacionada con la falla y hasta cierto punto predice el futuro, lo que genera problemas en modelos como Probit.

```
[212]: df5 = dfrelevante.drop(columns=[col for col in
    ↳ ['Parameter7_9am', 'Parameter7_3pm', 'Parameter6_9am', 'Parameter6_3pm', 'Min_Temp', 'Parameter5_
    ↳ 'Leakage'] if col in df.columns])

corr = df5.corr()
mask = np.triu(np.ones_like(corr, dtype=bool))
```



```

# Estilo de seaborn
sns.set(style="white")


# Tamaño del gráfico
f, ax = plt.subplots(figsize=(14, 12))

# Paleta de colores mejorada
cmap = sns.diverging_palette(220, 10, as_cmap=True)

# Mapa de calor
sns.heatmap(
    corr, mask=mask, cmap=cmap, vmax=0.7, vmin=-0.7, center=0, square=True,
    ↪linewidths=0.4,
    cbar_kws={"shrink": 0.8, 'label': 'índice de Correlación'}, annot=True,
    ↪fmt=".2f",annot_kws={"size": 8}
)
plt.xticks(rotation=35, ha='right', fontsize=10)
plt.yticks(fontsize=10)
plt.title("Matriz de Correlación", fontsize=16, pad=20)
plt.tight_layout()
plt.show()
#eliminar la variable dependiente para el analisis de correlacion

```

Matriz de Correlación



```
[213]: df7=df5
#Se calcula el percentil 99 para cada columna
percentil_99 = df7.quantile(0.99)

# Filtrar las filas que están por debajo del percentil 99 en todas las columnas
df7_cleaned = df7[(df7 <= percentil_99).all(axis=1)]

# Verificar la cantidad de datos restantes
print(f"Datos originales: {len(df7)}")
print(f"Datos después de eliminar outliers: {len(df7_cleaned)}")
```

Datos originales: 56420

Datos después de eliminar outliers: 51948

### 0.3 2.-

calculamos la regresión para ver los parametros con la data hasta este punto

```
[214]: import statsmodels.api as sm

# Definir la variable dependiente
y = df7_cleaned['Failure_today']
df6=df7_cleaned.drop(columns=['Failure_today'])
# Definir las variables independientes
X = df6[['Max_Temp', 'Evaporation', 'Electricity', 'Parameter1_Speed',
↪ 'Parameter1_Dir_sin', 'Parameter1_Dir_cos', 'Parameter2_9am_sin',
↪ 'Parameter2_9am_cos', 'Parameter3_9am', 'Parameter3_3pm', 'Parameter4_9am',
↪ 'Parameter4_3pm', 'Parameter5_9am']]
# Agregar una constante al modelo
X = sm.add_constant(X)

# Ajustar el modelo OLS
model = sm.OLS(y, X).fit(cov_type='HCO')

# Mostrar el resumen del modelo
print(model.summary())
```

#### OLS Regression Results

```
=====
Dep. Variable:          Failure_today    R-squared:                0.259
Model:                  OLS              Adj. R-squared:          0.259
Method:                 Least Squares    F-statistic:             1428.
Date:                  Thu, 24 Apr 2025  Prob (F-statistic):       0.00
Time:                  23:21:12          Log-Likelihood:          -20005.
No. Observations:      51948            AIC:                   4.004e+04
Df Residuals:          51934            BIC:                   4.016e+04
Df Model:               13
Covariance Type:       HCO
=====
```

	coef	std err	z	P> z	[0.025
0.975]					
-----					
const	10.8452	0.355	30.564	0.000	10.150
11.541					
Max_Temp	0.0019	0.000	4.546	0.000	0.001
0.003					
Evaporation	-0.0185	0.001	-23.044	0.000	-0.020
-0.017					
Electricity	-0.0072	0.001	-12.315	0.000	-0.008
-0.006					
Parameter1_Speed	0.0053	0.000	23.833	0.000	0.005
0.006					
Parameter1_Dir_sin	-0.0065	0.003	-2.504	0.012	-0.012
-0.001					

Parameter1_Dir_cos	-0.0349	0.003	-12.897	0.000	-0.040
-0.030					
Parameter2_9am_sin	-0.0257	0.003	-9.849	0.000	-0.031
-0.021					
Parameter2_9am_cos	-0.0457	0.003	-16.588	0.000	-0.051
-0.040					
Parameter3_9am	0.0050	0.000	19.370	0.000	0.005
0.006					
Parameter3_3pm	-0.0041	0.000	-14.881	0.000	-0.005
-0.004					
Parameter4_9am	0.0058	0.000	42.983	0.000	0.006
0.006					
Parameter4_3pm	0.0022	0.000	17.084	0.000	0.002
0.002					
Parameter5_9am	-0.0110	0.000	-32.395	0.000	-0.012
-0.010					

Omnibus:	4691.412	Durbin-Watson:	1.783
Prob(Omnibus):	0.000	Jarque-Bera (JB):	6056.900
Skew:	0.833	Prob(JB):	0.00
Kurtosis:	2.843	Cond. No.	2.12e+05

Notes:

- [1] Standard Errors are heteroscedasticity robust (HCO)
- [2] The condition number is large, 2.12e+05. This might indicate that there are strong multicollinearity or other numerical problems.

en función de estos datos obtenidos, podemos ver que en este modelo con un coef R<sup>2</sup> del 0.259 con un F=1438 y un p-value <0,001 es globalmente significativo por lo que las variables independientes aportan información al comportamiento del sistema y a la predicción de falla.

en función de los coeficientes obtenidos, podemos ver que la temperatura maxima, la velocidad y los parametros 3\_9am, 4\_9am, 4\_3pm aumentan la probabilidad de falla, mientras que las otras variables la disminuyen.

#### 0.4 3.-

Ahora para tener otro enfoque, aplicamos el modelo probit que se ajusta mejor a la variable binaria

```
[215]: X2 = X
model = sm.Probit(y, X2)
probit_model = model.fit(cov_type='HCO')
print(probit_model.summary())

mfxp = probit_model.get_margeff()
print(mfxp.summary())
```

Optimization terminated successfully.

Current function value: 0.372519

Iterations 7

### Probit Regression Results

```
=====
Dep. Variable:      Failure_today    No. Observations:      51948
Model:              Probit           Df Residuals:             51934
Method:             MLE              Df Model:                13
Date:               Thu, 24 Apr 2025  Pseudo R-squ.:           0.2906
Time:               23:21:12           Log-Likelihood:         -19352.
converged:          True              LL-Null:               -27277.
Covariance Type:    HCO              LLR p-value:           0.000
=====
```

```
=====
                                coef    std err          z      P>|z|      [0.025
0.975]
-----
const                40.8697      1.459      28.011      0.000      38.010
43.729
Max_Temp              0.0050      0.002       2.857      0.004       0.002
0.008
Evaporation          -0.0904      0.004     -22.785      0.000     -0.098
-0.083
Electricity          -0.0055      0.003      -2.054      0.040     -0.011
-0.000
Parameter1_Speed      0.0205      0.001     21.904      0.000       0.019
0.022
Parameter1_Dir_sin    -0.0158      0.013      -1.226      0.220     -0.041
0.009
Parameter1_Dir_cos    -0.1340      0.013     -10.459      0.000     -0.159
-0.109
Parameter2_9am_sin    -0.1417      0.012     -11.422      0.000     -0.166
-0.117
Parameter2_9am_cos    -0.2438      0.013     -18.753      0.000     -0.269
-0.218
Parameter3_9am         0.0196      0.001     15.944      0.000       0.017
0.022
Parameter3_3pm        -0.0128      0.001     -10.074      0.000     -0.015
-0.010
Parameter4_9am         0.0322      0.001     45.959      0.000       0.031
0.034
Parameter4_3pm         0.0127      0.001     22.152      0.000       0.012
0.014
Parameter5_9am        -0.0444      0.001    -31.614      0.000     -0.047
-0.042
=====
=====
```

Probit Marginal Effects					
=====					
Dep. Variable:	Failure_today				
Method:	dydx				
At:	overall				
=====					
	dy/dx	std err	z	P> z	[0.025
0.975]					
-----					
Max_Temp	0.0010	0.000	2.859	0.004	0.000
0.002					
Evaporation	-0.0188	0.001	-23.239	0.000	-0.020
-0.017					
Electricity	-0.0012	0.001	-2.054	0.040	-0.002
-5.27e-05					
Parameter1_Speed	0.0043	0.000	22.256	0.000	0.004
0.005					
Parameter1_Dir_sin	-0.0033	0.003	-1.226	0.220	-0.009
0.002					
Parameter1_Dir_cos	-0.0279	0.003	-10.483	0.000	-0.033
-0.023					
Parameter2_9am_sin	-0.0295	0.003	-11.439	0.000	-0.035
-0.024					
Parameter2_9am_cos	-0.0508	0.003	-19.002	0.000	-0.056
-0.046					
Parameter3_9am	0.0041	0.000	16.066	0.000	0.004
0.005					
Parameter3_3pm	-0.0027	0.000	-10.100	0.000	-0.003
-0.002					
Parameter4_9am	0.0067	0.000	49.502	0.000	0.006
0.007					
Parameter4_3pm	0.0026	0.000	22.377	0.000	0.002
0.003					
Parameter5_9am	-0.0093	0.000	-32.535	0.000	-0.010
-0.009					
=====					
=====					

Considerando que el modelo probit converge y tiene un p-value 0, este es significativo para interpretaciones

Con esto vemos que los valores con mayor magnitud son los asociados a la dirección del viento, donde tenemos ordenes de hasta el 5% de disminución de probabilidad de falla.

Tambien podemos ver que la temperatura aumenta la probabilidad de falla junto con la velocidad de salida.

```
[216]: X3= X2
model = sm.Logit(y, X3)
logit_model = model.fit(cov_type='HCO')
print(logit_model.summary())

mfx1 = logit_model.get_margeff()
print(mfx1.summary())

params = logit_model.params
conf = logit_model.conf_int()
conf['Odds Ratio'] = params
conf.columns = ['Odds Ratio', '5%', '95%']
print("Odds Ratios")
print(np.exp(conf).iloc[1:17 , ])
```

Optimization terminated successfully.

Current function value: 0.372308

Iterations 7

#### Logit Regression Results

```
=====
Dep. Variable:          Failure_today    No. Observations:          51948
Model:                  Logit           Df Residuals:          51934
Method:                 MLE            Df Model:              13
Date:                  Thu, 24 Apr 2025   Pseudo R-squ.:          0.2910
Time:                  23:21:13          Log-Likelihood:         -19341.
converged:              True             LL-Null:                -27277.
Covariance Type:        HCO             LLR p-value:            0.000
=====
```

```
=====
                                coef      std err          z      P>|z|      [0.025
0.975]
-----
const                71.1818         2.587     27.514     0.000     66.111
76.252
Max_Temp              0.0101         0.003      3.307     0.001      0.004
0.016
Evaporation          -0.1656         0.007    -23.034     0.000     -0.180
-0.152
Electricity          -0.0073         0.005     -1.555     0.120     -0.017
0.002
Parameter1_Speed      0.0357         0.002     21.656     0.000      0.032
0.039
Parameter1_Dir_sin    -0.0250         0.023     -1.090     0.276     -0.070
0.020
Parameter1_Dir_cos    -0.2272         0.023    -10.052     0.000     -0.271
-0.183
Parameter2_9am_sin    -0.2476         0.022    -11.199     0.000     -0.291
```

-0.204					
Parameter2_9am_cos	-0.4479	0.023	-19.385	0.000	-0.493
-0.403					
Parameter3_9am	0.0340	0.002	15.572	0.000	0.030
0.038					
Parameter3_3pm	-0.0211	0.002	-9.352	0.000	-0.026
-0.017					
Parameter4_9am	0.0580	0.001	46.781	0.000	0.056
0.060					
Parameter4_3pm	0.0224	0.001	22.246	0.000	0.020
0.024					
Parameter5_9am	-0.0776	0.002	-31.106	0.000	-0.082
-0.073					

=====

=====

# Logit Marginal Effects

Dep. Variable: Failure\_today

Method: dydx

At: overall

=====

=====

	dy/dx	std err	z	P> z	[0.025
--	-------	---------	---	------	--------

0.975]

-----

-----

Max_Temp	0.0012	0.000	3.310	0.001	0.000
0.002					
Evaporation	-0.0195	0.001	-23.520	0.000	-0.021
-0.018					
Electricity	-0.0009	0.001	-1.555	0.120	-0.002
0.000					
Parameter1_Speed	0.0042	0.000	22.059	0.000	0.004
0.005					
Parameter1_Dir_sin	-0.0029	0.003	-1.090	0.275	-0.008
0.002					
Parameter1_Dir_cos	-0.0267	0.003	-10.069	0.000	-0.032
-0.022					
Parameter2_9am_sin	-0.0292	0.003	-11.215	0.000	-0.034
-0.024					
Parameter2_9am_cos	-0.0527	0.003	-19.692	0.000	-0.058
-0.047					
Parameter3_9am	0.0040	0.000	15.707	0.000	0.004
0.004					
Parameter3_3pm	-0.0025	0.000	-9.378	0.000	-0.003
-0.002					
Parameter4_9am	0.0068	0.000	50.758	0.000	0.007
0.007					



Parameter4_3pm	0.0026	0.000	22.492	0.000	0.002
0.003					
Parameter5_9am	-0.0091	0.000	-32.131	0.000	-0.010
-0.009					

=====

=====

Odds Ratios

	Odds Ratio	5%	95%
Max_Temp	1.004136	1.016273	1.010186
Evaporation	0.835533	0.859414	0.847389
Electricity	0.983544	1.001916	0.992687
Parameter1_Speed	1.032971	1.039662	1.036311
Parameter1_Dir_sin	0.932545	1.020107	0.975344
Parameter1_Dir_cos	0.762267	0.832877	0.796790
Parameter2_9am_sin	0.747547	0.815228	0.780655
Parameter2_9am_cos	0.610706	0.668594	0.638995
Parameter3_9am	1.030144	1.038992	1.034558
Parameter3_3pm	0.974799	0.983459	0.979119
Parameter4_9am	1.057169	1.062322	1.059742
Parameter4_3pm	1.020622	1.024655	1.022637
Parameter5_9am	0.920842	0.929889	0.925355

#### 0.4.1 5.-

Variable	OLS (coef)	Logit (dy/dx)	Probit (dy/dx)
Max_Temp	0.0018	0.0053	0.0053
Evaporation	-0.0183	-0.0177	-0.0171
Electricity	-0.0073	-0.0019	-0.0022
Parameter1_Speed	0.0053	0.0060	0.0061
Parameter1_Dir_sin	-0.0063	-0.0209	-0.0216
Parameter1_Dir_cos	-0.0358	-0.0210	-0.0222
Parameter2_9am_sin	-0.0258	-0.0322	-0.0334
Parameter2_9am_cos	-0.0457	-0.0507	-0.0488
Parameter3_9am	0.0050	0.0039	0.0040
Parameter3_3pm	-0.0041	-0.0027	-0.0029
Parameter4_9am	0.0058	0.0071	0.0070
Parameter4_3pm	0.0022	0.0033	0.0034
Parameter5_9am	-0.0111	-0.0011	-0.0011

Aunque los tres modelos presentan resultados consistentes en cuanto a la dirección e importancia relativa de las variables, el modelo Logit es el más adecuado para predecir fallas de máquinas en este contexto. Permite estimar probabilidades realistas, facilita la interpretación de los efectos a partir de los odds ratios y se ajusta mejor a la naturaleza binaria del problema. Por lo tanto, usar Logit como modelo de referencia para la interpretación del sistema y toma de decisiones sobre como mejorarlo.

## 0.5 6.-

```
[217]: # Extrae año y mes
df7_cleaned['AñoMes'] = df7_cleaned['Date'].dt.to_period('M')

# Lista de variables numéricas EXCLUYENDO las categóricas como las de dirección
# del viento
vars_numericas = [
    'Max_Temp', 'Evaporation', 'Electricity',
    'Parameter1_Speed', 'Parameter3_9am', 'Parameter3_3pm',
    'Parameter4_9am', 'Parameter4_3pm', 'Parameter5_9am'
    # agrega o ajusta según tu dataset
]

# Agrupa promediando las variables numéricas y contando fallos por mes
df_agregado = df7_cleaned.groupby('AñoMes')[vars_numericas].mean()
df_agregado['Fallos_mes'] = df7_cleaned.groupby('AñoMes')['Failure_today'].sum()

# Si no hubo fallos, Fallos_mes será 0, así que no hace falta más ajustes
df_agregado = df_agregado.reset_index()
```

```
[218]: import statsmodels.api as sm

# Variables independientes
X = df_agregado[vars_numericas]
X = sm.add_constant(X)

# Variable dependiente: cantidad de fallos por mes (recuerda: debe ser int >= 0)
y = df_agregado['Fallos_mes']

# Modelo Poisson
poisson_model = sm.GLM(y, X, family=sm.families.Poisson())
poisson_results = poisson_model.fit()
print(poisson_results.summary())
```

### Generalized Linear Model Regression Results

```
=====
Dep. Variable:          Fallos_mes    No. Observations:          111
Model:                  GLM           Df Residuals:              101
Model Family:           Poisson       Df Model:                  9
Link Function:          Log           Scale:                    1.0000
Method:                 IRLS          Log-Likelihood:          -641.89
Date:                   Thu, 24 Apr 2025    Deviance:                590.03
Time:                   23:24:05           Pearson chi2:             538.
No. Iterations:         5               Pseudo R-squ. (CS):      1.000
Covariance Type:        nonrobust
=====
```

====

	coef	std err	z	P> z	[0.025
0.975]					
-----					
-----					
const	26.6680	7.113	3.749	0.000	12.727
40.609					
Max_Temp	0.1299	0.011	11.926	0.000	0.109
0.151					
Evaporation	-0.3343	0.032	-10.306	0.000	-0.398
-0.271					
Electricity	-0.0560	0.040	-1.405	0.160	-0.134
0.022					
Parameter1_Speed	-0.1025	0.012	-8.638	0.000	-0.126
-0.079					
Parameter3_9am	0.2415	0.017	14.438	0.000	0.209
0.274					
Parameter3_3pm	0.2218	0.019	11.587	0.000	0.184
0.259					
Parameter4_9am	0.0088	0.006	1.473	0.141	-0.003
0.021					
Parameter4_3pm	0.0259	0.007	3.730	0.000	0.012
0.040					
Parameter5_9am	-0.0282	0.007	-4.263	0.000	-0.041
-0.015					
=====					
=====					

[ ]: