Tarea1_Morales_Orellana

April 30, 2025

Tarea 1 2025

Instrucciones

Su notebook con las respuestas a la tarea se deben entregar a mas tardar el dia 21/04/25 hasta las 21:00, subiendolo al repositorio en la carpeta tareas/2025.

Es importante considerar que el código debe poder ejecutarse en cualquier computadora con la data original del repositorio. Recordar la convencion para el nombre de archivo ademas de incluir en su documento titulos y encabezados por seccion. La data a utilizar es **machine_failure_data.csv**.

Las variables tienen la siguiente descripcion:

- Date: data medida en frecuencia diaria
- Location: ubicacion del medidor
- Min_Temp: temperatura minima observada
- Max_Temp: temperatura maxima observada
- Leakage: Filtracion medida en el area
- Evaporation: Tasa de evaporacion
- Electricity: Consumo electrico KW
- Parameter#: Diferentes sensores de reportando direccion y velocidad de viento en distintos momentos del dia, asi como otras metricas relevantes.
- Failure today: El sensor reporta fallo (o no)

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

[2]:
```python
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
from scipy.stats import nbinom
import seaborn as sns
from statsmodels.iolib.summary2 import summary_col

import warnings
warnings.filterwarnings("ignore")
```

```
%matplotlib inline
```

[3]:
```
# Puntitos para salir de carpeta. Primero abrimos el archivo.
df = pd.read_csv('../../data/machine_failure_data.csv')
df.reset_index(drop=True, inplace=True)
df['Date'] = pd.to_datetime(df['Date'])
```

[4]:
```
df['Date'] = pd.to_datetime(df['Date'])

df['Year'] = df['Date'].dt.year

sns.countplot(data=df, x='Year', hue='Failure_today')

df['Month'] = df['Date'].dt.month
```

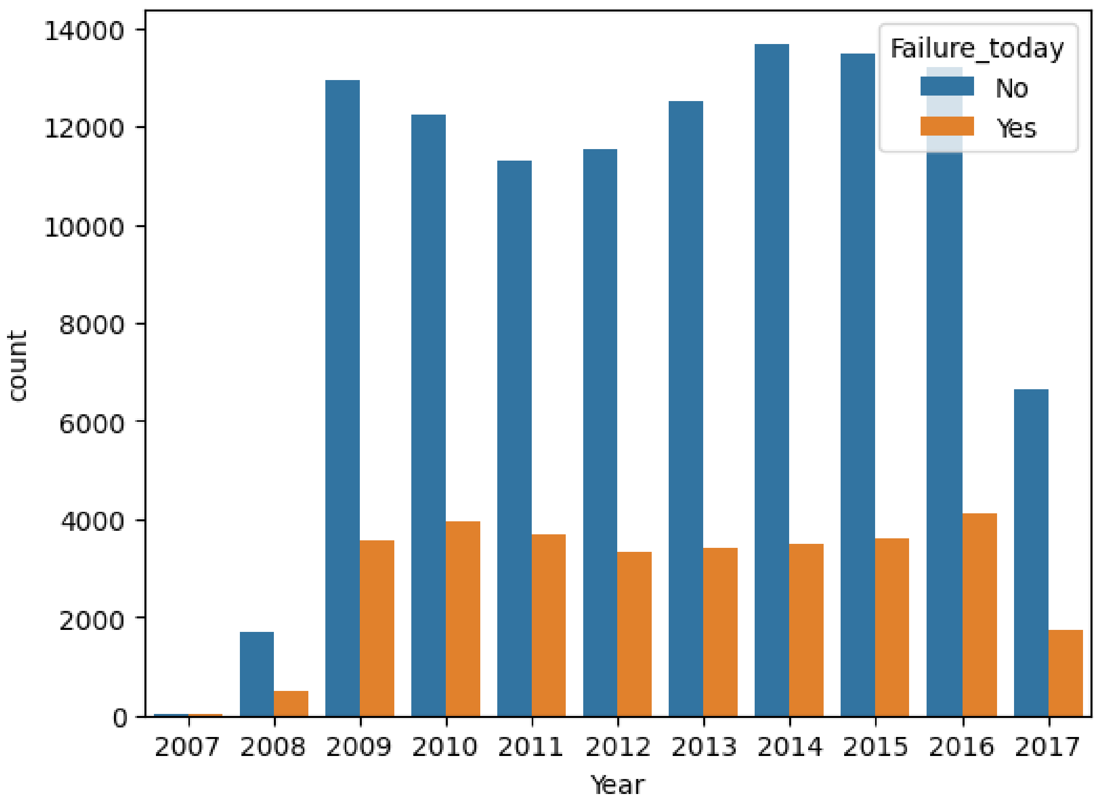

Este gráfico muestra la cantidad de datos por año, el color naranjo reprensenta los datos sobre los fallos. Se puede observar que el 2007 hay una cantidad de datos significativamente menor comparado a la cantidad de datos en los demás años.

Ahora vamos a estandarizar con método común y logarítmico y vamos a ver cuál es mejor.

```
[5]:  #Estandarizado por log de leakage
filtro_failure = df['Failure_today'] == 'Yes'
epsilon = 1
df['Log_Leakage'] = np.log(df['Leakage'] + epsilon)
leak_failure = pd.DataFrame(df['Log_Leakage'][filtro_failure])


sns.kdeplot(data=df, x='Log_Leakage', color='pink')
```

```
[5]: <Axes: xlabel='Log_Leakage', ylabel='Density'>
```

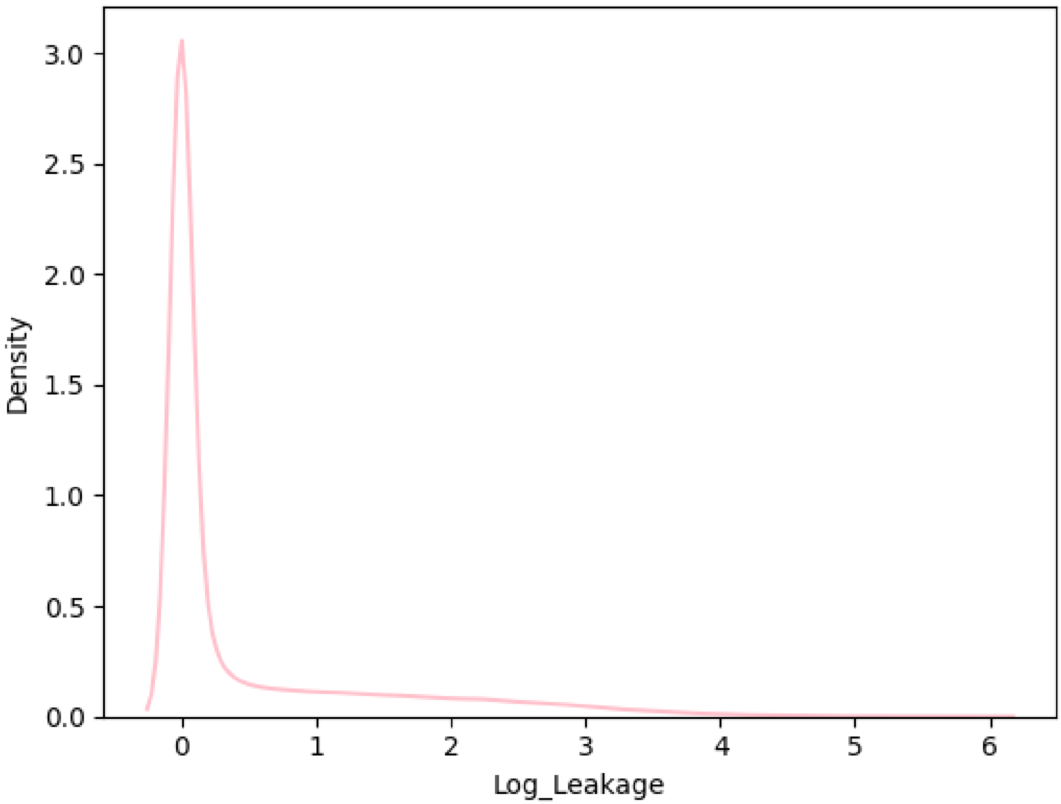

análisis exploratorio de datos especificamente de la variable de filtraciones. Con método logarítmico y método comùn

```
[6]: #Estandarizado comun de leakage
media = (df['Leakage']+epsilon).mean()
varianza = (df['Leakage']+epsilon).var()

df['Normal_Leakage'] = (df['Leakage']+epsilon - media)/np.sqrt(varianza)

sns.kdeplot(data=df, x='Normal_Leakage', color='pink')
```

[6]: <Axes: xlabel='Normal_Leakage', ylabel='Density'>

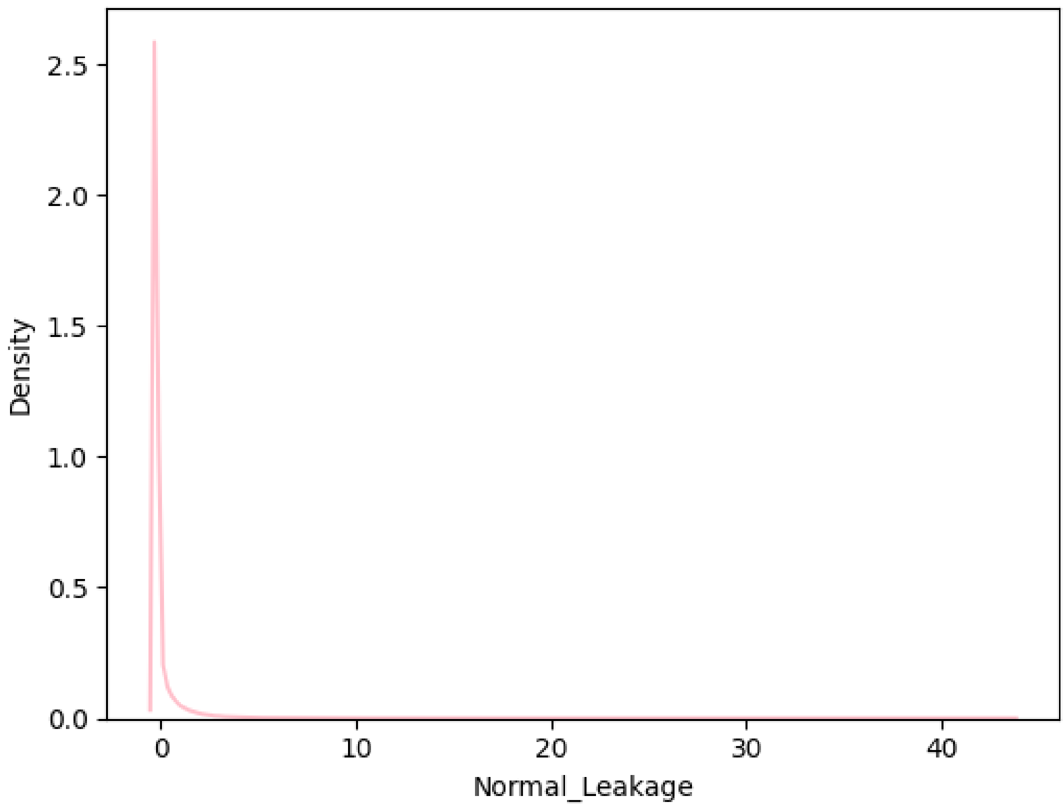

El método común estandariza Leakage para que tenga media 0 y desviación estándar 1. El método logarìtmico aplica una transformación logarítmica para reducir la asimetría. En conclusión ninguno de los dos métodos es mejor que el otro, ya que ninguno logró estandarizar correctamente la variable de las filtraciones

[10]:
```
#categorizar direcciones del viento
df['Is_P1Dir_North'] = df['Parameter1_Dir'].map({'NNW':1, 'N':1,'NNE':1,'NE':1,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

#categorizar direcciones del viento
df['Is_P1Dir_West'] = df['Parameter1_Dir'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':1,'W':1, 'WNW':1,'NW':1})

#categorizar direcciones del viento
df['Is_P1Dir_South'] = df['Parameter1_Dir'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
```

```python
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':1,'S':1,'SSW':1,'SW':1,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

df['Is_P1Dir_East'] = df['Parameter1_Dir'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':1,'E':1,'ESE':1,'SE':1,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

#Cargorizar direcciones del parametro 2 de 9am
df['Is_P29am_North'] = df['Parameter2_9am'].map({'NNW':1, 'N':1,'NNE':1,'NE':1,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

df['Is_P29am_West'] = df['Parameter2_9am'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':1,'W':1, 'WNW':1,'NW':1})

df['Is_P29am_South'] = df['Parameter2_9am'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':1,'S':1,'SSW':1,'SW':1,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

df['Is_P29am_East'] = df['Parameter2_9am'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':1,'E':1,'ESE':1,'SE':1,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

#Cargorizar direcciones del parametro 2 de 3pm
df['Is_P23pm_North'] = df['Parameter2_3pm'].map({'NNW':1, 'N':1,'NNE':1,'NE':1,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

df['Is_P23pm_West'] = df['Parameter2_3pm'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':0,'S':0,'SSW':0,'SW':0,
                                                'WSW':1,'W':1, 'WNW':1,'NW':1})

df['Is_P23pm_South'] = df['Parameter2_3pm'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
                                                'ENE':0,'E':0,'ESE':0,'SE':0,
                                                'SSE':1,'S':1,'SSW':1,'SW':1,
                                                'WSW':0,'W':0, 'WNW':0,'NW':0})

df['Is_P23pm_East'] = df['Parameter2_3pm'].map({'NNW':0, 'N':0,'NNE':0,'NE':0,
```

```
                                                    'ENE':1,'E':1,'ESE':1,'SE':1,
                                                    'SSE':0,'S':0,'SSW':0,'SW':0,
                                                    'WSW':0,'W':0, 'WNW':0,'NW':0})
```

[11]:
```
#Categorizar meses en estaciones
print(df['Month'].unique())
df['Is_Summer'] = df['Month'].map({ 12:0, 1:0, 2:0,
                                   3:0, 4:0, 5:0,
                                   6:1, 7:1, 8:1,
                                   9:0, 10:0, 11:0})

df['Is_Winter'] = df['Month'].map({12:1, 1:1, 2:1,
                                   3:0, 4:0, 5:0,
                                   6:0, 7:0, 8:0,
                                   9:0, 10:0, 11:0})

df['Is_Fall'] = df['Month'].map({12:0, 1:0, 2:0,
                                   3:0, 4:0, 5:0,
                                   6:0, 7:0, 8:0,
                                   9:1, 10:1, 11:1})

df['Is_Spring'] = df['Month'].map({12:0, 1:0, 2:0,
                                   3:1, 4:1, 5:1,
                                   6:0, 7:0, 8:0,
                                   9:0, 10:0, 11:0})
```

```
[12  1  2  3  4  5  6  7  8  9 10 11]
```

[12]:
```
#Elimina las filas donde la columna 'Failure_today' está vacía (NaN).
df = df[df['Failure_today'].notna()]
df['Fail'] = df['Failure_today'].apply(lambda x: 1 if x == 'Yes' else 0)


DF = df[['Fail','Location','Leakage','Log_Leakage', 'Evaporation',␣
 ↪'Electricity','Min_Temp', 'Max_Temp','Parameter1_Speed',
       ␣
 ↪'Parameter3_9am','Parameter3_3pm','Parameter4_9am','Parameter4_3pm','Parameter5_9am','Param
         'Parameter6_9am','Parameter6_3pm','Parameter7_9am','Parameter7_3pm']]
corr = DF.corr()

mask = np.triu(np.ones_like(corr, dtype=bool))
f, ax = plt.subplots(figsize=(20, 20))
cmap = sns.diverging_palette(230, 20, as_cmap=True)
sns.heatmap(corr, annot=True, cmap=cmap, center=0,mask=mask, )

#Genera un heatmap (mapa de calor) de correlaciones:
```

```
#annot=True: muestra los valores numéricos en cada celda.

#cmap=cmap: paleta de colores divergente.

#center=0: el punto medio de los colores es la correlación cero.

#mask=mask: oculta la parte superior.
```

[12]: <Axes: >

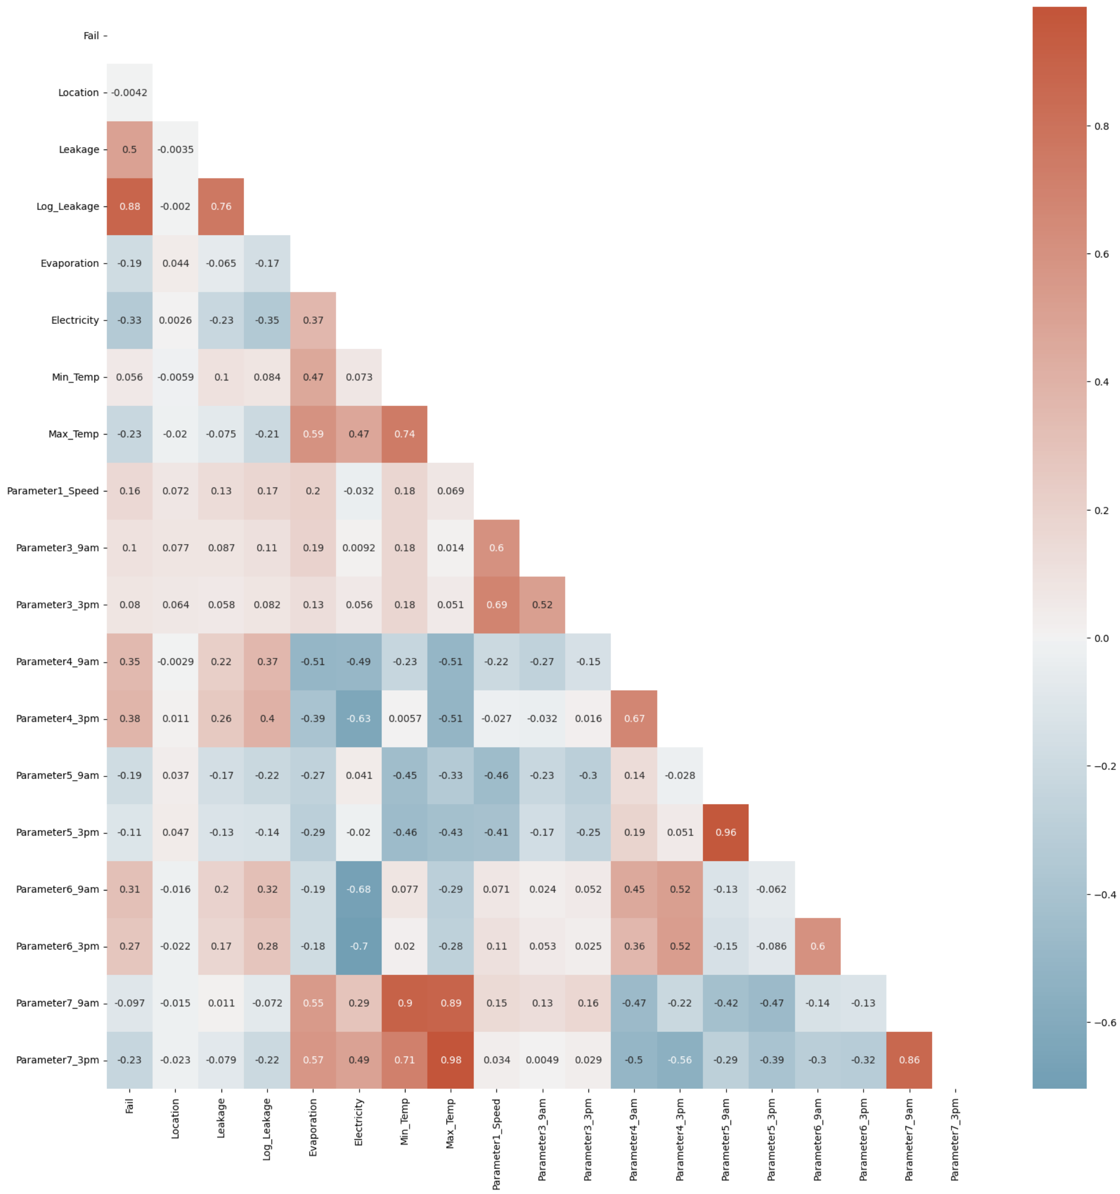

La variable Leakage tiene una correlación moderada con Fail (0.5), lo que sugiere que mayores fugas están asociadas con una mayor probabilidad de falla.

Log_Leakage también está muy correlacionada con Leakage (0.88), lo que era esperable ya que es una transformación logarítmica.

Electricity tiene una correlación negativa baja con Fail (-0.33), lo cual podría implicar que cuando el consumo eléctrico baja, aumentan las fallas, aunque la relación no es fuerte.

Las demás variables tienen una correlación muy baja con Fail, por lo que no muestran una relación lineal significativa directa. Hay variables muy correlacionadas entre sí, lo que puede ser un problema en modelos estadísticos como regresión:

Min_Temp y Max_Temp: 0.74

Parameter6_9am y Parameter6_3pm: 0.96

Parameter7_9am y Parameter7_3pm: 0.86

Parameter3_9am y Parameter3_3pm: 0.69 Evaporation tiene una correlación negativa baja con varias variables, como Max_Temp (-0.17), y su relación con Fail es también baja (-0.19).

Parameter4_9am muestra una correlación negativa moderada con Max_Temp (-0.51), lo que podría indicar sensibilidad a la temperatura en ese parámetro específico.

Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que un dia se reporte fallo medido por sensor, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[13]:
```python
#Regresion excluyendo variables de alta correlacion
#Elimina muchas variables irrelevantes o altamente correlacionadas, incluyendo:
#Variables temporales (Date, Year, Month, Is_Winter).
#Variables categóricas ya codificadas como dummies (Is_P1Dir_West, etc.).
#Variables redundantes con alta correlación, como:
#Evaporation, Electricity (relación baja con falla).
#Leakage, Log_Leakage (muy correlacionadas entre sí).
#Parameter5_3pm, Parameter6_*, Parameter7_* (todas con alta correlación).

#Esto ayuda a evitar multicolinealidad y mejorar la interpretación del modelo.

funcion = df.drop(['Date','Evaporation','Electricity',
                    'Parameter1_Dir','Parameter2_9am','Parameter2_3pm',␣
 ↪'Is_P1Dir_West', 'Is_P1Dir_South', 'Is_P1Dir_East', 'Is_P1Dir_North',
                    'Is_P29am_North', 'Is_P29am_West', 'Is_P29am_South',␣
 ↪'Is_P29am_East',
                    'Is_P23pm_North', 'Is_P23pm_West', 'Is_P23pm_South',␣
 ↪'Is_P23pm_East',
                    'Failure_today', 'Year', 'Month', 'Is_Winter',
                     'Parameter5_3pm',␣
 ↪'Parameter6_9am','Parameter6_3pm','Parameter7_9am','Parameter7_3pm',␣
 ↪'Normal_Leakage','Leakage','Log_Leakage'], axis=1)
funcion.dropna(inplace=True)
```

```python
y=funcion['Fail']
X=funcion.drop(['Fail'], axis=1)
X=sm.add_constant(X)
print(funcion.describe())
```

```
            Location       Min_Temp       Max_Temp  Parameter1_Speed  \
count  119626.000000  119626.000000  119626.000000     119626.000000
mean       24.854154      12.386895      23.485793         40.108488
std        14.537657       6.367256       6.986432         13.480284
min         1.000000      -8.200000       2.600000          6.000000
25%        12.000000       7.700000      18.100000         31.000000
50%        23.000000      12.100000      22.900000         39.000000
75%        38.000000      17.000000      28.500000         48.000000
max        49.000000      33.900000      48.100000        135.000000

       Parameter3_9am  Parameter3_3pm  Parameter4_9am  Parameter4_3pm  \
count   119626.000000   119626.000000   119626.000000   119626.000000
mean        14.364386       19.082959       68.290806       50.868156
std          8.796568        8.676046       19.130459       20.692306
min          0.000000        0.000000        0.000000        0.000000
25%          7.000000       13.000000       56.000000       36.000000
50%         13.000000       19.000000       69.000000       51.000000
75%         20.000000       24.000000       82.000000       65.000000
max         87.000000       87.000000      100.000000      100.000000

       Parameter5_9am      Is_Summer        Is_Fall      Is_Spring  \
count   119626.000000  119626.000000  119626.000000  119626.000000
mean      1017.655123       0.251801       0.243818       0.263362
std          7.098519       0.434050       0.429386       0.440459
min        980.500000       0.000000       0.000000       0.000000
25%       1013.000000       0.000000       0.000000       0.000000
50%       1017.600000       0.000000       0.000000       0.000000
75%       1022.400000       1.000000       0.000000       1.000000
max       1041.000000       1.000000       1.000000       1.000000

                Fail
count  119626.000000
mean        0.221131
std         0.415010
min         0.000000
25%         0.000000
50%         0.000000
75%         0.000000
max         1.000000
```

Se observaron 119.626 registros sin valores faltantes para las variables seleccionadas. Variables como Parameter1_Speed y Parameter3_* presentan una distribución amplia, lo cual puede indicar condiciones operativas diversas. Las variables estacionales (Is_Summer, Is_Fall, etc.) están balanceadas, representando todas las estaciones del año. Esta diversidad aporta riqueza al análisis de regresión, permitiendo evaluar el impacto de múltiples factores sobre las fallas.

[ ]:
```
model = sm.OLS(y, X)  # Crea el modelo de regresión lineal
results = model.fit(cov_type='HC0') # Ajusta el modelo usando errores robustos␣
 ↪(White/HC0)
print(results.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                   Fail   R-squared:                       0.262
Model:                            OLS   Adj. R-squared:                  0.262
Method:                 Least Squares   F-statistic:                     3602.
Date:                Thu, 24 Apr 2025   Prob (F-statistic):               0.00
Time:                        17:09:00   Log-Likelihood:                -46373.
No. Observations:              119626   AIC:                         9.277e+04
Df Residuals:                  119613   BIC:                         9.290e+04
Df Model:                          12
Covariance Type:                  HC0
================================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
const                9.5980      0.207     46.353      0.000       9.192
10.004
Location            -0.0005   7.06e-05     -7.708      0.000      -0.001
-0.000
Min_Temp             0.0191      0.000     57.757      0.000       0.018
0.020
Max_Temp            -0.0203      0.000    -57.047      0.000      -0.021
-0.020
Parameter1_Speed     0.0045      0.000     33.985      0.000       0.004
0.005
Parameter3_9am       0.0028      0.000     17.481      0.000       0.002
0.003
Parameter3_3pm      -0.0043      0.000    -24.776      0.000      -0.005
-0.004
Parameter4_9am       0.0068   8.16e-05     83.818      0.000       0.007
0.007
Parameter4_3pm    1.673e-05   9.72e-05      0.172      0.863      -0.000
0.000
Parameter5_9am      -0.0096      0.000    -47.852      0.000      -0.010
-0.009
Is_Summer            0.0073      0.004      1.991      0.046       0.000
0.015
Is_Fall              0.0408      0.003     13.058      0.000       0.035
```

```
0.047
Is_Spring              0.0032      0.003      1.016      0.310      -0.003
0.009
==============================================================================
Omnibus:                    10416.027   Durbin-Watson:                   1.733
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            13047.261
Skew:                           0.798   Prob(JB):                         0.00
Kurtosis:                       2.737   Cond. No.                     1.90e+05
==============================================================================

Notes:
[1] Standard Errors are heteroscedasticity robust (HC0)
[2] The condition number is large, 1.9e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
```

R-squared: 0.262 → El modelo explica el 26.2% de la variabilidad de las fallas. Aunque no es muy alto, en contextos industriales y con datos complejos, este valor puede ser aceptable.

F-statistic: 3602, con p-valor = 0.00 → El modelo en conjunto es estadísticamente significativo.

Variables significativas ($p < 0.05$):

Variable Coeficiente Sentido Interpretación Min_Temp +0.0191 Positivo A mayor temperatura mínima, mayor probabilidad de falla. Max_Temp -0.0203 Negativo A mayor temperatura máxima, menor probabilidad de falla. Parameter1_Speed +0.0045 Positivo A más velocidad del parámetro 1, más probabilidad de falla. Parameter3_9am +0.0028 Positivo Más valor a las 9am del parámetro 3, más fallas. Parameter3_3pm -0.0043 Negativo Más valor a las 3pm del parámetro 3, menos fallas. Parameter4_9am +0.0068 Positivo Aumento de este parámetro a las 9am incrementa fallas. Parameter5_9am -0.0096 Negativo A mayor valor, disminuyen las fallas. Location -0.0005 Negativo Aunque pequeño, sugiere que algunas ubicaciones presentan menos fallas. Is_Summer +0.0073 Positivo En verano, las fallas son ligeramente más frecuentes.

Variables no significativas: Parameter4_3pm → p = 0.863 → Este parámetro no tiene un efecto estadísticamente significativo en la probabilidad de falla.

Conclusiones El modelo de regresión lineal explica el 26.2% de la variabilidad en las fallas, lo cual indica que hay otros factores no considerados que podrían influir en el resultado.

La temperatura mínima está positivamente asociada con las fallas, mientras que la temperatura máxima tiene un efecto protector (negativo).

Parámetros operacionales medidos en la mañana (como Parameter3_9am y Parameter4_9am) muestran una fuerte relación con el aumento de fallas, lo cual podría indicar que ciertas condiciones tempranas en el día afectan negativamente.

En verano se observan más fallas, aunque el efecto es leve.

La variable Location influye negativamente en las fallas, posiblemente indicando que algunas ubicaciones son más estables o tienen mejores condiciones de operación.

Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[14]:
```python
model = sm.Probit(y, X)
probit = model.fit()
print(probit.summary())

mfx = probit.get_margeff()
print(mfx.summary())
# ¿Cuánto cambia la probabilidad de falla cuando una variable independiente␣
↪aumenta en una unidad, manteniendo las otras constantes?
```

```
Optimization terminated successfully.
         Current function value: 0.369234
         Iterations 7
                          Probit Regression Results
==============================================================================
Dep. Variable:                   Fail   No. Observations:               119626
Model:                         Probit   Df Residuals:                   119613
Method:                           MLE   Df Model:                           12
Date:                Thu, 24 Apr 2025   Pseudo R-squ.:                  0.3011
Time:                        22:26:58   Log-Likelihood:                -44170.
converged:                       True   LL-Null:                       -63203.
Covariance Type:            nonrobust   LLR p-value:                     0.000
================================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
const               30.0079      0.843     35.594      0.000      28.356
31.660
Location            -0.0019      0.000     -5.617      0.000      -0.003
-0.001
Min_Temp             0.1206      0.002     66.891      0.000       0.117
0.124
Max_Temp            -0.1269      0.002    -68.147      0.000      -0.131
-0.123
Parameter1_Speed     0.0165      0.001     29.698      0.000       0.015
0.018
Parameter3_9am       0.0088      0.001     11.703      0.000       0.007
0.010
Parameter3_3pm      -0.0132      0.001    -16.993      0.000      -0.015
-0.012
Parameter4_9am       0.0370      0.000     85.240      0.000       0.036
0.038
Parameter4_3pm      -0.0042      0.000    -10.127      0.000      -0.005
-0.003
Parameter5_9am      -0.0319      0.001    -38.962      0.000      -0.034
-0.030
Is_Summer           -0.0825      0.017     -4.763      0.000      -0.116
```

```
-0.049
Is_Fall             0.1495      0.015      9.741      0.000       0.119
0.180
Is_Spring          -0.0474      0.015     -3.209      0.001      -0.076
-0.018
================================================================================
====
       Probit Marginal Effects
=====================================
Dep. Variable:                   Fail
Method:                          dydx
At:                           overall
================================================================================
====
                     dy/dx    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
Location           -0.0004   7.04e-05     -5.619      0.000      -0.001
-0.000
Min_Temp            0.0249      0.000     70.226      0.000       0.024
0.026
Max_Temp           -0.0263      0.000    -71.879      0.000      -0.027
-0.026
Parameter1_Speed    0.0034      0.000     30.045      0.000       0.003
0.004
Parameter3_9am      0.0018      0.000     11.728      0.000       0.002
0.002
Parameter3_3pm     -0.0027      0.000    -17.069      0.000      -0.003
-0.002
Parameter4_9am      0.0077   8.24e-05     92.895      0.000       0.007
0.008
Parameter4_3pm     -0.0009   8.55e-05    -10.136      0.000      -0.001
-0.001
Parameter5_9am     -0.0066      0.000    -39.783      0.000      -0.007
-0.006
Is_Summer          -0.0171      0.004     -4.766      0.000      -0.024
-0.010
Is_Fall             0.0309      0.003      9.751      0.000       0.025
0.037
Is_Spring          -0.0098      0.003     -3.209      0.001      -0.016
-0.004
================================================================================
====
```

Interpretación del Probit Model Este modelo estima la probabilidad de que ocurra una falla (Fail = 1), dadas ciertas variables climáticas y de ubicación.

Pseudo $R^2 = 0.3011$: Esto indica que el modelo explica aproximadamente el 30.1% de la variabilidad en la probabilidad de falla. Es un buen valor para un modelo con datos binarios, especialmente con muchas observaciones.

Log-Likelihood y LLR p-value = 0.000: Esto indica que el modelo en conjunto es altamente significativo.

Ejecute un modelo *logit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[15]:
```
model = sm.Logit(y, X)
logit = model.fit()
print(logit.summary())

mfx = logit.get_margeff()
print(mfx.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.368744
         Iterations 7
                           Logit Regression Results
==============================================================================
Dep. Variable:                   Fail   No. Observations:               119626
Model:                          Logit   Df Residuals:                   119613
Method:                           MLE   Df Model:                           12
Date:                Thu, 24 Apr 2025   Pseudo R-squ.:                  0.3021
Time:                        22:27:06   Log-Likelihood:                -44111.
converged:                       True   LL-Null:                       -63203.
Covariance Type:            nonrobust   LLR p-value:                     0.000
================================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
const               50.7732      1.480     34.310      0.000      47.873
53.674
Location            -0.0034      0.001     -5.700      0.000      -0.005
-0.002
Min_Temp             0.2187      0.003     67.113      0.000       0.212
0.225
Max_Temp            -0.2274      0.003    -67.276      0.000      -0.234
-0.221
Parameter1_Speed     0.0286      0.001     29.323      0.000       0.027
0.030
Parameter3_9am       0.0146      0.001     11.047      0.000       0.012
0.017
Parameter3_3pm      -0.0217      0.001    -15.770      0.000      -0.024
-0.019
Parameter4_9am       0.0669      0.001     84.606      0.000       0.065
```

```
0.068
Parameter4_3pm      -0.0079      0.001    -10.943      0.000      -0.009
-0.007
Parameter5_9am      -0.0542      0.001    -37.703      0.000      -0.057
-0.051
Is_Summer           -0.0948      0.031     -3.097      0.002      -0.155
-0.035
Is_Fall              0.2748      0.028      9.991      0.000       0.221
0.329
Is_Spring           -0.0431      0.026     -1.653      0.098      -0.094
0.008
================================================================================
====
        Logit Marginal Effects
=====================================
Dep. Variable:                   Fail
Method:                          dydx
At:                           overall
================================================================================
====
                      dy/dx    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
Location            -0.0004   7.05e-05     -5.703      0.000      -0.001
-0.000
Min_Temp             0.0256      0.000     71.419      0.000       0.025
0.026
Max_Temp            -0.0266      0.000    -71.701      0.000      -0.027
-0.026
Parameter1_Speed     0.0033      0.000     29.764      0.000       0.003
0.004
Parameter3_9am       0.0017      0.000     11.074      0.000       0.001
0.002
Parameter3_3pm      -0.0025      0.000    -15.848      0.000      -0.003
-0.002
Parameter4_9am       0.0078   8.23e-05     95.126      0.000       0.008
0.008
Parameter4_3pm      -0.0009   8.48e-05    -10.958      0.000      -0.001
-0.001
Parameter5_9am      -0.0063      0.000    -38.634      0.000      -0.007
-0.006
Is_Summer           -0.0111      0.004     -3.098      0.002      -0.018
-0.004
Is_Fall              0.0322      0.003     10.007      0.000       0.026
0.038
Is_Spring           -0.0050      0.003     -1.653      0.098      -0.011
0.001
```

==
====

CONCLUSIONES Tanto el modelo Logit como el Probit se ajustan mejor que OLS para modelar una variable binaria como Fail. El Logit tuvo una Pseudo R^2 apenas superior (0.302 vs 0.301), pero ambos son prácticamente equivalentes en rendimiento. El modelo OLS, aunque útil para exploración inicial, no es adecuado para este tipo de problema, ya que no limita las predicciones entre 0 y 1.

Coeficientes:

En OLS, los coeficientes representan cambios absolutos en la probabilidad. En Logit y Probit, los coeficientes representan cambios en los log-odds (logit) o en la función normal inversa (probit). Para ambos, es mejor interpretar los efectos marginales (que mostraste con .get_margeff()). Variables como Min_Temp, Max_Temp, Parameter4_9am, y Parameter1_Speed son altamente significativas y con efectos consistentes entre modelos.

Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

Modelo 2: Probit Pseudo $R^2 = 0.3011 \rightarrow$ Buen nivel de ajuste para un modelo de clasificación. Todos los coeficientes principales son estadísticamente significativos ($p < 0.05$).

La mayoría de los signos de los coeficientes tienen sentido económico o físico (por ejemplo, aumento de Min_Temp aumenta la probabilidad de falla, lo que podría asociarse a condiciones extremas). La función de enlace Probit utiliza la distribución normal acumulada, lo que suaviza el efecto de los predictores.

Modelo 3: Logit Pseudo $R^2 = 0.3021 \rightarrow$ Prácticamente igual al modelo Probit, pero ligeramente superior. Signos y significancia de las variables son casi idénticos al modelo Probit, lo que sugiere consistencia. La diferencia principal es el uso de una función logística como función de enlace, que es más interpretada en términos de odds.

Modelo 4: OLS $R^2 = 0.262 \rightarrow$ Mucho menor ajuste comparado con los modelos Probit y Logit. El modelo asume que la variable dependiente es continua, lo cual no es el caso aquí (la variable Fail es binaria). Aunque los coeficientes pueden ser significativos, las predicciones pueden quedar fuera del rango [0, 1], lo que es problemático para clasificación. OLS se puede usar exploratoriamente, pero no es apropiado para inferencia en variables binarias.

¿Por qué existen diferencias entre los modelos? Naturaleza del modelo: OLS asume una relación lineal y no considera que la variable dependiente sea binaria. Logit y Probit sí respetan esa naturaleza al modelar la probabilidad de ocurrencia de un evento.

Función de enlace: Logit usa la función logística, Probit usa la función normal acumulada. Aunque dan resultados similares, difieren en la forma en que suavizan los cambios de probabilidad.

Interpretación de coeficientes: En OLS: cambios absolutos en la variable dependiente. En Logit/Probit: cambios en los log-odds (logit) o z-scores normalizados (probit). Se requiere calcular efectos marginales para interpretarlos fácilmente.

¿Cuál modelo es el más adecuado? El modelo Logit sería el más adecuado, ya que iene el mejor ajuste (Pseudo R^2 más alto). Converge bien, y tiene resultados robustos y estadísticamente significativos. Sus efectos marginales son más fáciles de interpretar en contextos prácticos. Probit también sería aceptable, especialmente si se justifica teóricamente el uso de la normalidad (por ejemplo, decisiones latentes). OLS, en cambio, no debería usarse como modelo final por la naturaleza de la variable dependiente.

¿Qué variables resultaron ser robustas? Min_Temp: Aumenta riesgo de falla. Max_Temp: Disminuye riesgo (quizás relacionado con clima estable). Parameter1_Speed: A mayor velocidad, mayor probabilidad de falla. Parameter4_9am: Fuerte impacto positivo. Parameter5_9am: Relación negativa consistente. Parameter3_9am/3pm: Cambios sutiles pero robustos. Location: Efecto leve pero significativo.

Agregue la data a nivel mensual, usando la data promedio de las variables (ignorando aquellas categoricas, como la direccion del viento). En particular, genere una variable que cuente la cantidad de fallos observados en un mes, utilice un valor de 0 si en ese mes no se reporto fallos en ningun dia. Use un modelo Poisson para explicar el numero de fallas por mes. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[16]:
```
df_mes = df.drop(['Date','Failure_today',
                  'Parameter1_Dir','Parameter2_9am','Parameter2_3pm',␣
↪'Is_P1Dir_West', 'Is_P1Dir_South', 'Is_P1Dir_East', 'Is_P1Dir_North',
                  'Is_P29am_North', 'Is_P29am_West', 'Is_P29am_South',␣
↪'Is_P29am_East',
                  'Is_P23pm_North', 'Is_P23pm_West', 'Is_P23pm_South',␣
↪'Is_P23pm_East',
                  'Is_Winter','Is_Summer','Is_Fall','Is_Spring'
                   ], axis=1)




# Creamos un diccionario con funciones agregadas
agg_dict = {col: 'mean' for col in df_mes.columns if col not in ['Year',␣
↪'Month', 'Location', 'Fail']}
agg_dict['Fail'] = 'sum'

# Aplicamos el groupby con agregación personalizada
df_mes = df_mes.groupby(['Year', 'Month', 'Location']).agg(agg_dict).
↪reset_index()


#df_mensual = df_mensual.groupby(['Year', 'Month','Location']).mean()
df_mes['Has_Failed'] = df_mes['Fail'].apply(lambda x: 1 if x != 0.0 else 0)

# Imputar NaNs con la media de cada columna para limpiar que y que no hayan␣
↪datos faltantes, en vez de eliminarlos mejor usamos la media
# Para que no haya un impacto en las otras filas y en los otros
for col in df_mes.columns:
    if df_mes[col].isna().sum() > 0:
        df_mes[col].fillna(df_mes[col].mean(), inplace=True)
df_mes
```

[16]:
```
      Year  Month  Location   Min_Temp   Max_Temp   Leakage  Evaporation  \
0     2007     11        10  11.753333  25.053333  3.180000     5.900000
1     2007     12        10  13.312903  25.119355  3.258065     5.819355
2     2008      1        10  15.348387  29.125806  1.412903     7.941935
3     2008      2        10  12.700000  24.572414  2.227586     5.862069
4     2008      2        38  18.503448  24.751724  8.910345     5.442857
…      …     …        …          …          …         …
4762  2017      6        45   4.424000  14.744000  0.648000     1.344000
4763  2017      6        46  10.100000  18.356000  9.256000     5.623591
4764  2017      6        47   8.736000  18.616000  3.760000     5.623591
4765  2017      6        48  11.788889  17.816667  4.177778     5.623591
4766  2017      6        49   5.800000  18.754167  0.008333     2.977273

      Electricity  Parameter1_Speed  Parameter3_9am  …  Parameter5_9am  \
0        7.880000         41.266667        9.166667  …     1018.550000
1        8.287097         40.580645       10.032258  …     1015.051613
2        9.119355         43.064516        9.709677  …     1014.096774
3        8.234483         40.896552        9.777778  …     1013.479310
4        5.662069         40.010661       12.931034  …     1013.513793
…             …                …               …  …          …
4762     4.632000         24.040000        4.960000  …     1028.816000
4763     7.631128         34.120000       16.440000  …     1025.720000
4764     7.631128         34.000000        9.520000  …     1024.156000
4765     7.631128         37.166667       14.666667  …     1026.405556
4766     0.000000         27.666667       11.375000  …     1029.704167

      Parameter5_3pm  Parameter6_9am  Parameter6_3pm  Parameter7_9am  \
0        1015.450000        4.400000        4.866667       16.750000
1        1012.696774        5.000000        4.903226       17.767742
2        1011.290323        4.225806        4.000000       19.716129
3        1010.717241        4.551724        4.724138       16.265517
4        1012.106897        5.965517        5.586207       20.903448
…              …               …               …               …
4762     1026.476000        4.960000        5.400000        6.736000
4763     1023.492000        6.250000        6.812500       13.168000
4764     1022.168000        4.577925        4.574191       12.948000
4765     1024.283333        7.000000        5.555556       14.922222
4766     1027.033333        2.826087        3.833333       10.495833

      Parameter7_3pm  Log_Leakage  Normal_Leakage  Fail  Has_Failed
0          23.720000     0.568132        0.098052     7           1
1          23.200000     0.804126        0.107274    12           1
2          27.348387     0.349507       -0.110697     5           1
3          23.210345     0.616497       -0.014458     9           1
4          23.203448     1.313197        0.774984    15           1
…              …            …              …  …     …
4762       13.696000     0.262493       -0.201056     3           1
```

```
4763      17.304000     1.333564       0.815816    13           1
4764      17.360000     0.808710       0.166568     9           1
4765      16.855556     0.593036       0.215920     4           1
4766      18.070833     0.007597      -0.276621     0           0

[4767 rows x 23 columns]
```

Finalmente aplicamos poisson.

[17]:
```python
import statsmodels.api as sm

# Definir variables dependiente e independientes
y = df_mes['Fail']
X = df_mes[['Year','Month', 'Location', 'Min_Temp', 'Max_Temp', 'Leakage',␣
 ↪'Evaporation', 'Electricity', 'Parameter1_Speed', 'Parameter3_9am',␣
 ↪'Parameter3_3pm',
            'Parameter4_9am', 'Parameter4_3pm', 'Parameter5_9am',␣
 ↪'Parameter5_3pm', 'Parameter6_9am', 'Parameter6_3pm', 'Parameter7_9am',␣
 ↪'Parameter7_3pm', 'Parameter7_3pm']]
X = sm.add_constant(X)

# Modelo Poisson
poisson_model = sm.GLM(y, X, family=sm.families.Poisson())
poisson_results = poisson_model.fit()
print(poisson_results.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:                   Fail   No. Observations:                 4767
Model:                            GLM   Df Residuals:                     4747
Model Family:                 Poisson   Df Model:                           19
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -10832.
Date:             jue, 24 abr. 2025   Deviance:                       5404.8
Time:                        22:27:19   Pearson chi2:                 4.83e+03
No. Iterations:                     5   Pseudo R-squ. (CS):             0.8633
Covariance Type:            nonrobust
================================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
const               12.0695      4.961      2.433      0.015       2.346
21.793
Year                 0.0009      0.002      0.381      0.703      -0.004
0.005
Month                0.0274      0.002     13.771      0.000       0.023
```

```
0.031
Location            -0.0007       0.000     -1.624      0.104      -0.001
0.000
Min_Temp             0.0223       0.006      3.759      0.000       0.011
0.034
Max_Temp            -0.1096       0.008    -13.866      0.000      -0.125
-0.094
Leakage              0.0445       0.002     25.460      0.000       0.041
0.048
Evaporation         -0.0341       0.004     -7.849      0.000      -0.043
-0.026
Electricity         -0.0189       0.006     -2.967      0.003      -0.031
-0.006
Parameter1_Speed     0.0245       0.002     14.362      0.000       0.021
0.028
Parameter3_9am      -0.0024       0.002     -1.046      0.296      -0.007
0.002
Parameter3_3pm      -0.0302       0.002    -12.645      0.000      -0.035
-0.026
Parameter4_9am       0.0261       0.001     18.657      0.000       0.023
0.029
Parameter4_3pm      -0.0072       0.002     -4.784      0.000      -0.010
-0.004
Parameter5_9am      -0.1261       0.010    -12.216      0.000      -0.146
-0.106
Parameter5_3pm       0.1131       0.010     10.928      0.000       0.093
0.133
Parameter6_9am      -0.0157       0.009     -1.667      0.096      -0.034
0.003
Parameter6_3pm       0.0728       0.011      6.848      0.000       0.052
0.094
Parameter7_9am       0.1035       0.009     10.944      0.000       0.085
0.122
Parameter7_3pm      -0.0028       0.003     -0.897      0.370      -0.009
0.003
Parameter7_3pm      -0.0028       0.003     -0.897      0.370      -0.009
0.003
================================================================================
====
```

Variables no significativas: Parameter3_9am Parameter7_3pm Location Year

Variables robustas: Min_Temp (positivo) Max_Temp (negativo) Parameter1_Speed (positivo) Parameter4_9am (positivo) Parameter5_9am (negativo) Leakage (positivo)

Determine sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

[20]:
```python
import statsmodels.api as sm

# Ajuste del modelo Poisson
poisson_model = sm.GLM(y, X, family=sm.families.Poisson()).fit()

# Verificar sobredispersión
print("Deviance / DF Residual:", poisson_model.deviance / poisson_model.
↪df_resid)
```

```
Deviance / DF Residual: 1.1385778519360172
```

[ ]:
```python
import statsmodels.api as sm

# Asume que 'X' es la matriz de variables explicativas y 'y' es la columna Fail
nb_model = sm.GLM(y, X, family=sm.families.NegativeBinomial())
nb_results = nb_model.fit()
print(nb_results.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:                   Fail   No. Observations:                 4767
Model:                            GLM   Df Residuals:                     4747
Model Family:        NegativeBinomial   Df Model:                           19
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -13366.
Date:               jue, 24 abr. 2025   Deviance:                       1173.8
Time:                        22:29:01   Pearson chi2:                     809.
No. Iterations:                    13   Pseudo R-squ. (CS):             0.2667
Covariance Type:            nonrobust
================================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
----
const               15.9068     14.097      1.128      0.259     -11.722
43.536
Year                -0.0012      0.007     -0.177      0.859      -0.014
0.012
Month                0.0309      0.005      5.678      0.000       0.020
0.042
Location            -0.0011      0.001     -0.934      0.350      -0.003
0.001
Min_Temp             0.0232      0.015      1.532      0.125      -0.006
0.053
Max_Temp            -0.1280      0.022     -5.838      0.000      -0.171
-0.085
Leakage              0.0856      0.007     12.379      0.000       0.072
```

```
0.099
Evaporation          -0.0208      0.010     -2.155      0.031      -0.040
-0.002
Electricity          -0.0346      0.017     -2.057      0.040      -0.068
-0.002
Parameter1_Speed      0.0275      0.005      5.399      0.000       0.018
0.038
Parameter3_9am       -0.0001      0.006     -0.019      0.984      -0.012
0.012
Parameter3_3pm       -0.0382      0.007     -5.712      0.000      -0.051
-0.025
Parameter4_9am        0.0284      0.004      7.366      0.000       0.021
0.036
Parameter4_3pm       -0.0135      0.004     -3.023      0.003      -0.022
-0.005
Parameter5_9am       -0.1620      0.028     -5.710      0.000      -0.218
-0.106
Parameter5_3pm        0.1494      0.029      5.232      0.000       0.093
0.205
Parameter6_9am        0.0014      0.025      0.058      0.954      -0.047
0.050
Parameter6_3pm        0.0968      0.029      3.386      0.001       0.041
0.153
Parameter7_9am        0.1205      0.025      4.785      0.000       0.071
0.170
Parameter7_3pm       -0.0024      0.009     -0.264      0.792      -0.020
0.015
Parameter7_3pm       -0.0024      0.009     -0.264      0.792      -0.020
0.015
================================================================================
====
```

[24]:
```
#Alpha es la estimacion de de la dispersion de la data

var = df_mes['Fail'].var()
media = df_mes['Fail'].mean()

print("Media:", media)
print("Varianza:", var)
```

```
Media: 6.598489616110761
Varianza: 19.592847067821232
```

Para calcular alpha debe resolver lo siguiente: $\alpha = \frac{\text{Varianza} - \mu}{\mu^2}$

[25]:
```
print("Alpha:", (var-media)/media**2)
```

```
Alpha: 0.2984459804519457
```

Ese valor de $= 0.298$ indica que existe sobredispersión en los datos.

Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[ ]:
```python
print(significant_vars.shape)

import matplotlib.pyplot as plt
import seaborn as sns

# Ordenar por coeficiente para mejor visualización
significant_vars = significant_vars.sort_values('Coeficiente')

plt.figure(figsize=(10, 6))

# Barplot sin errorbars
sns.barplot(
    x='Coeficiente',
    y='Variable',
    data=significant_vars,
    palette='coolwarm',
    orient='h'
)

# Añadir barras de error con matplotlib
plt.errorbar(
    x=significant_vars['Coeficiente'],
    y=range(len(significant_vars)),
    xerr=significant_vars['Error Std'],
    fmt='none',
    ecolor='black',
    capsize=3
)

plt.title('Coeficientes Significativos del Modelo Binomial Negativo')
plt.axvline(0, color='gray', linestyle='--')
plt.xlabel('Coeficiente')
plt.ylabel('Variable')
plt.tight_layout()
plt.show()
```

```
(13, 7)
```

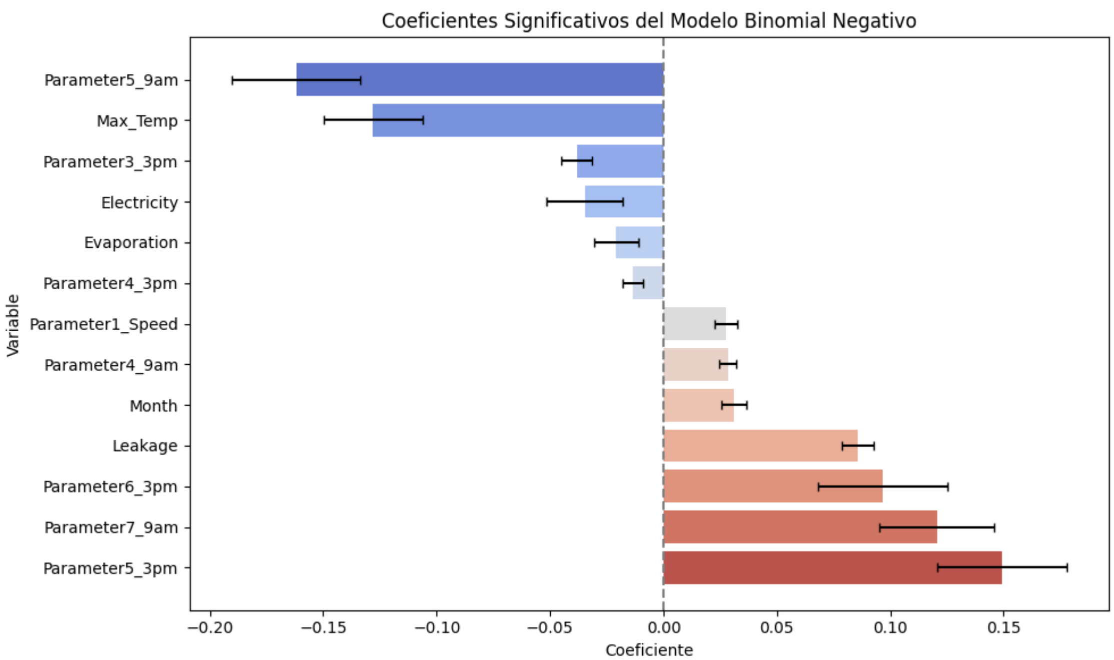

El gráfico de coeficientes significativos del modelo binomial negativo revela que varias variables tienen un impacto estadísticamente significativo sobre la variable dependiente. En particular, se observan efectos tanto positivos como negativos. Entre los más destacados, Parameter5_9am y Max_Temp presentan coeficientes negativos pronunciados, lo que sugiere que un aumento en estas variables se asocia con una disminución en el resultado esperado. Por otro lado, variables como Parameter5_3pm, Parameter7_9am y Parameter6_3pm muestran efectos positivos significativos, indicando que incrementos en estos predictores están relacionados con un aumento en el número esperado de eventos.

Estos resultados aportan evidencia empírica relevante sobre los factores que influyen significativamente en el fenómeno estudiado, y pueden servir como base para futuras decisiones analíticas o intervenciones prácticas.

Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

Los modelos estimados presentan diferencias notables en la significancia de los coeficientes y en la magnitud de los efectos. Estas diferencias se deben principalmente a cómo cada modelo maneja la dispersión de los datos:

Modelo de Poisson: Asume equidispersión (media = varianza). Este supuesto no se cumple en nuestros datos, lo que afecta la validez de los errores estándar y puede llevar a una identificación errónea de variables significativas.

Modelo Binomial Negativo: Introduce un parámetro de sobre-dispersión que permite que la varianza sea mayor que la media, ajustándose mejor a los datos. Este modelo mostró un mejor ajuste y una identificación más razonable de variables significativas.

Modelo Quasi-Poisson o Poisson con errores robustos: Corrige la dispersión en los errores estándar sin modificar la función de verosimilitud. Es útil para obtener inferencia válida en presencia de sobre-dispersión, pero no mejora el ajuste del modelo como sí lo hace el Binomial Negativo.

Diferencias en los resultados:

Las diferencias en los coeficientes significativos se deben a la sensibilidad de cada modelo frente a la sobre-dispersión. En el modelo de Poisson algunos efectos pueden haber aparecido como significativos por errores estándar subestimados. El modelo Binomial Negativo ajustó mejor los datos, reduciendo falsos positivos y mostrando una imagen más fiable de las relaciones entre variables. El modelo Quasi-Poisson ofreció una solución intermedia, con coeficientes similares al de Poisson, pero errores estándar más realistas.

Modelo más adecuado:

En mi opinión, el modelo Binomial Negativo es el más adecuado. Este modelo captura adecuadamente la estructura de dispersión de los datos, proporciona estimaciones consistentes y permite una mejor identificación de las variables relevantes, todo lo cual es crucial para interpretar correctamente los determinantes del fenómeno observado.

Variables robustas a la especificación:

Al comparar los tres modelos, se observa que algunas variables como Max_Temp, Electricity, y Parameter5_3pm aparecen como significativas de manera consistente. Esto sugiere que estos predictores son robustos a la especificación del modelo, es decir, su relevancia no depende del tipo de modelo utilizado, lo que fortalece la confianza en su efecto sobre la variable dependiente.