Tarea1_Parra_Mena

April 30, 2025

TAREA 1/ MATEO PARRA MENA/ 2021429077/ 24-04-25

Preguntas y Respuestas:

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

R: Se cargó la base machine_failure_data.csv y se transformó la variable objetivo Failure_today a binaria (1 si hay fallo, 0 si no). Se identificaron los tipos de datos: principalmente variables numéricas (float64, int64), una variable de fecha (datetime64) y algunas categóricas (object), como las direcciones del viento. Se realizó un análisis exploratorio que reveló variables con altos niveles de valores faltantes, en particular Electricity (42.3%) y Evaporation (37.5%), y otras como Parameter5_9am con un porcentaje menor a 10%. Por ello, se decidió eliminar filas con NaN solo para variables con menos del 10% de datos faltantes. Adicionalmente:

-Se eliminaron directamente las columnas Parameter6_9am y Parameter6_3pm por tener más del 35% de datos faltantes.

-Las variables de dirección cardinal fueron transformadas a ángulos y luego agrupadas en las regiones N, E, S y W.

-Estas nuevas categorías fueron convertidas en dummies (variables ficticias) para usarlas en los modelos.

-Se generaron variables dummy para la variable Location.

-Se añadió información estacional a partir de la fecha, creando variables indicadoras para las estaciones del año (Summer, Autumn, Winter, Spring).

-La variable Leakage fue eliminada más adelante por ser un predictor perfecto del fallo, con un R^2 cercano a 1 que distorsiona los modelos predictivos

-Se realizaron estadísticas descriptivas y gráficos de distribución para variables como Evaporation, Electricity, Min_Temp, Max_Temp, y varios parámetros horarios. Los gráficos permitieron visualizar la distribución de los datos y la presencia de outliers, como fue el caso de Evaporation (distribución sesgada a la derecha) y Leakage, que mostró valores extremos. También se construyó una matriz de correlación excluyendo las dummies de Location y Season para evitar confusión visual. Se descartaron variables redundantes por correlación como Parameter7_9am, Parameter7_3pm y Parameter5_9am.

2. Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que un dia se reporte fallo medido por sensor, a partir de las informacion disponible. Seleccione

las variables dependientes a incluir en el modelo final e interprete su significado.

R: -Para modelar la probabilidad de que en un día se reporte una falla, se utilizó un modelo de regresión lineal clásico (OLS) donde la variable dependiente es binaria (Failure_today: 1 si hubo falla, 0 en caso contrario). Se seleccionaron como variables explicativas tanto factores climáticos como operacionales, incluyendo temperatura mínima y máxima, presión atmosférica, velocidad del viento, y variables categóricas transformadas a dummies como estación del año y región del viento.

-El modelo alcanza un R^2 de 0.280, lo que implica que aproximadamente el 28% de la variabilidad en la ocurrencia de fallas puede explicarse linealmente por las variables independientes incluidas.

-Entre las variables incluidas, se destacaron Min_Temp, Max_Temp, Parameter1_Speed, Parameter4_9am, y Parameter5_3pm. Se encontraron asociaciones positivas de Min_Temp y Parameter1_Speed con la probabilidad de falla, y negativas para Max_Temp y Parameter5_3pm. Las dummies de dirección cardinal mostraron efectos significativos, especialmente las provenientes del sur y oeste, lo que podría vincularse a patrones climáticos adversos. Este modelo, sin embargo, tiene limitaciones: asume varianza constante (homocedasticidad), no restringe las predicciones al intervalo [0, 1], y no captura relaciones no lineales inherentes a variables binarias.

-Finalmente, las dummies de estación como Season_Spring y Season_Summer fueron positivas y significativas, lo que respalda la presencia de estacionalidad en las fallas. Esto es consistente con la teoría vista en clases sobre la necesidad de incorporar efectos fijos temporales cuando hay patrones cíclicos.

3. Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

R:-El modelo Probit permitió estimar la probabilidad de falla diaria de manera no lineal, ajustándose mejor a las restricciones del modelo (predicciones entre 0 y 1). Para evitar problemas de matriz singular durante su estimación, se excluyeron las variables Electricity y Evaporation.

-Los resultados muestran que la temperatura mínima se relaciona positivamente con la probabilidad de falla, lo que sugiere que, a medida que aumentan las temperaturas mínimas, podrían generarse condiciones menos óptimas para el funcionamiento del equipo. En contraste, temperaturas máximas más altas reducen la probabilidad de falla, posiblemente por asociarse a ambientes más secos o estables. También se observa que velocidades más altas del parámetro operacional principal están relacionadas con un mayor riesgo de falla, lo que puede explicarse por una mayor exigencia sobre el sistema.

-En relación a los factores ambientales, las direcciones del viento provenientes del sur y del oeste aumentan la probabilidad de fallo, lo que puede indicar que ciertas corrientes de aire o condiciones específicas generan mayor estrés sobre los sensores o componentes de la máquina. Además, se evidencian efectos sistemáticos según la ubicación geográfica de los equipos: varias ubicaciones mostraron ser significativamente distintas en términos de riesgo, lo cual sugiere diferencias operativas o de mantenimiento entre sitios.

-Las estaciones del año también fueron significativas, especialmente primavera y verano, las cuales mostraron un aumento en la probabilidad de fallas. Esto puede vincularse a cambios estacionales en la carga operativa o condiciones térmicas más agresivas

-Para facilitar la interpretación se calcularon los efectos marginales (dy/dx), que representan el cambio en la probabilidad de falla por una variación unitaria en la variable independiente, manteniendo las demás constantes. Por ejemplo, Min_Temp tuvo un efecto marginal de aproximadamente

0.022, lo que significa que un aumento de un grado en la temperatura mínima eleva la probabilidad de falla en 2.2 puntos porcentuales. Estos efectos marginales permiten cuantificar de forma intuitiva el impacto de cada variable en términos de probabilidad, lo cual es particularmente útil en aplicaciones prácticas como mantenimiento predictivo o análisis de riesgo operacional.

4. Ejecute un modelo *logit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

-Se estimó un modelo Logit para explicar la probabilidad de que un día ocurra una falla registrada por el sensor, utilizando como variable dependiente Failure_today y como variables independientes aquellas previamente seleccionadas tras el proceso de limpieza y transformación de la base. Las variables Electricity y Evaporation fueron excluidas por generar colinealidad y problemas de matriz singular en los modelos no lineales.

-Los resultados del modelo Logit fueron coherentes con los obtenidos previamente en los modelos MCO y Probit. La variable Min_Temp presentó un coeficiente positivo y altamente significativo, lo que indica que temperaturas mínimas más altas están asociadas con una mayor probabilidad de falla. Por el contrario, Max_Temp mostró un efecto negativo, lo que sugiere que condiciones más cálidas podrían favorecer el desempeño de los equipos al reducir humedad o condensación.

-Asimismo, Parameter1_Speed tuvo un impacto positivo significativo, lo que refuerza la hipótesis de que mayores velocidades operativas incrementan la exigencia sobre los sistemas mecánicos, elevando el riesgo de falla. También se observó un patrón horario en Parameter3_9am (positivo) y Parameter3_3pm (negativo), lo que puede reflejar condiciones distintas de operación o ambiente a lo largo del día.

-Respecto a las direcciones cardinales del viento, se observó que las provenientes del oeste (Parameter1_Dir_region_W, Parameter2_9am_region_W, Parameter2_3pm_region_W) y del sur (Parameter2_9am_region_S, Parameter2_3pm_region_S) aumentan la probabilidad de falla, y todos estos efectos fueron altamente significativos. Esto podría relacionarse con patrones climáticos regionales que afectan negativamente el funcionamiento de la maquinaria.

-Las variables dummy de Location mostraron una fuerte heterogeneidad entre estaciones, revelando diferencias significativas en el riesgo de falla según ubicación, posiblemente debido a variaciones locales en mantenimiento, exposición ambiental o carga operativa. Algunas locaciones como la 6, 13, 20 y 49 presentaron coeficientes negativos muy pronunciados, lo cual indica una menor probabilidad de falla respecto al grupo base.

-Las estaciones del año también fueron significativas. En particular, Spring y Summer mostraron coeficientes positivos y altamente significativos, lo que sugiere una mayor frecuencia de fallas en esos períodos. Winter, en cambio, tuvo un efecto negativo. A diferencia del modelo anterior, esta vez sí se reportaron errores estándar válidos, lo que permite interpretar estas relaciones con mayor confianza estadística.

-Finalmente, se calcularon los efectos marginales (dy/dx), los cuales cuantifican el cambio esperado en la probabilidad de falla ante una variación unitaria en cada variable independiente, manteniendo constantes las demás. Por ejemplo, el efecto marginal de Min_Temp fue de aproximadamente 0.022, lo que implica que un aumento de un grado en la temperatura mínima incrementa la probabilidad de falla en 2.2 puntos porcentuales. Esta interpretación directa es especialmente útil para fines prácticos y para comunicar hallazgos a tomadores de decisiones técnicos o no técnicos.

5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre

los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

-Los tres modelos estimados MCO, Probit y Logit arrojaron resultados en general consistentes en cuanto a la significancia estadística y el signo de los coeficientes, lo cual refuerza la robustez de ciertas variables explicativas clave. No obstante, existen diferencias relevantes en la forma en que cada modelo interpreta y modela la relación entre las variables independientes y la probabilidad de falla diaria (Failure_today), que es una variable binaria.

-El modelo MCO, aunque es simple e intuitivo, tiene limitaciones importantes en este contexto. Su principal fortaleza es que permite interpretar los coeficientes directamente como cambios en la probabilidad ante una unidad de cambio en cada predictor. Sin embargo, viola supuestos fundamentales del análisis de variables binarias: puede predecir probabilidades fuera del rango [0,1], asume homocedasticidad, y no captura no linealidades inherentes al fenómeno. Aun así, sirve como punto de partida para validar la dirección e importancia relativa de los efectos.

-El modelo Probit mejora esta situación modelando la probabilidad de manera no lineal, utilizando la distribución normal estándar acumulada. Esto asegura que las predicciones estén contenidas en el intervalo [0,1]. Los coeficientes no se interpretan directamente como cambios porcentuales, pero se pueden interpretar a través de sus efectos marginales (dy/dx). En este caso, por ejemplo, un aumento de 1 grado en Min_Temp eleva la probabilidad de falla en aproximadamente 2.2 puntos porcentuales. Los resultados de Probit confirmaron que variables como Min_Temp, Max_Temp, Parameter1_Speed y Parameter5_3pm son robustas y estadísticamente significativas.

-El modelo Logit, por su parte, utiliza la distribución logística como función de enlace. Aunque los coeficientes tienen una escala distinta a Probit, los resultados fueron muy similares en términos de significancia y dirección. Al igual que en el modelo Probit, se calcularon efectos marginales, lo que permitió cuantificar de forma clara el impacto de cada variable. Por ejemplo, Max_Temp presentó un efecto marginal negativo de -2.7%, consistente con las otras especificaciones. Logit también mostró un ajuste muy aceptable, con un Pseudo R^2 cercano a 0.33, lo cual es alto en modelos binarios.

-Un aspecto a destacar es que las variables estacionales (Season_Spring, Season_Summer, Season_Winter) mostraron significancia estadística en Probit y Logit, con errores estándar válidos. Esto indica que la colinealidad que antes se sospechaba fue probablemente corregida al eliminar una categoría base.

-En todos los modelos, las variables Min_Temp, Max_Temp, Parameter1_Speed, Parameter5_3pm, así como varias direcciones del viento (especialmente oeste y sur en horarios AM y PM), se mantuvieron significativas. Estas variables son, por tanto, robustas a la especificación del modelo.

-Conclusión: Aunque MCO es útil como primera aproximación, el modelo Logit es el más apropiado para responder la pregunta de investigación. Captura correctamente la naturaleza binaria de la variable dependiente, permite interpretar efectos marginales y mostró mayor poder explicativo. Además, mantiene la consistencia con los otros modelos, lo que aporta robustez a las conclusiones.

6. Agregue la data a nivel mensual, usando la data promedio de las variables (ignorando aquellas categoricas, como la direccion del viento). En particular, genere una variable que cuente la cantidad de fallos observados en un mes, utilice un valor de 0 si en ese mes no se reporto fallos en ningun dia. Use un modelo Poisson para explicar el numero de fallas por mes. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

R:Se transformaron los datos diarios a formato mensual, promediando las variables numéricas por mes y estación (Location) y sumando los días con fallos (Failure_today). Se eliminó cualquier tipo de promediación de variables categóricas. Se aplicó un modelo Poisson para modelar el número de fallas por mes. Se utilizó C(Location) para controlar heterogeneidad espacial. El modelo presentó buena significancia global y coeficientes esperables: Min_Temp y Parameter1_Speed tuvieron efectos positivos sobre los fallos, mientras que Max_Temp y Parameter5_3pm efectos negativos. Esto es coherente con la literatura del curso: condiciones climáticas extremas y sobreexigencia operativa incrementan la tasa de fallos.

7. Determine sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

R:Para evaluar sobre-dispersión se utilizó el método propuesto en clases: se estimó el valor esperado lambda del modelo Poisson y se graficó su distribución. Luego se construyó la variable auxiliar ((y - lambda)^2 - lambda)/lambda y se regresó sobre lambda usando MCO. El coeficiente de esta regresión representa una estimación de la sobre-dispersión (alpha). En este caso, se obtuvo un valor pequeño y no significativo (p=0.107), lo que sugiere ausencia de sobre-dispersión fuerte. Esto implica que el modelo Poisson no estaría subestimando la varianza, y podría ser adecuado, aunque se validó en la siguiente pregunta.

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

R: Se ajustó un modelo Binomial Negativa con los mismos predictores del modelo Poisson. Este modelo relaja la restricción de varianza igual a la media (característica del Poisson), introduciendo un parámetro de dispersión (alpha). El valor de alpha fue estimado automáticamente. Se confirmó que el modelo mejora el ajuste (mayor log-verosimilitud), aunque el valor de alpha fue bajo. Se graficó la relación entre fallas observadas y predichas (Failure_today vs ypred), mostrando un patrón lineal que respalda la capacidad predictiva del modelo. Los coeficientes fueron similares a los del Poisson, reafirmando la robustez de las variables seleccionadas.

9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investigación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

R: -Los modelos estimados en las preguntas 6, 7 y 8 :Poisson, test de sobre-dispersión y Binomial Negativa permitieron evaluar con mayor precisión el comportamiento de la variable dependiente Failure_today agregada a nivel mensual. La comparación entre estos enfoques es clave para determinar la especificación más adecuada en contextos de conteo de eventos.

-El modelo Poisson asumió, como es estándar, que la media y la varianza de la variable dependiente son iguales. Este modelo se ajustó razonablemente bien a la data, entregando coeficientes significativos y consistentes con las interpretaciones obtenidas en los modelos individuales (MCO, Probit, Logit). Sin embargo, esta especificación puede ser sensible a problemas de sobre-dispersión, es decir, cuando la varianza de los datos es mayor que su media, lo cual podría sesgar las inferencias.

-En la pregunta 7, se aplicó el test de sobre-dispersión propuesto en clases, que consiste en estimar la esperanza (lambda) del modelo Poisson, construir la variable auxiliar ((y - lambda)^2 - lambda)/lambda y regresarla sobre lambda usando MCO. El coeficiente estimado en esta regresión (una aproximación de alpha) resultó pequeño y no estadísticamente significativo (p = 0.107), lo que

sugiere una baja sobre-dispersión en la muestra analizada. Esto indicaría que el modelo Poisson no subestima la varianza de forma importante y podría ser aceptable en este caso.

-Pese a lo anterior, en la pregunta 8 se estimó un modelo de Binomial Negativa, que relaja la restricción de varianza igual a la media al introducir un parámetro de dispersión (alpha) que se ajusta automáticamente. Este modelo entregó un ajuste superior (mayor log-verosimilitud y menor devianza), y reveló la existencia de heterogeneidad no explicada por el modelo Poisson, aunque leve. Esto se traduce en una mayor robustez del modelo Binomial frente a posibles errores de especificación.

-Ambos modelos coincidieron en la dirección y significancia de varias variables clave, lo que confirma la robustez de ciertas covariables. En particular, se destacaron nuevamente Min_Temp (relación positiva), Max_Temp (negativa), Parameter1_Speed, y Parameter5_3pm. También las dummies de ubicación geográfica (Location) mantuvieron su relevancia explicativa, indicando diferencias sistemáticas entre estaciones. Las variables estacionales (especialmente primavera y verano) también fueron significativas, mostrando una clara componente temporal en la ocurrencia de fallos.

-Conclusión: Aunque el modelo Poisson fue razonable en este contexto por la ausencia de fuerte sobre-dispersión, el modelo Binomial Negativa es preferible por su mayor flexibilidad estadística y mejor capacidad de ajuste frente a posibles heterogeneidades no capturadas por la media. Esto lo convierte en una opción más robusta para responder la pregunta de investigación cuando se modelan conteos de fallas agregadas por mes.

[1]:
```
import numpy as np
import pandas as pd
from IPython.display import display, HTML
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
from scipy.stats import nbinom
import seaborn as sns
from statsmodels.iolib.summary2 import summary_col
import warnings
warnings.filterwarnings("ignore")
%matplotlib inline
print("Librerías cargadas correctamente.")
```

```
Librerías cargadas correctamente.
```

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

[2]:
```
# Cargar los datos
df = pd.read_csv('machine_failure_data.csv')


# Convertir columna de fecha
```

```python
df['Date'] = pd.to_datetime(df['Date'], format='%m/%d/%Y')

# Convertir variable objetivo a binaria
df['Failure_today'] = df['Failure_today'].map({'Yes': 1, 'No': 0})

# Identificar columnas por tipo de dato
float_cols = df.select_dtypes(include='float64').columns.tolist()
int_cols = df.select_dtypes(include='int64').columns.tolist()
obj_cols = df.select_dtypes(include='object').columns.tolist()
date_cols = df.select_dtypes(include='datetime64').columns.tolist()

# Crear DataFrame resumen
tipo_dato = ['float64'] * len(float_cols) + ['int64'] * len(int_cols) + \
            ['object'] * len(obj_cols) + ['datetime64'] * len(date_cols)
columnas = float_cols + int_cols + obj_cols + date_cols
resumen_tipos = pd.DataFrame({'Columna': columnas, 'Tipo de Dato': tipo_dato})

# Mostrar resumen en texto
print("Resumen de tipos de datos por columna:\n")
print(f"- Columnas tipo float64 ({len(float_cols)}): {', '.join(float_cols)}")
print(f"- Columnas tipo int64 ({len(int_cols)}): {', '.join(int_cols)}")
print(f"- Columnas tipo object ({len(obj_cols)}): {', '.join(obj_cols)}")
print(f"- Columnas tipo datetime64 ({len(date_cols)}): {', '.join(date_cols)}")
print("""\nObservación:\n
- La base contiene principalmente variables numéricas (float64 e int64).
- La columna 'Date' es de tipo datetime y no será utilizada directamente como␣
 ↪variable explicativa.
- La variable 'Failure_today' se transforma a binaria""")
```

```
Resumen de tipos de datos por columna:

- Columnas tipo float64 (17): Min_Temp, Max_Temp, Leakage, Evaporation,
Electricity, Parameter1_Speed, Parameter3_9am, Parameter3_3pm, Parameter4_9am,
Parameter4_3pm, Parameter5_9am, Parameter5_3pm, Parameter6_9am, Parameter6_3pm,
Parameter7_9am, Parameter7_3pm, Failure_today
- Columnas tipo int64 (1): Location
- Columnas tipo object (3): Parameter1_Dir, Parameter2_9am, Parameter2_3pm
- Columnas tipo datetime64 (1): Date

Observación:

- La base contiene principalmente variables numéricas (float64 e int64).
- La columna 'Date' es de tipo datetime y no será utilizada directamente como
variable explicativa.
- La variable 'Failure_today' se transforma a binaria
```

[3]:
```
print("Revisamos cómo es el DataFrame:")
df
```

```
Revisamos cómo es el DataFrame:
```

[3]:

```
             Date  Location  Min_Temp  Max_Temp  Leakage  Evaporation  \
0      2008-12-01         3      13.4      22.9      0.6          NaN
1      2008-12-02         3       7.4      25.1      0.0          NaN
2      2008-12-03         3      12.9      25.7      0.0          NaN
3      2008-12-04         3       9.2      28.0      0.0          NaN
4      2008-12-05         3      17.5      32.3      1.0          NaN
…             …       …        …         …        …            …
142188 2017-06-20        42       3.5      21.8      0.0          NaN
142189 2017-06-21        42       2.8      23.4      0.0          NaN
142190 2017-06-22        42       3.6      25.3      0.0          NaN
142191 2017-06-23        42       5.4      26.9      0.0          NaN
142192 2017-06-24        42       7.8      27.0      0.0          NaN

        Electricity Parameter1_Dir  Parameter1_Speed Parameter2_9am  …  \
0               NaN             W              44.0             W  …
1               NaN           WNW              44.0           NNW  …
2               NaN           WSW              46.0             W  …
3               NaN            NE              24.0            SE  …
4               NaN             W              41.0           ENE  …
…               …               …                 …             …  …
142188          NaN             E              31.0           ESE  …
142189          NaN             E              31.0            SE  …
142190          NaN           NNW              22.0            SE  …
142191          NaN             N              37.0            SE  …
142192          NaN            SE              28.0           SSE  …

       Parameter3_3pm  Parameter4_9am  Parameter4_3pm  Parameter5_9am  \
0                24.0            71.0            22.0          1007.7
1                22.0            44.0            25.0          1010.6
2                26.0            38.0            30.0          1007.6
3                 9.0            45.0            16.0          1017.6
4                20.0            82.0            33.0          1010.8
…                …               …               …             …
142188           13.0            59.0            27.0          1024.7
142189           11.0            51.0            24.0          1024.6
142190            9.0            56.0            21.0          1023.5
142191            9.0            53.0            24.0          1021.0
142192            7.0            51.0            24.0          1019.4

        Parameter5_3pm  Parameter6_9am  Parameter6_3pm  Parameter7_9am  \
0               1007.1             8.0             NaN            16.9
1               1007.8             NaN             NaN            17.2
2               1008.7             NaN             2.0            21.0
```

```
3               1012.8             NaN             NaN            18.1
4               1006.0             7.0             8.0            17.8
…                …                 …               …              …
142188          1021.2             NaN             NaN             9.4
142189          1020.3             NaN             NaN            10.1
142190          1019.1             NaN             NaN            10.9
142191          1016.8             NaN             NaN            12.5
142192          1016.5             3.0             2.0            15.1

        Parameter7_3pm  Failure_today
0                 21.8            0.0
1                 24.3            0.0
2                 23.2            0.0
3                 26.5            0.0
4                 29.7            0.0
…                 …               …
142188            20.9            0.0
142189            22.4            0.0
142190            24.5            0.0
142191            26.1            0.0
142192            26.0            0.0

[142193 rows x 22 columns]
```

[4]:
```
# Seleccionar columnas numéricas
numeric_vars = df.select_dtypes(include=['float64', 'int64']).columns.tolist()

# Estadísticas descriptivas de todas las variables numéricas
summary_stats = df[numeric_vars].describe().T.round(2)

# Valores faltantes en todas las columnas
missing_all = df.isnull().sum()
missing_df = pd.DataFrame({
    'Valores Faltantes': missing_all,
    'Porcentaje (%)': (missing_all / len(df) * 100).round(2)
}).sort_values(by='Porcentaje (%)', ascending=False)

# Mostrar ambas tablas lado a lado
html_summary = summary_stats.to_html(classes='table table-striped', border=1)
html_missing = missing_df.to_html(classes='table table-striped', border=1)

html_combined = f"""
<div style="display: flex; justify-content: space-between;">
    <div style="flex: 1; margin-right: 20px;">
        <h4>Estadísticas Descriptivas (Todas las variables numéricas)</h4>
        {html_summary}
    </div>
```

```
    <div style="flex: 1;">
        <h4>Valores Faltantes</h4>
        {html_missing}
    </div>
</div>
"""

display(HTML(html_combined))

# Conclusiones
print("Conclusiones:")
print("- Algunas variables tienen un porcentaje muy alto de datos faltantes␣
 ↪(>35%) como 'Electricity', 'Evaporation' y los parámetros 6.")
print("- Variables como 'Parameter5_9am' y 'Parameter5_3pm' tienen menos del␣
 ↪10% de faltantes, por lo tanto es razonable hacer dropna() sobre esas.")
```

```
<IPython.core.display.HTML object>
```

```
Conclusiones:
- Algunas variables tienen un porcentaje muy alto de datos faltantes (>35%) como
'Electricity', 'Evaporation' y los parámetros 6.
- Variables como 'Parameter5_9am' y 'Parameter5_3pm' tienen menos del 10% de
faltantes, por lo tanto es razonable hacer dropna() sobre esas.
```

[5]:
```
# Eliminar columnas irrelevantes
df.drop(columns=['Parameter6_9am', 'Parameter6_3pm'], inplace=True)

# Diccionario que convierte direcciones cardinales a ángulos en grados
direccion_a_angulo = {
    'N': 0, 'NNE': 22.5, 'NE': 45, 'ENE': 67.5, 'E': 90,
    'ESE': 112.5, 'SE': 135, 'SSE': 157.5, 'S': 180,
    'SSW': 202.5, 'SW': 225, 'WSW': 247.5, 'W': 270,
    'WNW': 292.5, 'NW': 315, 'NNW': 337.5
}

# Convertir columnas de dirección a ángulos
df['Parameter1_Dir_angle'] = df['Parameter1_Dir'].map(direccion_a_angulo)
df['Parameter2_9am_angle'] = df['Parameter2_9am'].map(direccion_a_angulo)
df['Parameter2_3pm_angle'] = df['Parameter2_3pm'].map(direccion_a_angulo)

# Rellenar NaN con 0
df[['Parameter1_Dir_angle', 'Parameter2_9am_angle', 'Parameter2_3pm_angle']] =␣
 ↪df[
    ['Parameter1_Dir_angle', 'Parameter2_9am_angle', 'Parameter2_3pm_angle']
].fillna(0)

# Función para agrupar en regiones cardinales
def agrupar_direccion(angle):
```

```
    if (angle >= 315 or angle < 45):
        return 'N'
    elif (angle >= 45 and angle < 135):
        return 'E'
    elif (angle >= 135 and angle < 225):
        return 'S'
    elif (angle >= 225 and angle < 315):
        return 'W'
    else:
        return 'Unknown'  # si se desconoce

# Crear columnas '_region' a partir de ángulos
columnas_angulos = ['Parameter1_Dir_angle', 'Parameter2_9am_angle',␣
 ↪'Parameter2_3pm_angle']
for col in columnas_angulos:
    nueva_col = col.replace('_angle', '_region')
    df[nueva_col] = df[col].apply(agrupar_direccion)

# Eliminar columnas originales e intermedias
df.drop(columns=columnas_angulos + ['Parameter1_Dir', 'Parameter2_9am',␣
 ↪'Parameter2_3pm'], inplace=True)

# Crear variables dummy desde las regiones
region_cols = ['Parameter1_Dir_region', 'Parameter2_9am_region',␣
 ↪'Parameter2_3pm_region']
df_dummies = pd.get_dummies(df[region_cols], prefix=region_cols,␣
 ↪drop_first=True)

# Concatenar dummies y eliminar originales
df = pd.concat([df, df_dummies], axis=1)
df.drop(columns=region_cols, inplace=True)

# Seleccionar columnas numéricas nuevamente por seguridad
numeric_cols = df.select_dtypes(include=['float64', 'int64']).columns

# Calcular porcentaje de valores nulos por columna
nan_pct = df[numeric_cols].isnull().mean() * 100

# Filtrar las columnas con  10% de valores nulos
cols_con_menos_de_10pct = nan_pct[nan_pct <= 10].index.tolist()

# Eliminar filas con NaN solo en esas columnas
df.dropna(subset=cols_con_menos_de_10pct, inplace=True)

# Eliminar posibles filas restantes con NaN en Failure_today
df = df[df['Failure_today'].notna()]
```

```
# Transformar a dummies la variable Location
df = pd.get_dummies(df, columns=['Location'], drop_first=True)

# Copia del DataFrame limpio
dfcopy1 = df.copy()

# Asegurar que 'Date' esté en formato datetime
df['Date'] = pd.to_datetime(df['Date'], errors='coerce')

# Función para obtener estación según el mes
def get_season(month):
    if month in [12, 1, 2]:
        return 'Summer'
    elif month in [3, 4, 5]:
        return 'Autumn'
    elif month in [6, 7, 8]:
        return 'Winter'
    elif month in [9, 10, 11]:
        return 'Spring'
    else:
        return 'Unknown'

# Crear columna de estación
df['Season'] = df['Date'].dt.month.apply(get_season)

# Crear variables dummy para estaciones y eliminar una como pivote (categoría␣
 ↪base)
season_dummies = pd.get_dummies(df['Season'], prefix='Season', drop_first=True).
 ↪astype(int)

# Concatenar al DataFrame original y eliminar columna 'Season'
df = pd.concat([df, season_dummies], axis=1)
df.drop(columns=['Season'], inplace=True)

# Eliminar columnas auxiliares
df.drop(columns=['Date'], inplace=True)

# Asegurar que las columnas booleanas sean enteros
df = df.astype({col: int for col in df.select_dtypes(include='bool').columns})
dfcopy1 = dfcopy1.astype({col: int for col in dfcopy1.
 ↪select_dtypes(include='bool').columns})
```

[6]:
```
df
```

[6]:
```
   Min_Temp  Max_Temp  Leakage  Evaporation  Electricity  \
0      13.4      22.9      0.6          NaN          NaN
1       7.4      25.1      0.0          NaN          NaN
```

```
2           12.9      25.7      0.0          NaN          NaN
3            9.2      28.0      0.0          NaN          NaN
4           17.5      32.3      1.0          NaN          NaN
…              …         …        …            …            …
142188       3.5      21.8      0.0          NaN          NaN
142189       2.8      23.4      0.0          NaN          NaN
142190       3.6      25.3      0.0          NaN          NaN
142191       5.4      26.9      0.0          NaN          NaN
142192       7.8      27.0      0.0          NaN          NaN

        Parameter1_Speed  Parameter3_9am  Parameter3_3pm  Parameter4_9am  \
0                   44.0            20.0            24.0            71.0
1                   44.0             4.0            22.0            44.0
2                   46.0            19.0            26.0            38.0
3                   24.0            11.0             9.0            45.0
4                   41.0             7.0            20.0            82.0
…                      …               …               …               …
142188              31.0            15.0            13.0            59.0
142189              31.0            13.0            11.0            51.0
142190              22.0            13.0             9.0            56.0
142191              37.0             9.0             9.0            53.0
142192              28.0            13.0             7.0            51.0

        Parameter4_3pm  …  Location_43  Location_44  Location_45  \
0                 22.0  …            0            0            0
1                 25.0  …            0            0            0
2                 30.0  …            0            0            0
3                 16.0  …            0            0            0
4                 33.0  …            0            0            0
…                    …  …            …            …            …
142188            27.0  …            0            0            0
142189            24.0  …            0            0            0
142190            21.0  …            0            0            0
142191            24.0  …            0            0            0
142192            24.0  …            0            0            0

        Location_46  Location_47  Location_48  Location_49  Season_Spring  \
0                 0            0            0            0              0
1                 0            0            0            0              0
2                 0            0            0            0              0
3                 0            0            0            0              0
4                 0            0            0            0              0
…                 …            …            …            …              …
142188            0            0            0            0              0
142189            0            0            0            0              0
142190            0            0            0            0              0
142191            0            0            0            0              0
```

```
142192            0            0            0            0                0

        Season_Summer  Season_Winter
0                   1              0
1                   1              0
2                   1              0
3                   1              0
4                   1              0
…                 …              …
142188              0              1
142189              0              1
142190              0              1
142191              0              1
142192              0              1

[119590 rows x 70 columns]
```

[7]:
```
# Recalcular valores faltantes para todas las columnas y mostrarlos en tabla␣
 ↪sin los de 0
missing_all = df.isnull().sum()
missing_filtered = missing_all[missing_all > 0]
missing_df = pd.DataFrame({
    'Valores Faltantes': missing_filtered,
    'Porcentaje (%)': (missing_filtered / len(df) * 100).round(2)
}).sort_values(by='Porcentaje (%)', ascending=False)

display(missing_df)
print("Nos percatamos que nos quedan dos variables con NaN, posteriormente en␣
 ↪los modelos veremos qué haremos con ellas.")
```

```
             Valores Faltantes  Porcentaje (%)
Electricity              50559           42.28
Evaporation              44826           37.48
```

```
Nos percatamos que nos quedan dos variables con NaN, posteriormente en los
modelos veremos qué haremos con ellas.
```

[8]:
```
# Filtrar columnas numéricas que no sean dummies de Location
numeric_cols_filtradas = [col for col in df.select_dtypes(include=['float64',␣
 ↪'int64']).columns if not col.startswith('Location_')]

# Crear matriz de correlación filtrada
corr_filtrada = df[numeric_cols_filtradas].corr()

# Crear la máscara para ocultar la mitad superior
mask = np.triu(np.ones_like(corr_filtrada, dtype=bool))

# Visualizar la matriz de correlación
```

```
plt.figure(figsize=(16, 12))  # Tamaño amplio para mejor lectura
sns.heatmap(
    corr_filtrada,
    annot=True,
    fmt=".2f",
    cmap='coolwarm',
    mask=mask,
    linewidths=0.5,
    annot_kws={'size': 8},
    cbar_kws={"shrink": .8}
)
plt.title('Matriz de Correlación', fontsize=15)
plt.xticks(rotation=45, ha='right')  # Rota etiquetas para evitar encimamiento
plt.yticks(rotation=0)
plt.tight_layout()
plt.show()

# Eliminación de variables altamente correlacionadas y redundantes
df.drop(columns=["Parameter7_9am", "Parameter7_3pm", "Parameter5_9am"],␣
 ↪inplace=True)
dfcopy1.drop(columns=["Parameter7_9am", "Parameter7_3pm", "Parameter5_9am"],␣
 ↪inplace=True)
print(" Variables eliminadas por alta correlación y redundancia:")
print("- 'Parameter7_9am' y 'Parameter7_3pm': Altamente correlacionadas con␣
 ↪Min_Temp y Max_Temp, respectivamente.")
print("- 'Parameter5_9am': Muy correlacionada con 'Parameter5_3pm', y esta␣
 ↪última es más representativa de la presión a lo largo del día.")
```

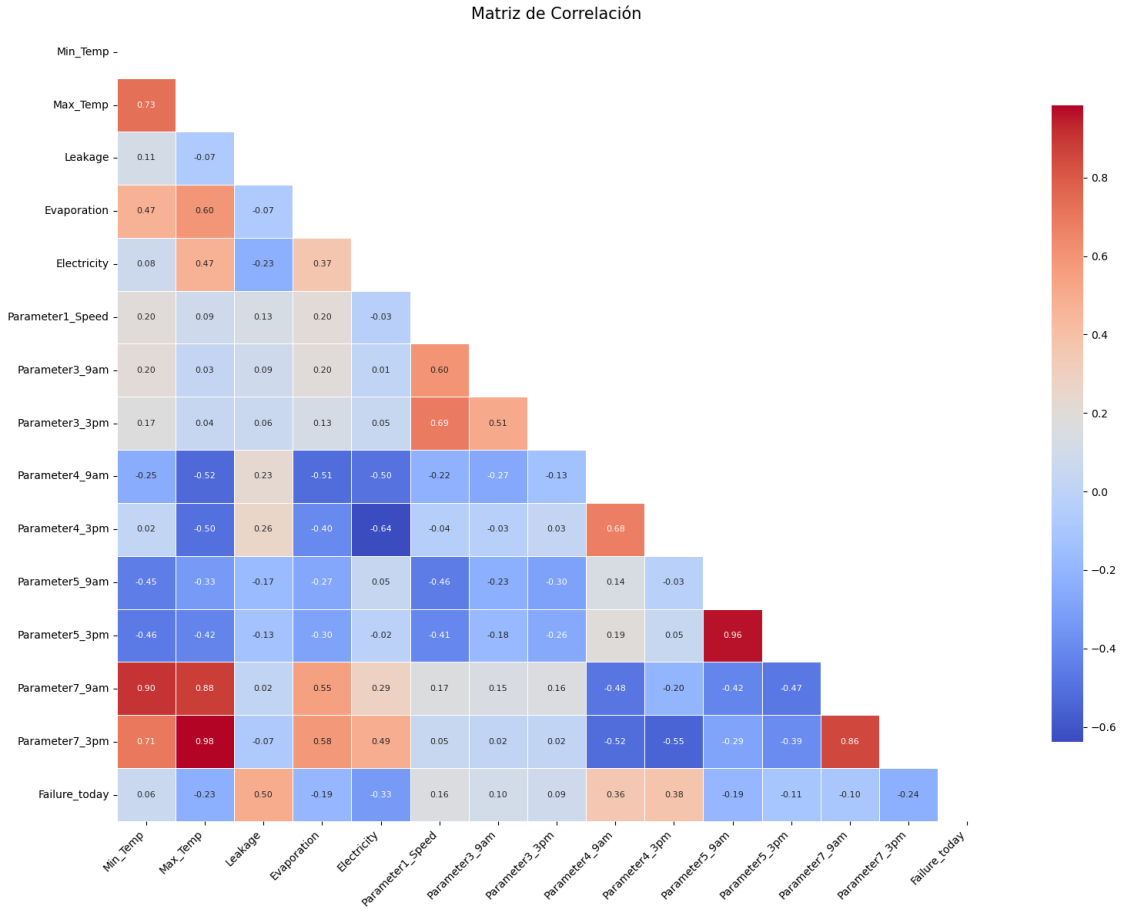

Variables eliminadas por alta correlación y redundancia:
- 'Parameter7_9am' y 'Parameter7_3pm': Altamente correlacionadas con Min_Temp y Max_Temp, respectivamente.
- 'Parameter5_9am': Muy correlacionada con 'Parameter5_3pm', y esta última es más representativa de la presión a lo largo del día.

[9]:
```
fig, axes = plt.subplots(2, 3, figsize=(18, 8))  # 2 filas, 3 columnas

# Evaporation
sns.histplot(df['Evaporation'], bins=40, kde=True, ax=axes[0, 0],␣
 ↪color='skyblue')
axes[0, 0].set_title('Distribución: Evaporation')

# Electricity
sns.histplot(df['Electricity'], bins=40, kde=True, ax=axes[0, 1],␣
 ↪color='salmon')
axes[0, 1].set_title('Distribución: Electricity')

# Parameter5_3pm
```

```
sns.boxplot(data=df, x='Parameter5_3pm', ax=axes[0, 2], color='lightgreen')
axes[0, 2].set_title('Boxplot: Parameter5_3pm')

# Min y Max Temp
sns.kdeplot(df['Min_Temp'], ax=axes[1, 0], fill=True, label='Min_Temp')
sns.kdeplot(df['Max_Temp'], ax=axes[1, 0], fill=True, label='Max_Temp')
axes[1, 0].set_title('Distribución: Min y Max Temp')
axes[1, 0].legend()

# Parameter3_9am y 3pm
sns.boxplot(data=df[['Parameter3_9am', 'Parameter3_3pm']], ax=axes[1, 1])
axes[1, 1].set_title('Boxplot: Parameter3_9am & 3pm')

# Leakage
sns.boxplot(data=df, x='Leakage', ax=axes[1, 2], color='lightcoral')
axes[1, 2].set_title('Boxplot: Leakage')

plt.tight_layout()
plt.show()

print("""
Observaciones a partir de los gráficos:

- La variable 'Evaporation' presenta una distribución sesgada a la derecha con␣
 ↪varios outliers visibles, lo que indica que hay días con una evaporación␣
 ↪anormalmente alta.
- 'Electricity' muestra un patrón de distribución más disperso y algunos␣
 ↪valores elevados por encima de 12, que pueden representar situaciones␣
 ↪inusuales de consumo energético.
- El boxplot de 'Parameter5_3pm' revela outliers en ambos extremos, aunque el␣
 ↪grueso de los datos se concentra en un rango estable.
- La comparación entre 'Min_Temp' y 'Max_Temp' permite observar claramente la␣
 ↪diferencia entre temperaturas mínimas y máximas diarias.
- 'Parameter3_9am' y 'Parameter3_3pm' muestran una cantidad significativa de␣
 ↪outliers, lo cual podría indicar sensores sensibles o condiciones extremas␣
 ↪ocasionales.
- Se eliminó la variable 'Leakage' porque actúa como un predictor casi perfecto␣
 ↪del fallo de la máquina, generando una estimación con R² cercano a 1. Esto␣
 ↪indica que su inclusión contamina el modelo, ya que anticipa directamente la␣
 ↪variable objetivo, distorsionando la interpretación y la contribución de las␣
 ↪demás variables explicativas.""")

# Eliminar 'Leakage' después de graficar
df.drop(columns=['Leakage'], inplace=True)
dfcopy1.drop(columns=['Leakage'], inplace=True)
```

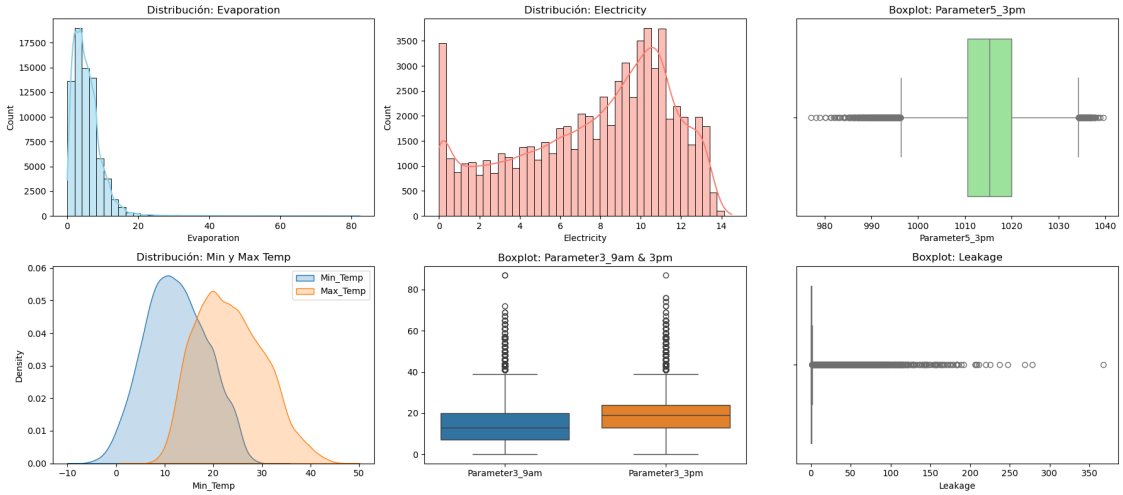

Observaciones a partir de los gráficos:

- La variable 'Evaporation' presenta una distribución sesgada a la derecha con varios outliers visibles, lo que indica que hay días con una evaporación anormalmente alta.
- 'Electricity' muestra un patrón de distribución más disperso y algunos valores elevados por encima de 12, que pueden representar situaciones inusuales de consumo energético.
- El boxplot de 'Parameter5_3pm' revela outliers en ambos extremos, aunque el grueso de los datos se concentra en un rango estable.
- La comparación entre 'Min_Temp' y 'Max_Temp' permite observar claramente la diferencia entre temperaturas mínimas y máximas diarias.
- 'Parameter3_9am' y 'Parameter3_3pm' muestran una cantidad significativa de outliers, lo cual podría indicar sensores sensibles o condiciones extremas ocasionales.
- Se eliminó la variable 'Leakage' porque actúa como un predictor casi perfecto del fallo de la máquina, generando una estimación con R^2 cercano a 1. Esto indica que su inclusión contamina el modelo, ya que anticipa directamente la variable objetivo, distorsionando la interpretación y la contribución de las demás variables explicativas.

2. Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que un dia se reporte fallo medido por sensor, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[10]:
```
# Crear el DataFrame modelo a partir del DataFrame limpio actual
df_model = df.copy()
# y: variable dependiente (lo que queremos predecir)
y = df_model['Failure_today']
```

```python
# X: todas las demás variables (excepto la variable objetivo)
X = df_model.drop(columns=['Failure_today'])

# Agregamos constante (intercepto) al modelo
X = sm.add_constant(X)

# Eliminamos filas con posibles NaN (por seguridad)
Xy = pd.concat([y, X], axis=1).dropna()
y_clean = Xy['Failure_today']
X_clean = Xy.drop(columns=['Failure_today'])

# Ejecutamos el modelo
modelo = sm.OLS(y_clean, X_clean).fit()

# Mostramos el resumen
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:          Failure_today   R-squared:                       0.280
Model:                            OLS   Adj. R-squared:                  0.279
Method:                 Least Squares   F-statistic:                     518.1
Date:                Thu, 24 Apr 2025   Prob (F-statistic):               0.00
Time:                        23:02:41   Log-Likelihood:                -24513.
No. Observations:               65434   AIC:                         4.913e+04
Df Residuals:                   65384   BIC:                         4.958e+04
Df Model:                          49
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
const          5.9395      0.287     20.723      0.000       5.378
6.501
Min_Temp       0.0166      0.001     28.202      0.000       0.015
0.018
Max_Temp      -0.0145      0.001    -24.980      0.000      -0.016
-0.013
Evaporation   -0.0133      0.001    -22.385      0.000      -0.014
-0.012
Electricity   -0.0049      0.001     -9.030      0.000      -0.006
-0.004
Parameter1_Speed   0.0058      0.000     32.462      0.000       0.005
0.006
Parameter3_9am   0.0034      0.000     14.595      0.000       0.003
0.004
```

Parameter3_3pm	-0.0035	0.000	-14.016	0.000	-0.004	-0.003
Parameter4_9am	0.0069	0.000	55.631	0.000	0.007	0.007
Parameter4_3pm	0.0005	0.000	3.883	0.000	0.000	0.001
Parameter5_3pm	-0.0061	0.000	-22.049	0.000	-0.007	-0.006
Parameter1_Dir_region_N	-0.0119	0.005	-2.235	0.025	-0.022	-0.001
Parameter1_Dir_region_S	0.0130	0.005	2.662	0.008	0.003	0.023
Parameter1_Dir_region_W	0.0267	0.005	5.031	0.000	0.016	0.037
Parameter2_9am_region_N	-0.0091	0.004	-2.025	0.043	-0.018	-0.000
Parameter2_9am_region_S	0.0199	0.005	4.268	0.000	0.011	0.029
Parameter2_9am_region_W	0.0609	0.005	12.090	0.000	0.051	0.071
Parameter2_3pm_region_N	0.0021	0.005	0.399	0.690	-0.008	0.012
Parameter2_3pm_region_S	0.0466	0.005	9.743	0.000	0.037	0.056
Parameter2_3pm_region_W	0.0520	0.005	9.818	0.000	0.042	0.062
Location_3	-6.346e-17	1.63e-17	-3.886	0.000	-9.55e-17	-3.15e-17
Location_4	0.1112	0.013	8.578	0.000	0.086	0.137
Location_5	-3.506e-17	1.84e-17	-1.908	0.056	-7.11e-17	9.62e-19
Location_6	2.526e-16	1.41e-17	17.888	0.000	2.25e-16	2.8e-16
Location_7	-7.341e-17	9.62e-18	-7.630	0.000	-9.23e-17	-5.46e-17
Location_8	-0.0092	0.013	-0.725	0.468	-0.034	0.016
Location_9	-0.0567	0.014	-4.148	0.000	-0.083	-0.030
Location_10	-0.0849	0.014	-5.861	0.000	-0.113	-0.056
Location_11	-0.0359	0.018	-1.954	0.051	-0.072	0.000
Location_12	-0.0442	0.014	-3.062	0.002	-0.073	-0.016
Location_13	-0.1222	0.013	-9.307	0.000	-0.148	-0.096

Location_14	-0.0959	0.013	-7.250	0.000	-0.122 -0.070
Location_15	1.988e-17	5.41e-18	3.671	0.000	9.27e-18 3.05e-17
Location_16	-0.1402	0.013	-11.189	0.000	-0.165 -0.116
Location_17	5.787e-17	4.37e-18	13.241	0.000	4.93e-17 6.64e-17
Location_18	2.683e-17	6.11e-18	4.395	0.000	1.49e-17 3.88e-17
Location_19	-0.1175	0.013	-9.053	0.000	-0.143 -0.092
Location_20	-0.1588	0.013	-12.558	0.000	-0.184 -0.134
Location_21	-0.0844	0.013	-6.748	0.000	-0.109 -0.060
Location_22	-0.0329	0.013	-2.484	0.013	-0.059 -0.007
Location_23	-0.0927	0.013	-7.186	0.000	-0.118 -0.067
Location_26	-7.41e-17	3.78e-18	-19.601	0.000	-8.15e-17 -6.67e-17
Location_27	1.53e-17	3.6e-18	4.247	0.000	8.24e-18 2.24e-17
Location_28	-0.1593	0.013	-12.247	0.000	-0.185 -0.134
Location_29	-0.0769	0.013	-6.150	0.000	-0.101 -0.052
Location_30	1.549e-17	3.36e-18	4.613	0.000	8.91e-18 2.21e-17
Location_32	-0.0156	0.012	-1.283	0.200	-0.039 0.008
Location_33	-0.0324	0.012	-2.607	0.009	-0.057 -0.008
Location_34	-0.1001	0.013	-7.749	0.000	-0.125 -0.075
Location_35	5.317e-19	6.34e-20	8.391	0.000	4.08e-19 6.56e-19
Location_36	-0.1817	0.014	-13.134	0.000	-0.209 -0.155
Location_38	-0.1155	0.013	-8.813	0.000	-0.141 -0.090
Location_39	-0.1011	0.013	-8.004	0.000	-0.126 -0.076
Location_40	-0.0935	0.014	-6.918	0.000	-0.120 -0.067
Location_41	0	0	nan	nan	0 0

```
Location_42                    0          0        nan        nan           0
0
Location_43              -0.0593      0.013     -4.674      0.000      -0.084
-0.034
Location_44                    0          0        nan        nan           0
0
Location_45              -0.1300      0.012    -10.470      0.000      -0.154
-0.106
Location_46              -0.0701      0.015     -4.763      0.000      -0.099
-0.041
Location_47                    0          0        nan        nan           0
0
Location_48                    0          0        nan        nan           0
0
Location_49              -0.0605      0.013     -4.514      0.000      -0.087
-0.034
Season_Spring             0.0555      0.004     13.589      0.000       0.048
0.064
Season_Summer             0.0436      0.005      9.606      0.000       0.035
0.052
Season_Winter            -0.0164      0.005     -3.591      0.000      -0.025
-0.007
==============================================================================
Omnibus:                     5445.436   Durbin-Watson:                   1.804
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             6873.761
Skew:                           0.789   Prob(JB):                         0.00
Kurtosis:                       2.827   Cond. No.                     1.03e+19
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
[2] The smallest eigenvalue is 6.4e-28. This might indicate that there are
strong multicollinearity problems or that the design matrix is singular.
```

3. Ejecute un modelo *probit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[11]:
```python
# Crear el DataFrame modelo a partir del DataFrame limpio actual y eliminar␣
 ↪columnas conflictivas
df_model2 = df.drop(columns=['Electricity', 'Evaporation'])

# y: variable dependiente (lo que queremos predecir)
y = df_model2['Failure_today']

# X: todas las demás variables (excepto la variable objetivo)
X = df_model2.drop(columns=['Failure_today'])
```

```python
# Agregar constante (intercepto) al modelo
X = sm.add_constant(X)

# Unir y eliminar posibles filas con NaN por seguridad
Xy = pd.concat([y, X], axis=1).dropna()
y_clean2 = Xy['Failure_today']
X_clean2 = Xy.drop(columns=['Failure_today'])

# Ejecutar modelo Probit
modelo_probit = sm.Probit(y_clean2, X_clean2)
probit_result = modelo_probit.fit(cov_type="HC0")

# Mostrar resumen del modelo
print(probit_result.summary())

# Mostrar efectos marginales
mfx_probit = probit_result.get_margeff()
print(mfx_probit.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.356680
         Iterations 7
                          Probit Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:               119590
Model:                         Probit   Df Residuals:                   119526
Method:                           MLE   Df Model:                           63
Date:                Thu, 24 Apr 2025   Pseudo R-squ.:                  0.3248
Time:                        23:02:42   Log-Likelihood:                -42655.
converged:                       True   LL-Null:                       -63172.
Covariance Type:                  HC0   LLR p-value:                     0.000
==============================================================================
===========
                               coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
-----------
const                       21.3376      0.953     22.381      0.000      19.469
23.206
Min_Temp                     0.1097      0.002     53.764      0.000       0.106
0.114
Max_Temp                    -0.1299      0.002    -55.838      0.000      -0.134
-0.125
Parameter1_Speed             0.0211      0.001     35.320      0.000       0.020
0.022
Parameter3_9am               0.0119      0.001     14.330      0.000       0.010
0.014
Parameter3_3pm              -0.0135      0.001    -15.865      0.000      -0.015
```

```
-0.012
Parameter4_9am              0.0419      0.001     82.859      0.000       0.041
0.043
Parameter4_3pm             -0.0027      0.000     -5.963      0.000      -0.004
-0.002
Parameter5_3pm             -0.0239      0.001    -26.095      0.000      -0.026
-0.022
Parameter1_Dir_region_N    -0.0444      0.020     -2.264      0.024      -0.083
-0.006
Parameter1_Dir_region_S     0.0307      0.018      1.735      0.083      -0.004
0.065
Parameter1_Dir_region_W     0.0887      0.019      4.554      0.000       0.051
0.127
Parameter2_9am_region_N    -0.0085      0.017     -0.494      0.621      -0.042
0.025
Parameter2_9am_region_S     0.1290      0.017      7.565      0.000       0.096
0.162
Parameter2_9am_region_W     0.2710      0.018     15.124      0.000       0.236
0.306
Parameter2_3pm_region_N    -0.0139      0.019     -0.721      0.471      -0.052
0.024
Parameter2_3pm_region_S     0.1310      0.017      7.552      0.000       0.097
0.165
Parameter2_3pm_region_W     0.1588      0.020      8.007      0.000       0.120
0.198
Location_3                 -0.1956      0.046     -4.253      0.000      -0.286
-0.105
Location_4                  0.2484      0.061      4.044      0.000       0.128
0.369
Location_5                 -0.2381      0.046     -5.210      0.000      -0.328
-0.149
Location_6                 -0.9238      0.047    -19.488      0.000      -1.017
-0.831
Location_7                 -0.3808      0.046     -8.267      0.000      -0.471
-0.291
Location_8                  0.3170      0.044      7.258      0.000       0.231
0.403
Location_9                  0.0628      0.045      1.400      0.162      -0.025
0.151
Location_10                -0.1535      0.046     -3.351      0.001      -0.243
-0.064
Location_11                -0.1270      0.053     -2.416      0.016      -0.230
-0.024
Location_12                 0.0671      0.045      1.492      0.136      -0.021
0.155
Location_13                -0.5069      0.044    -11.522      0.000      -0.593
-0.421
Location_14                -0.0776      0.047     -1.668      0.095      -0.169
```

0.014
Location_15 -0.0631 0.045 -1.399 0.162 -0.151
0.025
Location_16 -0.3587 0.045 -8.054 0.000 -0.446
-0.271
Location_17 0.0277 0.079 0.350 0.726 -0.127
0.183
Location_18 -0.3442 0.049 -6.981 0.000 -0.441
-0.248
Location_19 -0.2927 0.047 -6.281 0.000 -0.384
-0.201
Location_20 -0.5514 0.045 -12.193 0.000 -0.640
-0.463
Location_21 -0.5649 0.051 -11.114 0.000 -0.664
-0.465
Location_22 -0.0144 0.051 -0.282 0.778 -0.114
0.086
Location_23 -0.3140 0.044 -7.204 0.000 -0.399
-0.229
Location_26 -0.7974 0.058 -13.641 0.000 -0.912
-0.683
Location_27 -0.5230 0.044 -11.838 0.000 -0.610
-0.436
Location_28 -0.5060 0.043 -11.833 0.000 -0.590
-0.422
Location_29 -0.4938 0.049 -10.054 0.000 -0.590
-0.398
Location_30 0.1161 0.049 2.364 0.018 0.020
0.212
Location_32 0.0874 0.043 2.025 0.043 0.003
0.172
Location_33 0.0961 0.046 2.108 0.035 0.007
0.185
Location_34 -0.4255 0.043 -9.915 0.000 -0.510
-0.341
Location_35 -0.2180 0.045 -4.820 0.000 -0.307
-0.129
Location_36 -0.6216 0.046 -13.486 0.000 -0.712
-0.531
Location_38 -0.2526 0.046 -5.522 0.000 -0.342
-0.163
Location_39 -0.2139 0.045 -4.707 0.000 -0.303
-0.125
Location_40 -0.1297 0.047 -2.764 0.006 -0.222
-0.038
Location_41 -0.0849 0.045 -1.871 0.061 -0.174
0.004
Location_42 0.2088 0.077 2.698 0.007 0.057

```
0.361
Location_43                -0.1769      0.049     -3.632      0.000      -0.272
-0.081
Location_44                -0.2959      0.043     -6.860      0.000      -0.380
-0.211
Location_45                -0.5283      0.044    -12.006      0.000      -0.615
-0.442
Location_46                -0.0289      0.047     -0.611      0.541      -0.121
0.064
Location_47                -0.0459      0.045     -1.028      0.304      -0.134
0.042
Location_48                -0.6068      0.045    -13.571      0.000      -0.694
-0.519
Location_49                -0.7232      0.060    -12.119      0.000      -0.840
-0.606
Season_Spring               0.2007      0.015     13.817      0.000       0.172
0.229
Season_Summer               0.1530      0.016      9.545      0.000       0.122
0.184
Season_Winter              -0.1242      0.016     -7.897      0.000      -0.155
-0.093
================================================================================
===========
       Probit Marginal Effects
=====================================
Dep. Variable:          Failure_today
Method:                          dydx
At:                           overall
================================================================================
===========
                              dy/dx    std err          z      P>|z|      [0.025
0.975]
--------------------------------------------------------------------------------
-----------
Min_Temp                    0.0220      0.000     55.585      0.000       0.021
0.023
Max_Temp                   -0.0260      0.000    -59.057      0.000      -0.027
-0.025
Parameter1_Speed            0.0042      0.000     36.045      0.000       0.004
0.004
Parameter3_9am              0.0024      0.000     14.378      0.000       0.002
0.003
Parameter3_3pm             -0.0027      0.000    -15.925      0.000      -0.003
-0.002
Parameter4_9am              0.0084   8.78e-05     95.524      0.000       0.008
0.009
Parameter4_3pm             -0.0005   9.14e-05     -5.971      0.000      -0.001
-0.000
```

Parameter5_3pm	-0.0048	0.000	-26.346	0.000	-0.005 -0.004
Parameter1_Dir_region_N	-0.0089	0.004	-2.265	0.024	-0.017 -0.001
Parameter1_Dir_region_S	0.0062	0.004	1.735	0.083	-0.001 0.013
Parameter1_Dir_region_W	0.0178	0.004	4.552	0.000	0.010 0.025
Parameter2_9am_region_N	-0.0017	0.003	-0.494	0.621	-0.008 0.005
Parameter2_9am_region_S	0.0258	0.003	7.568	0.000	0.019 0.033
Parameter2_9am_region_W	0.0543	0.004	15.162	0.000	0.047 0.061
Parameter2_3pm_region_N	-0.0028	0.004	-0.721	0.471	-0.010 0.005
Parameter2_3pm_region_S	0.0262	0.003	7.558	0.000	0.019 0.033
Parameter2_3pm_region_W	0.0318	0.004	8.012	0.000	0.024 0.040
Location_3	-0.0392	0.009	-4.257	0.000	-0.057 -0.021
Location_4	0.0497	0.012	4.044	0.000	0.026 0.074
Location_5	-0.0477	0.009	-5.213	0.000	-0.066 -0.030
Location_6	-0.1849	0.009	-19.697	0.000	-0.203 -0.167
Location_7	-0.0762	0.009	-8.284	0.000	-0.094 -0.058
Location_8	0.0635	0.009	7.265	0.000	0.046 0.081
Location_9	0.0126	0.009	1.400	0.162	-0.005 0.030
Location_10	-0.0307	0.009	-3.353	0.001	-0.049 -0.013
Location_11	-0.0254	0.011	-2.418	0.016	-0.046 -0.005
Location_12	0.0134	0.009	1.492	0.136	-0.004 0.031
Location_13	-0.1015	0.009	-11.561	0.000	-0.119 -0.084
Location_14	-0.0155	0.009	-1.668	0.095	-0.034 0.003
Location_15	-0.0126	0.009	-1.399	0.162	-0.030 0.005
Location_16	-0.0718	0.009	-8.074	0.000	-0.089 -0.054

Location_17	0.0055	0.016	0.350	0.726	-0.025 0.037
Location_18	-0.0689	0.010	-6.991	0.000	-0.088 -0.050
Location_19	-0.0586	0.009	-6.289	0.000	-0.077 -0.040
Location_20	-0.1104	0.009	-12.239	0.000	-0.128 -0.093
Location_21	-0.1131	0.010	-11.147	0.000	-0.133 -0.093
Location_22	-0.0029	0.010	-0.282	0.778	-0.023 0.017
Location_23	-0.0629	0.009	-7.216	0.000	-0.080 -0.046
Location_26	-0.1596	0.012	-13.697	0.000	-0.182 -0.137
Location_27	-0.1047	0.009	-11.869	0.000	-0.122 -0.087
Location_28	-0.1013	0.009	-11.864	0.000	-0.118 -0.085
Location_29	-0.0989	0.010	-10.091	0.000	-0.118 -0.080
Location_30	0.0232	0.010	2.364	0.018	0.004 0.042
Location_32	0.0175	0.009	2.025	0.043	0.001 0.034
Location_33	0.0192	0.009	2.109	0.035	0.001 0.037
Location_34	-0.0852	0.009	-9.941	0.000	-0.102 -0.068
Location_35	-0.0436	0.009	-4.823	0.000	-0.061 -0.026
Location_36	-0.1244	0.009	-13.555	0.000	-0.142 -0.106
Location_38	-0.0506	0.009	-5.526	0.000	-0.069 -0.033
Location_39	-0.0428	0.009	-4.709	0.000	-0.061 -0.025
Location_40	-0.0260	0.009	-2.763	0.006	-0.044 -0.008
Location_41	-0.0170	0.009	-1.872	0.061	-0.035 0.001
Location_42	0.0418	0.015	2.698	0.007	0.011 0.072
Location_43	-0.0354	0.010	-3.635	0.000	-0.054 -0.016
Location_44	-0.0592	0.009	-6.868	0.000	-0.076 -0.042

```
Location_45                -0.1058      0.009    -12.054      0.000      -0.123
-0.089
Location_46                -0.0058      0.009     -0.611      0.541      -0.024
0.013
Location_47                -0.0092      0.009     -1.028      0.304      -0.027
0.008
Location_48                -0.1215      0.009    -13.616      0.000      -0.139
-0.104
Location_49                -0.1448      0.012    -12.178      0.000      -0.168
-0.121
Season_Spring               0.0402      0.003     13.811      0.000       0.034
0.046
Season_Summer               0.0306      0.003      9.548      0.000       0.024
0.037
Season_Winter              -0.0249      0.003     -7.912      0.000      -0.031
-0.019
==============================================================================
==========
```

4. Ejecute un modelo *logit* para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[12]:
```python
# Crear el DataFrame modelo a partir del DataFrame limpio actual
df_model3 = df.drop(columns=['Electricity', 'Evaporation'])

# y: variable dependiente (lo que queremos predecir)
y = df_model3['Failure_today']

# X: todas las demás variables (excepto la variable objetivo)
X = df_model3.drop(columns=['Failure_today'])

# Agregar constante (intercepto) al modelo
X = sm.add_constant(X)

# Unir y eliminar posibles filas con NaN por seguridad
Xy = pd.concat([y, X], axis=1).dropna()
y_clean3 = Xy['Failure_today']
X_clean3 = Xy.drop(columns=['Failure_today'])

# Ejecutar modelo Logit
modelo_logit = sm.Logit(y_clean3, X_clean3)
logit_result = modelo_logit.fit(cov_type="HC0")

# Mostrar resumen del modelo
print(logit_result.summary())

# Mostrar efectos marginales
mfx_logit = logit_result.get_margeff()
```

```
print(mfx_logit.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.355396
         Iterations 8
                          Logit Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:               119590
Model:                          Logit   Df Residuals:                   119526
Method:                           MLE   Df Model:                           63
Date:                Thu, 24 Apr 2025   Pseudo R-squ.:                  0.3272
Time:                        23:02:48   Log-Likelihood:                -42502.
converged:                       True   LL-Null:                       -63172.
Covariance Type:                 HC0   LLR p-value:                     0.000
==============================================================================
===========
                               coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
-----------
const                       36.7051      1.675     21.911      0.000      33.422
39.988
Min_Temp                     0.1967      0.004     54.530      0.000       0.190
0.204
Max_Temp                    -0.2396      0.004    -58.012      0.000      -0.248
-0.232
Parameter1_Speed             0.0371      0.001     35.068      0.000       0.035
0.039
Parameter3_9am               0.0203      0.001     13.766      0.000       0.017
0.023
Parameter3_3pm              -0.0227      0.002    -15.034      0.000      -0.026
-0.020
Parameter4_9am               0.0761      0.001     85.370      0.000       0.074
0.078
Parameter4_3pm              -0.0058      0.001     -7.230      0.000      -0.007
-0.004
Parameter5_3pm              -0.0412      0.002    -25.533      0.000      -0.044
-0.038
Parameter1_Dir_region_N     -0.0955      0.035     -2.752      0.006      -0.163
-0.027
Parameter1_Dir_region_S      0.0347      0.031      1.107      0.268      -0.027
0.096
Parameter1_Dir_region_W      0.1410      0.034      4.091      0.000       0.073
0.209
Parameter2_9am_region_N     -0.0212      0.030     -0.699      0.484      -0.081
0.038
Parameter2_9am_region_S      0.2253      0.030      7.420      0.000       0.166
0.285
```

Parameter2_9am_region_W	0.4770	0.032	15.055	0.000	0.415
0.539					
Parameter2_3pm_region_N	-0.0327	0.034	-0.958	0.338	-0.100
0.034					
Parameter2_3pm_region_S	0.2192	0.031	7.136	0.000	0.159
0.279					
Parameter2_3pm_region_W	0.2618	0.035	7.469	0.000	0.193
0.331					
Location_3	-0.4099	0.081	-5.040	0.000	-0.569
-0.251					
Location_4	0.3676	0.109	3.362	0.001	0.153
0.582					
Location_5	-0.4069	0.082	-4.973	0.000	-0.567
-0.247					
Location_6	-1.7276	0.083	-20.781	0.000	-1.891
-1.565					
Location_7	-0.7195	0.081	-8.829	0.000	-0.879
-0.560					
Location_8	0.6299	0.078	8.102	0.000	0.478
0.782					
Location_9	0.2190	0.079	2.761	0.006	0.064
0.374					
Location_10	-0.3012	0.082	-3.669	0.000	-0.462
-0.140					
Location_11	-0.3160	0.095	-3.323	0.001	-0.502
-0.130					
Location_12	0.1613	0.080	2.020	0.043	0.005
0.318					
Location_13	-0.9266	0.077	-11.967	0.000	-1.078
-0.775					
Location_14	-0.0201	0.083	-0.242	0.809	-0.183
0.143					
Location_15	-0.0402	0.080	-0.500	0.617	-0.198
0.117					
Location_16	-0.6818	0.080	-8.541	0.000	-0.838
-0.525					
Location_17	0.1855	0.142	1.311	0.190	-0.092
0.463					
Location_18	-0.6223	0.087	-7.157	0.000	-0.793
-0.452					
Location_19	-0.5307	0.083	-6.398	0.000	-0.693
-0.368					
Location_20	-1.0022	0.081	-12.424	0.000	-1.160
-0.844					
Location_21	-1.0492	0.090	-11.604	0.000	-1.226
-0.872					
Location_22	-0.0334	0.094	-0.357	0.721	-0.217
0.150					

Location_23	-0.5814	0.077	-7.545	0.000	-0.732 -0.430
Location_26	-1.4462	0.104	-13.904	0.000	-1.650 -1.242
Location_27	-0.9191	0.079	-11.659	0.000	-1.074 -0.765
Location_28	-0.8777	0.076	-11.567	0.000	-1.026 -0.729
Location_29	-0.9575	0.087	-11.000	0.000	-1.128 -0.787
Location_30	0.2137	0.087	2.450	0.014	0.043 0.385
Location_32	0.1934	0.076	2.533	0.011	0.044 0.343
Location_33	0.1964	0.081	2.421	0.015	0.037 0.355
Location_34	-0.7737	0.076	-10.174	0.000	-0.923 -0.625
Location_35	-0.3658	0.081	-4.533	0.000	-0.524 -0.208
Location_36	-1.1410	0.082	-13.917	0.000	-1.302 -0.980
Location_38	-0.4240	0.081	-5.224	0.000	-0.583 -0.265
Location_39	-0.3786	0.082	-4.593	0.000	-0.540 -0.217
Location_40	-0.1056	0.084	-1.264	0.206	-0.269 0.058
Location_41	-0.1758	0.081	-2.171	0.030	-0.335 -0.017
Location_42	0.3162	0.140	2.255	0.024	0.041 0.591
Location_43	-0.3984	0.088	-4.544	0.000	-0.570 -0.227
Location_44	-0.5270	0.077	-6.877	0.000	-0.677 -0.377
Location_45	-0.9763	0.078	-12.542	0.000	-1.129 -0.824
Location_46	-0.0443	0.084	-0.526	0.599	-0.209 0.121
Location_47	-0.0836	0.079	-1.064	0.287	-0.238 0.070
Location_48	-1.0698	0.080	-13.343	0.000	-1.227 -0.913
Location_49	-1.3775	0.105	-13.157	0.000	-1.583 -1.172
Season_Spring	0.3208	0.026	12.350	0.000	0.270 0.372

```
Season_Summer                0.2541      0.029      8.911      0.000       0.198
0.310
Season_Winter               -0.2418      0.028     -8.782      0.000      -0.296
-0.188
==============================================================================
==========
        Logit Marginal Effects
=====================================
Dep. Variable:          Failure_today
Method:                          dydx
At:                           overall
==============================================================================
==========
                              dy/dx    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
----------
Min_Temp                     0.0221      0.000     56.500      0.000       0.021
0.023
Max_Temp                    -0.0269      0.000    -61.152      0.000      -0.028
-0.026
Parameter1_Speed             0.0042      0.000     35.960      0.000       0.004
0.004
Parameter3_9am               0.0023      0.000     13.811      0.000       0.002
0.003
Parameter3_3pm              -0.0026      0.000    -15.096      0.000      -0.003
-0.002
Parameter4_9am               0.0086    8.6e-05     99.523      0.000       0.008
0.009
Parameter4_3pm              -0.0007   9.01e-05     -7.238      0.000      -0.001
-0.000
Parameter5_3pm              -0.0046      0.000    -25.779      0.000      -0.005
-0.004
Parameter1_Dir_region_N     -0.0107      0.004     -2.753      0.006      -0.018
-0.003
Parameter1_Dir_region_S      0.0039      0.004      1.107      0.268      -0.003
0.011
Parameter1_Dir_region_W      0.0158      0.004      4.090      0.000       0.008
0.023
Parameter2_9am_region_N     -0.0024      0.003     -0.700      0.484      -0.009
0.004
Parameter2_9am_region_S      0.0253      0.003      7.420      0.000       0.019
0.032
Parameter2_9am_region_W      0.0536      0.004     15.093      0.000       0.047
0.061
Parameter2_3pm_region_N     -0.0037      0.004     -0.958      0.338      -0.011
0.004
Parameter2_3pm_region_S      0.0246      0.003      7.142      0.000       0.018
```

```
0.031
Parameter2_3pm_region_W     0.0294      0.004      7.475      0.000       0.022
0.037
Location_3                 -0.0461      0.009     -5.046      0.000      -0.064
-0.028
Location_4                  0.0413      0.012      3.362      0.001       0.017
0.065
Location_5                 -0.0457      0.009     -4.977      0.000      -0.064
-0.028
Location_6                 -0.1941      0.009    -21.013      0.000      -0.212
-0.176
Location_7                 -0.0809      0.009     -8.849      0.000      -0.099
-0.063
Location_8                  0.0708      0.009      8.109      0.000       0.054
0.088
Location_9                  0.0246      0.009      2.762      0.006       0.007
0.042
Location_10                -0.0338      0.009     -3.672      0.000      -0.052
-0.016
Location_11                -0.0355      0.011     -3.325      0.001      -0.056
-0.015
Location_12                 0.0181      0.009      2.020      0.043       0.001
0.036
Location_13                -0.1041      0.009    -12.008      0.000      -0.121
-0.087
Location_14                -0.0023      0.009     -0.242      0.809      -0.021
0.016
Location_15                -0.0045      0.009     -0.500      0.617      -0.022
0.013
Location_16                -0.0766      0.009     -8.568      0.000      -0.094
-0.059
Location_17                 0.0208      0.016      1.311      0.190      -0.010
0.052
Location_18                -0.0699      0.010     -7.168      0.000      -0.089
-0.051
Location_19                -0.0596      0.009     -6.408      0.000      -0.078
-0.041
Location_20                -0.1126      0.009    -12.476      0.000      -0.130
-0.095
Location_21                -0.1179      0.010    -11.641      0.000      -0.138
-0.098
Location_22                -0.0038      0.011     -0.357      0.721      -0.024
0.017
Location_23                -0.0653      0.009     -7.557      0.000      -0.082
-0.048
Location_26                -0.1625      0.012    -13.963      0.000      -0.185
-0.140
Location_27                -0.1033      0.009    -11.695      0.000      -0.121
```

```
-0.086
Location_28                -0.0986      0.009    -11.602      0.000      -0.115
-0.082
Location_29                -0.1076      0.010    -11.036      0.000      -0.127
-0.088
Location_30                 0.0240      0.010      2.450      0.014       0.005
0.043
Location_32                 0.0217      0.009      2.533      0.011       0.005
0.039
Location_33                 0.0221      0.009      2.422      0.015       0.004
0.040
Location_34                -0.0869      0.009    -10.200      0.000      -0.104
-0.070
Location_35                -0.0411      0.009     -4.536      0.000      -0.059
-0.023
Location_36                -0.1282      0.009    -13.996      0.000      -0.146
-0.110
Location_38                -0.0476      0.009     -5.229      0.000      -0.066
-0.030
Location_39                -0.0425      0.009     -4.596      0.000      -0.061
-0.024
Location_40                -0.0119      0.009     -1.264      0.206      -0.030
0.007
Location_41                -0.0198      0.009     -2.171      0.030      -0.038
-0.002
Location_42                 0.0355      0.016      2.255      0.024       0.005
0.066
Location_43                -0.0448      0.010     -4.549      0.000      -0.064
-0.025
Location_44                -0.0592      0.009     -6.887      0.000      -0.076
-0.042
Location_45                -0.1097      0.009    -12.599      0.000      -0.127
-0.093
Location_46                -0.0050      0.009     -0.526      0.599      -0.024
0.014
Location_47                -0.0094      0.009     -1.064      0.287      -0.027
0.008
Location_48                -0.1202      0.009    -13.397      0.000      -0.138
-0.103
Location_49                -0.1548      0.012    -13.208      0.000      -0.178
-0.132
Season_Spring               0.0360      0.003     12.346      0.000       0.030
0.042
Season_Summer               0.0286      0.003      8.907      0.000       0.022
0.035
Season_Winter              -0.0272      0.003     -8.794      0.000      -0.033
-0.021
==============================================================================
```

==========

6. Agregue la data a nivel mensual, usando la data promedio de las variables (ignorando aquellas categoricas, como la direccion del viento). En particular, genere una variable que cuente la cantidad de fallos observados en un mes, utilice un valor de 0 si en ese mes no se reporto fallos en ningun dia. Use un modelo Poisson para explicar el numero de fallas por mes. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[13]:
```
# Paso 1: Asegurar formato de fecha y extraer año y mes
dfcopy1['Year'] = dfcopy1['Date'].dt.year
dfcopy1['Month'] = dfcopy1['Date'].dt.month

# Paso 2: Reconstruir variable Location desde las dummies
location_cols = [col for col in dfcopy1.columns if col.startswith('Location_')]

if location_cols:
    dfcopy1['Location'] = dfcopy1[location_cols].idxmax(axis=1).str.
 ↪replace('Location_', '').astype(int)
    dfcopy1.drop(columns=location_cols, inplace=True)

# Paso 3: Eliminar columnas de dirección y otras no deseadas
cols_a_eliminar = [
    'Parameter1_Dir_region_W',
    'Parameter2_9am_region_N', 'Parameter2_9am_region_S',␣
 ↪'Parameter2_9am_region_W',
    'Parameter2_3pm_region_N', 'Parameter2_3pm_region_S',␣
 ↪'Parameter2_3pm_region_W',
    'Evaporation', 'Electricity',
    'Parameter1_Dir_region_N', 'Parameter1_Dir_region_S'
]
dfcopy1.drop(columns=[col for col in cols_a_eliminar if col in dfcopy1.
 ↪columns], inplace=True)

# Paso 4: Agrupar por Year, Month y Location
cols_promedio = ['Min_Temp', 'Max_Temp', 'Parameter1_Speed', 'Parameter3_9am',
                 'Parameter3_3pm', 'Parameter4_9am', 'Parameter4_3pm',␣
 ↪'Parameter5_3pm']

df_mensual = dfcopy1.groupby(['Year', 'Month', 'Location']).agg({
    **{col: 'mean' for col in cols_promedio},
    'Failure_today': 'sum'
}).reset_index()

# Paso 5: Crear columna 'Mes' en formato 'YYYY-MM'
df_mensual['Mes'] = df_mensual['Year'].astype(str) + '-' + df_mensual['Month'].
 ↪astype(str).str.zfill(2)
```

```python
# Paso 6: Ajustar modelo Poisson con fórmula (C(Location) como variable␣
 ↪categórica)
poisson_model = smf.poisson(
    formula="Failure_today ~ C(Location) + Min_Temp + Max_Temp +␣
 ↪Parameter1_Speed + Parameter3_9am + Parameter3_3pm + Parameter4_9am +␣
 ↪Parameter4_3pm + Parameter5_3pm",
    data=df_mensual
).fit()

# Paso 7: Mostrar resumen
print(poisson_model.summary())
```

```
Optimization terminated successfully.
         Current function value: 2.243287
         Iterations 8
                          Poisson Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:                 4037
Model:                        Poisson   Df Residuals:                     3986
Method:                           MLE   Df Model:                           50
Date:                Thu, 24 Apr 2025   Pseudo R-squ.:                  0.3332
Time:                        23:02:53   Log-Likelihood:                -9056.2
converged:                       True   LL-Null:                       -13582.
Covariance Type:            nonrobust   LLR p-value:                     0.000
==============================================================================
=====
                         coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
-----
Intercept             23.9085      2.867      8.340      0.000      18.290
29.527
C(Location)[T.4]     -0.6129      0.075     -8.225      0.000      -0.759
-0.467
C(Location)[T.5]     -0.8916      0.055    -16.195      0.000      -0.999
-0.784
C(Location)[T.6]     -1.0855      0.061    -17.810      0.000      -1.205
-0.966
C(Location)[T.7]     -0.8222      0.054    -15.287      0.000      -0.928
-0.717
C(Location)[T.8]     -0.7212      0.053    -13.507      0.000      -0.826
-0.617
C(Location)[T.9]     -0.7526      0.056    -13.477      0.000      -0.862
-0.643
C(Location)[T.10]    -0.7323      0.057    -12.929      0.000      -0.843
-0.621
C(Location)[T.11]    -0.7356      0.063    -11.685      0.000      -0.859
```

```
-0.612
C(Location)[T.12]    -0.6866      0.055    -12.569      0.000      -0.794
-0.580
C(Location)[T.13]    -0.9660      0.051    -18.779      0.000      -1.067
-0.865
C(Location)[T.14]    -1.0670      0.055    -19.263      0.000      -1.176
-0.958
C(Location)[T.15]    -0.7973      0.063    -12.690      0.000      -0.920
-0.674
C(Location)[T.16]    -1.3110      0.051    -25.622      0.000      -1.411
-1.211
C(Location)[T.17]    -1.3076      0.104    -12.626      0.000      -1.511
-1.105
C(Location)[T.18]    -1.0274      0.058    -17.606      0.000      -1.142
-0.913
C(Location)[T.19]    -1.0381      0.057    -18.255      0.000      -1.150
-0.927
C(Location)[T.20]    -0.9559      0.057    -16.714      0.000      -1.068
-0.844
C(Location)[T.21]    -0.8259      0.066    -12.530      0.000      -0.955
-0.697
C(Location)[T.22]    -0.7530      0.068    -11.135      0.000      -0.886
-0.620
C(Location)[T.23]    -0.7038      0.052    -13.588      0.000      -0.805
-0.602
C(Location)[T.26]    -0.9686      0.076    -12.725      0.000      -1.118
-0.819
C(Location)[T.27]    -1.3323      0.054    -24.862      0.000      -1.437
-1.227
C(Location)[T.28]    -1.2867      0.061    -21.155      0.000      -1.406
-1.168
C(Location)[T.29]    -0.8090      0.053    -15.324      0.000      -0.912
-0.705
C(Location)[T.30]    -0.7335      0.058    -12.599      0.000      -0.848
-0.619
C(Location)[T.32]    -0.5966      0.049    -12.104      0.000      -0.693
-0.500
C(Location)[T.33]    -0.5252      0.055     -9.541      0.000      -0.633
-0.417
C(Location)[T.34]    -0.9500      0.049    -19.474      0.000      -1.046
-0.854
C(Location)[T.35]    -0.8952      0.055    -16.327      0.000      -1.003
-0.788
C(Location)[T.36]    -0.9228      0.057    -16.312      0.000      -1.034
-0.812
C(Location)[T.38]    -0.9837      0.055    -17.908      0.000      -1.091
-0.876
C(Location)[T.39]    -0.8256      0.056    -14.636      0.000      -0.936
```

```
-0.715
C(Location)[T.40]    -1.0694      0.064    -16.660      0.000      -1.195
-0.944
C(Location)[T.41]    -0.7046      0.054    -13.070      0.000      -0.810
-0.599
C(Location)[T.42]    -0.7962      0.102     -7.797      0.000      -0.996
-0.596
C(Location)[T.43]    -0.6245      0.055    -11.453      0.000      -0.731
-0.518
C(Location)[T.44]    -1.1755      0.049    -24.099      0.000      -1.271
-1.080
C(Location)[T.45]    -1.0998      0.049    -22.663      0.000      -1.195
-1.005
C(Location)[T.46]    -0.7620      0.056    -13.548      0.000      -0.872
-0.652
C(Location)[T.47]    -0.7834      0.050    -15.758      0.000      -0.881
-0.686
C(Location)[T.48]    -1.5235      0.058    -26.428      0.000      -1.636
-1.411
C(Location)[T.49]    -1.1568      0.082    -14.104      0.000      -1.318
-0.996
Min_Temp              0.1026      0.008     13.039      0.000       0.087
0.118
Max_Temp             -0.1011      0.008    -12.959      0.000      -0.116
-0.086
Parameter1_Speed      0.0562      0.003     21.125      0.000       0.051
0.061
Parameter3_9am       -0.0096      0.004     -2.524      0.012      -0.017
-0.002
Parameter3_3pm       -0.0578      0.004    -16.211      0.000      -0.065
-0.051
Parameter4_9am        0.0166      0.002      9.896      0.000       0.013
0.020
Parameter4_3pm        0.0169      0.002      8.509      0.000       0.013
0.021
Parameter5_3pm       -0.0229      0.003     -8.305      0.000      -0.028
-0.017
==============================================================================
=====
```

7. Determine sobre dispersion en la data y posible valor optimo de alpha para un modelo Binomial Negativa.

[14]:
```
# Paso 1: Obtener el lambda estimado del modelo Poisson
df_mensual['plambda'] = poisson_model.predict(df_mensual)

# Paso 2: Graficar la distribución de los valores esperados ( )
plt.figure(figsize=(8, 5))
```

```
sns.histplot(data=df_mensual, x="plambda", bins=30, kde=True, color='skyblue')
plt.title("Distribución de  estimado por modelo Poisson")
plt.xlabel("  estimado (mu)")
plt.ylabel("Frecuencia")
plt.tight_layout()
plt.show()

# Paso 3: Calcular variable auxiliar para test de sobre-dispersión
aux = ((df_mensual['Failure_today'] - df_mensual['plambda'])**2 -␣
 ↪df_mensual['plambda']) / df_mensual['plambda']

# Paso 4: Regresión auxiliar (estima alpha implícitamente)
auxr = sm.OLS(aux, df_mensual['plambda']).fit()

# Paso 5: Resultado de la regresión auxiliar
print(auxr.summary())
```

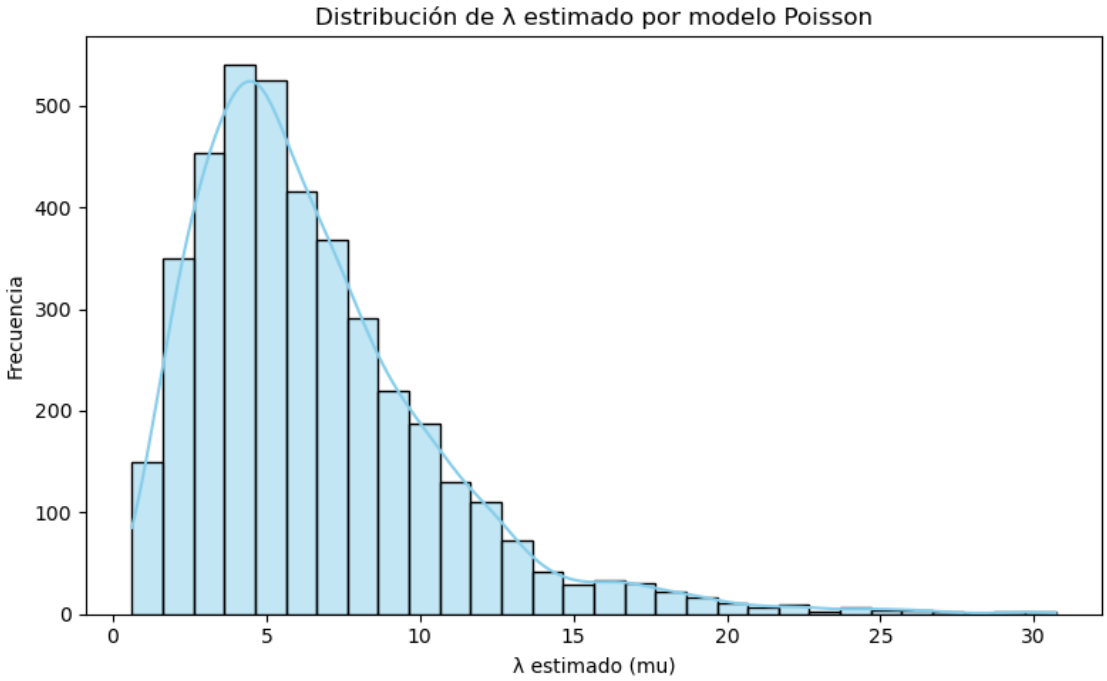


```
                            OLS Regression Results
==============================================================================
=======
Dep. Variable:                      y   R-squared (uncentered):
0.001
Model:                            OLS   Adj. R-squared (uncentered):
0.000
Method:                 Least Squares   F-statistic:
```

```
2.598
Date:                Thu, 24 Apr 2025   Prob (F-statistic):
0.107
Time:                        23:02:53   Log-Likelihood:
-7134.4
No. Observations:                4037   AIC:
1.427e+04
Df Residuals:                    4036   BIC:
1.428e+04
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
plambda       -0.0047      0.003     -1.612      0.107      -0.010       0.001
==============================================================================
Omnibus:                     3474.559   Durbin-Watson:                   1.829
Prob(Omnibus):                  0.000   Jarque-Bera (JB):           147695.752
Skew:                           3.919   Prob(JB):                         0.00
Kurtosis:                      31.576   Cond. No.                         1.00
==============================================================================

Notes:
[1] R² is computed without centering (uncentered) since the model does not
contain a constant.
[2] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[15]:
```python
# Paso 1: Estimar modelo Binomial Negativa (con alpha ajustado automáticamente)
neg_bin_model = smf.glm(
    formula="Failure_today ~ C(Location) + Min_Temp + Max_Temp +␣
 ↪Parameter1_Speed + \
            Parameter3_9am + Parameter3_3pm + Parameter4_9am + Parameter4_3pm␣
 ↪+ Parameter5_3pm",
    data=df_mensual,
    family=sm.families.NegativeBinomial()
).fit()

# Paso 2: Mostrar resumen
print(neg_bin_model.summary())

# Paso 3: Generar predicciones y graficar
df_mensual['ypred'] = neg_bin_model.predict(df_mensual)
```

```python
# Gráfico de valores predichos vs observados
sns.lmplot(data=df_mensual, x='Failure_today', y='ypred', height=5, aspect=1.5,␣
 ↪scatter_kws={'alpha':0.5})
plt.title("Predicción vs Observado - Modelo Binomial Negativa")
plt.xlabel("Fallas Observadas")
plt.ylabel("Fallas Predichas")
plt.tight_layout()
plt.show()
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:                 4037
Model:                            GLM   Df Residuals:                     3986
Model Family:        NegativeBinomial   Df Model:                           50
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -11238.
Date:                Thu, 24 Apr 2025   Deviance:                       1058.5
Time:                        23:02:53   Pearson chi2:                     741.
No. Iterations:                     9   Pseudo R-squ. (CS):             0.2858
Covariance Type:            nonrobust
==============================================================================
=====
                         coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
-----
Intercept             25.3367      8.261      3.067      0.002       9.145
41.528
C(Location)[T.4]     -0.6922      0.172     -4.016      0.000      -1.030
-0.354
C(Location)[T.5]     -0.9538      0.161     -5.913      0.000      -1.270
-0.638
C(Location)[T.6]     -1.1281      0.189     -5.966      0.000      -1.499
-0.757
C(Location)[T.7]     -0.8022      0.160     -5.012      0.000      -1.116
-0.489
C(Location)[T.8]     -0.8423      0.161     -5.232      0.000      -1.158
-0.527
C(Location)[T.9]     -0.9796      0.177     -5.533      0.000      -1.327
-0.633
C(Location)[T.10]    -0.7119      0.165     -4.318      0.000      -1.035
-0.389
C(Location)[T.11]    -0.7103      0.165     -4.311      0.000      -1.033
-0.387
C(Location)[T.12]    -0.8244      0.173     -4.764      0.000      -1.164
-0.485
C(Location)[T.13]    -1.0489      0.170     -6.162      0.000      -1.383
-0.715
```

```
C(Location)[T.14]    -1.4833      0.172     -8.645      0.000      -1.820
-1.147
C(Location)[T.15]    -0.9933      0.189     -5.256      0.000      -1.364
-0.623
C(Location)[T.16]    -1.3900      0.160     -8.661      0.000      -1.705
-1.075
C(Location)[T.17]    -1.7464      0.271     -6.451      0.000      -2.277
-1.216
C(Location)[T.18]    -1.1114      0.179     -6.220      0.000      -1.462
-0.761
C(Location)[T.19]    -1.1061      0.172     -6.424      0.000      -1.444
-0.769
C(Location)[T.20]    -0.9822      0.175     -5.628      0.000      -1.324
-0.640
C(Location)[T.21]    -0.7526      0.167     -4.501      0.000      -1.080
-0.425
C(Location)[T.22]    -0.7485      0.177     -4.236      0.000      -1.095
-0.402
C(Location)[T.23]    -0.7310      0.172     -4.257      0.000      -1.068
-0.394
C(Location)[T.26]    -0.9643      0.208     -4.636      0.000      -1.372
-0.557
C(Location)[T.27]    -1.5192      0.168     -9.050      0.000      -1.848
-1.190
C(Location)[T.28]    -1.5181      0.188     -8.069      0.000      -1.887
-1.149
C(Location)[T.29]    -0.7893      0.158     -4.990      0.000      -1.099
-0.479
C(Location)[T.30]    -0.8331      0.166     -5.025      0.000      -1.158
-0.508
C(Location)[T.32]    -0.7520      0.151     -4.973      0.000      -1.048
-0.456
C(Location)[T.33]    -0.6771      0.165     -4.102      0.000      -1.001
-0.354
C(Location)[T.34]    -1.1143      0.166     -6.731      0.000      -1.439
-0.790
C(Location)[T.35]    -0.9400      0.160     -5.865      0.000      -1.254
-0.626
C(Location)[T.36]    -0.9992      0.171     -5.836      0.000      -1.335
-0.664
C(Location)[T.38]    -1.0869      0.171     -6.357      0.000      -1.422
-0.752
C(Location)[T.39]    -0.9236      0.175     -5.282      0.000      -1.266
-0.581
C(Location)[T.40]    -1.3916      0.184     -7.558      0.000      -1.753
-1.031
C(Location)[T.41]    -0.6918      0.158     -4.365      0.000      -1.002
-0.381
```

```
C(Location)[T.42]    -0.8857      0.217     -4.079      0.000      -1.311
-0.460
C(Location)[T.43]    -0.5751      0.160     -3.601      0.000      -0.888
-0.262
C(Location)[T.44]    -1.3576      0.163     -8.336      0.000      -1.677
-1.038
C(Location)[T.45]    -1.1368      0.155     -7.339      0.000      -1.440
-0.833
C(Location)[T.46]    -0.8168      0.169     -4.831      0.000      -1.148
-0.485
C(Location)[T.47]    -0.9518      0.165     -5.768      0.000      -1.275
-0.628
C(Location)[T.48]    -1.7404      0.175     -9.940      0.000      -2.084
-1.397
C(Location)[T.49]    -1.1373      0.184     -6.171      0.000      -1.499
-0.776
Min_Temp              0.1094      0.021      5.238      0.000       0.068
0.150
Max_Temp             -0.1025      0.021     -4.872      0.000      -0.144
-0.061
Parameter1_Speed      0.0640      0.008      8.328      0.000       0.049
0.079
Parameter3_9am       -0.0077      0.010     -0.751      0.453      -0.028
0.012
Parameter3_3pm       -0.0652      0.010     -6.629      0.000      -0.084
-0.046
Parameter4_9am        0.0162      0.004      3.601      0.000       0.007
0.025
Parameter4_3pm        0.0242      0.006      4.386      0.000       0.013
0.035
Parameter5_3pm       -0.0248      0.008     -3.120      0.002      -0.040
-0.009
==============================================================================
=====
```

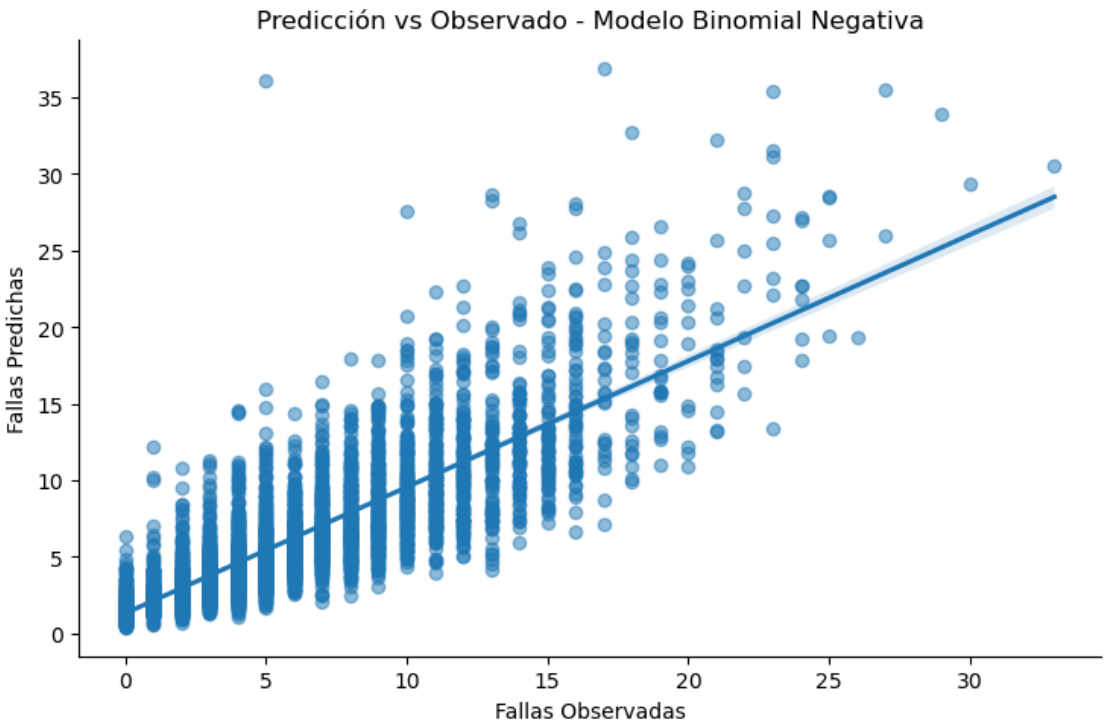
Predicción vs Observado - Modelo Binomial Negativa
Fallas Predichas
Fallas Observadas
0
5
10
15
20
25
30
35