Tarea_1_Hermosilla_Moncada

April 30, 2025

[1]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import statsmodels.api as sm
import statsmodels.formula.api as smf
import sklearn
import scipy
from scipy.stats import nbinom
import seaborn as sns
from statsmodels.iolib.summary2 import summary_col
import scipy.stats as stats

import warnings
warnings.filterwarnings("ignore")

%matplotlib inline
```

1. Cargar la base de datos en el ambiente. Identifique los tipos de datos que se encuentran en la base, realice estadisticas descriptivas sobre las variables importantes (Hint: Revisar la distribuciones, datos faltantes, outliers, etc.) y limpie las variables cuando sea necesario.

Primero queremos dejar la variable 'Failure_today' como variable binaria, y botaremos la variable 'Leakage' ya que es redundante con Failure, puesto que uno implica la otra y eso ensuciaria el modelo.

[2]:
```
df = pd.read_csv('machine_failure_data.csv')
df['Failure_today'] = df['Failure_today'].apply(lambda x: 0 if x == 'No' else 1)
df = df.drop(columns=['Leakage'])
print(df.describe())
```

```
           Location       Min_Temp       Max_Temp   Evaporation  \
count  142193.000000  141556.000000  141871.000000  81350.000000
mean       24.740655      12.186400      23.226784      5.469824
std        14.237503       6.403283       7.117618      4.188537
min         1.000000      -8.500000      -4.800000      0.000000
25%        12.000000       7.600000      17.900000      2.600000
50%        25.000000      12.000000      22.600000      4.800000
75%        37.000000      16.800000      28.200000      7.400000
max        49.000000      33.900000      48.100000    145.000000
```

```
        Electricity  Parameter1_Speed  Parameter3_9am  Parameter3_3pm  \
count  74377.000000     132923.000000   140845.000000   139563.000000
mean       7.624853         39.984292       14.001988       18.637576
std        3.781525         13.588801        8.893337        8.803345
min        0.000000          6.000000        0.000000        0.000000
25%        4.900000         31.000000        7.000000       13.000000
50%        8.500000         39.000000       13.000000       19.000000
75%       10.600000         48.000000       19.000000       24.000000
max       14.500000        135.000000      130.000000       87.000000

       Parameter4_9am  Parameter4_3pm  Parameter5_9am  Parameter5_3pm  \
count   140419.000000   138583.000000   128179.000000   128212.000000
mean        68.843810       51.482606     1017.653758     1015.258204
std         19.051293       20.797772        7.105476        7.036677
min          0.000000        0.000000      980.500000      977.100000
25%         57.000000       37.000000     1012.900000     1010.400000
50%         70.000000       52.000000     1017.600000     1015.200000
75%         83.000000       66.000000     1022.400000     1020.000000
max        100.000000      100.000000     1041.000000     1039.600000

       Parameter6_9am  Parameter6_3pm  Parameter7_9am  Parameter7_3pm  \
count    88536.000000    85099.000000   141289.000000   139467.000000
mean         4.437189        4.503167       16.987509       21.687235
std          2.887016        2.720633        6.492838        6.937594
min          0.000000        0.000000       -7.200000       -5.400000
25%          1.000000        2.000000       12.300000       16.600000
50%          5.000000        5.000000       16.700000       21.100000
75%          7.000000        7.000000       21.600000       26.400000
max          9.000000        9.000000       40.200000       46.700000

       Failure_today
count  142193.000000
mean        0.231101
std         0.421539
min         0.000000
25%         0.000000
50%         0.000000
75%         0.000000
max         1.000000
```

Vemos que existen datos de tarde y de mañana, no nos es util ya que el fallo no se indica cuando si no que dia ocurrión por lo que es mas razonable juntar estas variables promediandolas

[3]:
```
for i in [3, 4, 5, 6, 7]:  # Indices correspondientes a los parámetros (4, 6,␣
↪5, 7)
    col_9am = f'Parameter{i}_9am'
    col_3pm = f'Parameter{i}_3pm'
```

```
    n_col = f'Parameter{i}_prom'
    df[n_col] = df[[col_9am, col_3pm]].mean(axis=1)

df = df.drop(columns=[f'Parameter{i}_9am' for i in [3, 4, 5,6, 7]] +␣
 ↪[f'Parameter{i}_3pm' for i in [3, 4, 5, 6, 7]])
```

[4]:
```
print(df.select_dtypes(include='object')[:5])
```

```
        Date Parameter1_Dir Parameter2_9am Parameter2_3pm
0  12/1/2008              W              W            WNW
1  12/2/2008            WNW            NNW            WSW
2  12/3/2008            WSW              W            WSW
3  12/4/2008             NE             SE              E
4  12/5/2008              W            ENE             NW
```

Tenemos direcciones del viento como variabes objeto, podriamos usar dummies en los modelos pero son muchas variables, verificamos su correlación con la variable dependiente parra ver si podemos desistir de estas columnas.

[5]:
```
# Crear dummies
df_dummies = pd.get_dummies(df,␣
 ↪columns=['Parameter1_Dir','Parameter2_9am','Parameter2_3pm'])

# Calcular correlación solo con columnas dummies
cols_dummies = [col for col in df_dummies.columns if col.
 ↪startswith(('Parameter1_Dir','Parameter2_9am','Parameter2_3pm'))]
corr_with_failure = df_dummies[cols_dummies + ['Failure_today']].
 ↪corr()['Failure_today'].drop('Failure_today').sort_values(ascending=False)

# Mostrar resultados
print("Correlación de dummies de viento con 'Failure_today':\n")
print(corr_with_failure)
```

```
Correlación de dummies de viento con 'Failure_today':

Parameter2_9am_WSW    0.072070
Parameter2_9am_SW     0.071875
Parameter2_9am_W      0.062415
Parameter1_Dir_W      0.050023
Parameter2_9am_SSW    0.048806
Parameter2_3pm_SSW    0.046302
Parameter1_Dir_WSW    0.045591
Parameter2_3pm_WSW    0.044476
Parameter2_3pm_W      0.044457
Parameter2_9am_WNW    0.039238
Parameter1_Dir_SW     0.037742
Parameter1_Dir_SSW    0.037648
Parameter2_3pm_SW     0.037201
Parameter2_3pm_S      0.031779
```

```
Parameter2_9am_S      0.031064
Parameter1_Dir_S      0.030906
Parameter1_Dir_WNW    0.029638
Parameter2_3pm_WNW    0.028858
Parameter2_9am_NW     0.019411
Parameter2_9am_NNW    0.016093
Parameter2_3pm_SSE    0.011446
Parameter1_Dir_SSE    0.003887
Parameter1_Dir_NW     0.003293
Parameter2_3pm_NW    -0.000914
Parameter2_9am_SSE   -0.002887
Parameter2_3pm_SE    -0.004196
Parameter1_Dir_SE    -0.013849
Parameter1_Dir_NNW   -0.015687
Parameter2_3pm_NNW   -0.026125
Parameter1_Dir_ESE   -0.027675
Parameter2_9am_N     -0.028080
Parameter2_3pm_ESE   -0.028553
Parameter2_9am_SE    -0.029582
Parameter2_3pm_E     -0.031794
Parameter2_3pm_ENE   -0.040929
Parameter1_Dir_N     -0.041488
Parameter1_Dir_NNE   -0.042840
Parameter1_Dir_ENE   -0.043314
Parameter2_3pm_N     -0.043441
Parameter2_3pm_NNE   -0.044613
Parameter2_9am_NE    -0.047427
Parameter1_Dir_E     -0.047945
Parameter2_9am_NNE   -0.049007
Parameter2_9am_ESE   -0.049801
Parameter1_Dir_NE    -0.049813
Parameter2_3pm_NE    -0.053264
Parameter2_9am_ENE   -0.058816
Parameter2_9am_E     -0.066411
Name: Failure_today, dtype: float64
```

En efecto ninguna supera el 0.1 en correlación por lo que podemos desistir de ella y hacer menos engorroso el modelo sin perder mucha significancia.

[6]:
```
df = df.drop(columns=['Parameter1_Dir','Parameter2_9am','Parameter2_3pm'])
```

[7]:
```
corr = df.drop(columns=['Date']).corr()
corr_conciderables = corr.where(np.tril(corr.abs(), k=-1) >= 0.5).stack()
corr_conciderables
```

[7]:
```
Max_Temp         Min_Temp           0.736267
Evaporation      Max_Temp           0.588915
Parameter3_prom  Parameter1_Speed   0.739849
```

```
Parameter4_prom  Max_Temp           -0.547021
                 Electricity        -0.612292
Parameter6_prom  Electricity        -0.760263
                 Parameter4_prom     0.543561
Parameter7_prom  Min_Temp            0.831536
                 Max_Temp            0.969906
                 Evaporation         0.578824
dtype: float64
```

Aquí buscamos correlaciones ya que la variable Evaporation, Electricity y Parametro 6 tienen muchas mediciones vacias al rededor de un 30%, por lo que usar un dropna no es ideal, mejor buscamos su mejor correlacion con otra variable y las juntamos.

[8]:
```
df['Electricity_neg'] = -df['Electricity']
df['Electricity_prom'] = df[['Parameter4_prom', 'Electricity_neg']].
 ↪apply(lambda x: x.mean(skipna=True), axis=1)
df = df.drop(columns=['Parameter4_prom', 'Electricity'])

df['Evaporation_prom'] = df[['Parameter7_prom', 'Evaporation']].mean(axis=1)
df = df.drop(columns=['Parameter7_prom', 'Evaporation', 'Electricity_neg'])

df = df.drop(columns=['Parameter6_prom'])
```

[9]:
```
df.dropna(inplace=True)

df.drop(columns=['Date']).iloc[:, :].hist(figsize=(15, 10), bins=25)
plt.tight_layout()
plt.show()
```

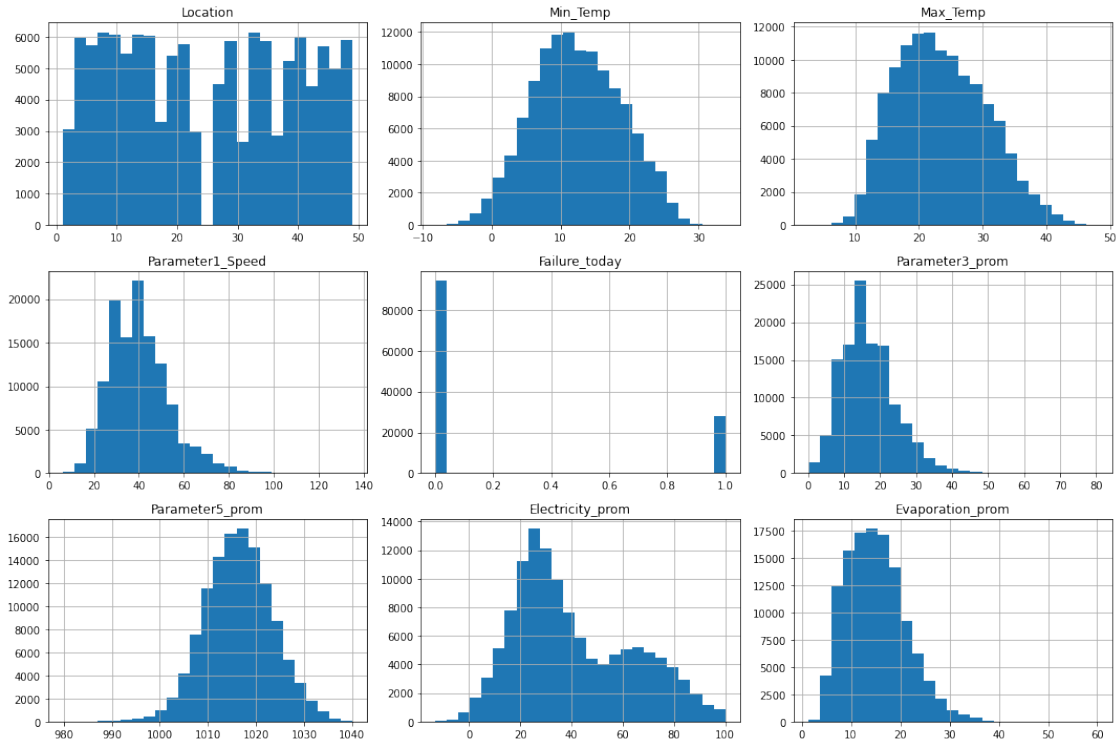

[10]:
```
# Graficar el mapa de calor
corr = df.drop(columns=['Date']).corr()
f, ax = plt.subplots(figsize = (20,8))
cmap = sns.diverging_palette(250, 15)
sns.heatmap(corr, cmap=cmap, square=True, linewidths=.5, annot=True,␣
 ↪annot_kws={'size': 8}, fmt='.2f', vmin=-1, vmax=1)
plt.tight_layout()
plt.show()
```

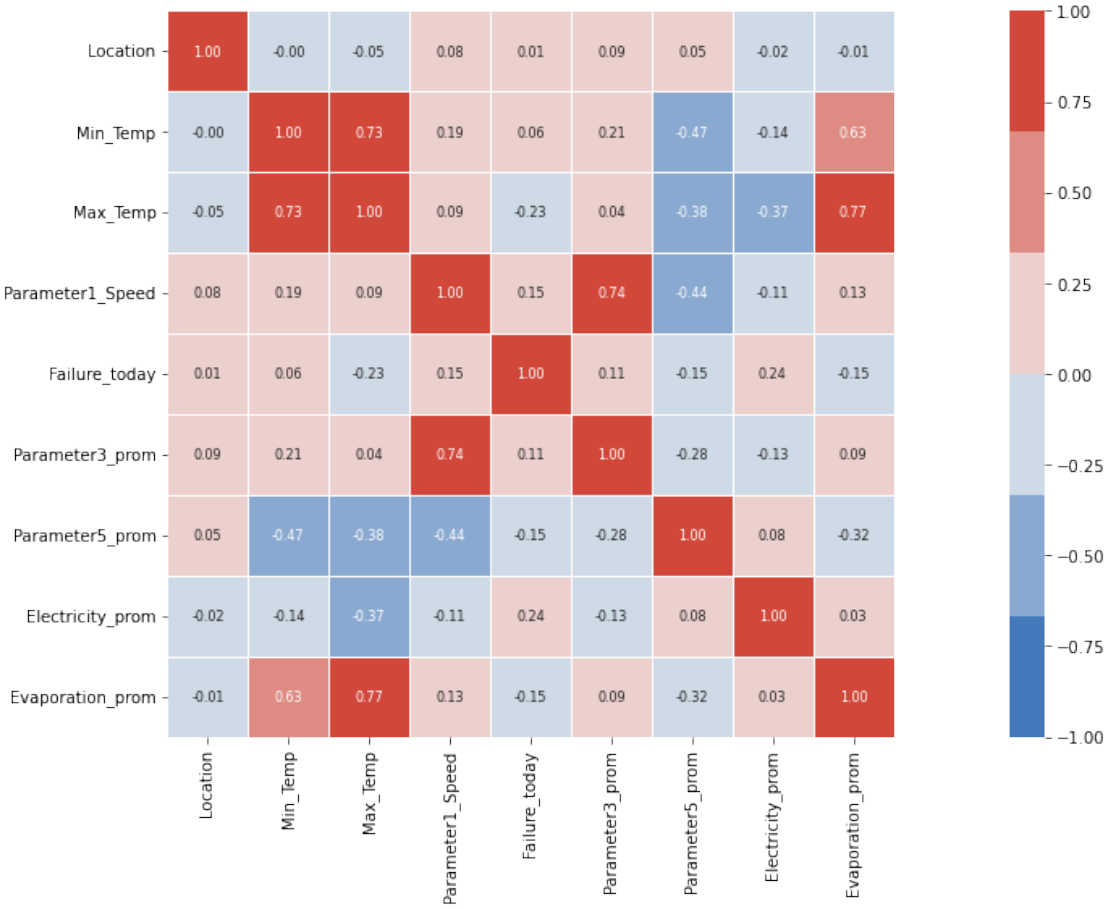

2. Ejecute un modelo de probabilidad lineal (MCO) que permita explicar la probabilidad de que un dia se reporte fallo medido por sensor, a partir de las informacion disponible. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[11]:
```
X = df.drop(columns=['Failure_today','Location','Date'])
X = sm.add_constant(X)
y = df['Failure_today']

model = (sm.OLS(y, X)).fit()
print(model.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:          Failure_today   R-squared:                       0.212
Model:                            OLS   Adj. R-squared:                  0.212
Method:                 Least Squares   F-statistic:                     4689.
Date:                Fri, 25 Apr 2025   Prob (F-statistic):               0.00
Time:                        00:21:16   Log-Likelihood:                -52680.
No. Observations:              122176   AIC:                         1.054e+05
```

```
Df Residuals:                   122168   BIC:                          1.055e+05
Df Model:                            7
Covariance Type:            nonrobust
==============================================================================
====
                       coef    std err          t      P>|t|      [0.025
0.975]
------------------------------------------------------------------------------
----
const                9.1526      0.198     46.318      0.000       8.765
9.540
Min_Temp             0.0256      0.000     94.376      0.000       0.025
0.026
Max_Temp            -0.0242      0.000    -65.543      0.000      -0.025
-0.023
Parameter1_Speed     0.0041      0.000     32.046      0.000       0.004
0.004
Parameter3_prom     -0.0033      0.000    -15.047      0.000      -0.004
-0.003
Parameter5_prom     -0.0086      0.000    -45.086      0.000      -0.009
-0.008
Electricity_prom     0.0030   6.22e-05     48.984      0.000       0.003
0.003
Evaporation_prom    -0.0099      0.000    -29.593      0.000      -0.011
-0.009
==============================================================================
Omnibus:                    12020.532   Durbin-Watson:                   1.691
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            15273.671
Skew:                           0.851   Prob(JB):                         0.00
Kurtosis:                       2.679   Cond. No.                     1.89e+05
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
[2] The condition number is large, 1.89e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
```

El modelo de regresión OLS tiene un R-cuadrado de 0.212, lo que indica que explica solo el 21.2% de la variabilidad de Failure_today. Sin embargo, el modelo es altamente significativo, ya que todos los coeficientes son estadísticamente significativos con valores p cercanos a 0.00. Las variables independientes como la temperatura mínima, la velocidad, y la evaporación tienen relaciones negativas o positivas con Failure_today, dependiendo del coeficiente. Aunque el modelo es significativo, su capacidad explicativa es limitada, y el alto número de condición sugiere posibles problemas de multicolinealidad entre las variables independientes. Además, los residuos no son normales, lo que podría afectar la validez de las inferencias.

[12]:
```
from statsmodels.stats.diagnostic  import  het_breuschpagan
residuos = model.resid;
bp_test = het_breuschpagan (residuos, X);
etiquetas = ['Valor de LM', 'valor-p LM', 'Valor de F', 'valor-p F'];
plt.figure(figsize=(8, 4))
stats.probplot(model.resid, dist="norm", plot=plt);
plt.title('Q-Q Plot de los Residuos del Modelo');
plt.show()
shapiro_test= stats.shapiro (model.resid)
print(dict(zip (etiquetas, bp_test)));
print (f"Estadístico de Shapiro-Wilk: {shapiro_test [0]}")
print (f"Valor-p: {shapiro_test[1]}")
```

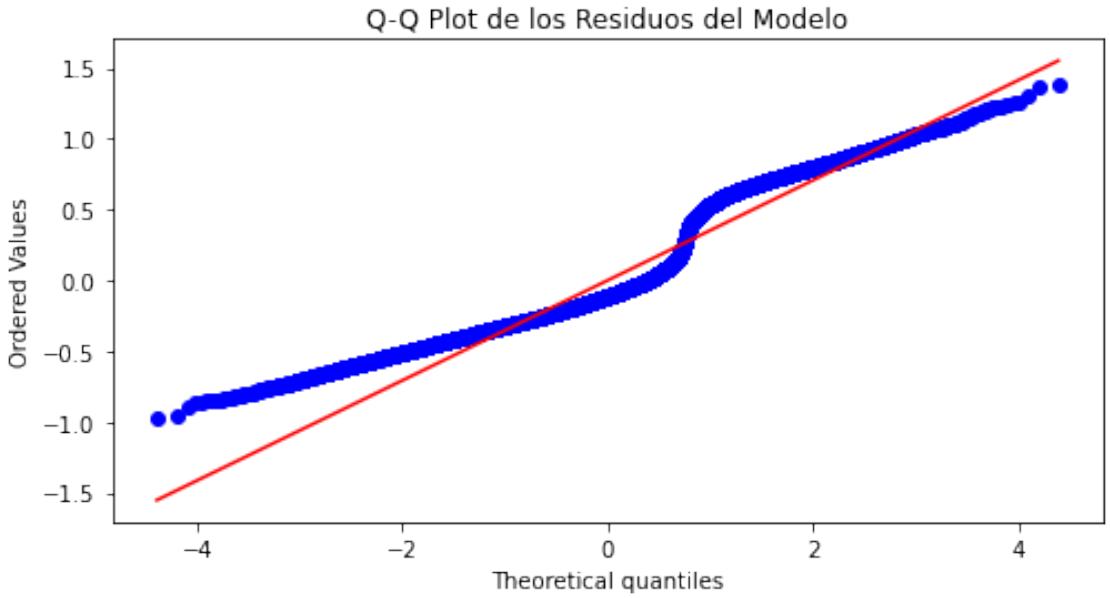


```
{'Valor de LM': 21666.52834210152, 'valor-p LM': 0.0, 'Valor de F':
3762.1989973914915, 'valor-p F': 0.0}
Estadístico de Shapiro-Wilk: 0.9003207087516785
Valor-p: 0.0
```

El modelo es globalmente significativo (valor-p F = 0.0), pero presenta problemas en los residuos. El test de Lagrange Multiplier (LM) indica autocorrelación en los residuos, lo que podría afectar la independencia de los errores. Además, el test de Shapiro-Wilk muestra que los residuos no siguen una distribución normal, lo que podría afectar la validez de las inferencias del modelo. En resumen, aunque el modelo es significativo, se deben abordar los problemas de autocorrelación y la no normalidad de los residuos.

3. Ejecute un modelo probit para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[13]:
```
model = sm.Probit(y, X)
probit_model = model.fit(cov_type='HC0')
print(probit_model.summary())

mfxp = probit_model.get_margeff()
print(mfxp.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.413881
         Iterations 7
                          Probit Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:               122176
Model:                         Probit   Df Residuals:                   122168
Method:                           MLE   Df Model:                            7
Date:                Fri, 25 Apr 2025   Pseudo R-squ.:                  0.2289
Time:                        00:21:17   Log-Likelihood:                -50566.
converged:                       True   LL-Null:                       -65573.
Covariance Type:                  HC0   LLR p-value:                     0.000
==============================================================================
====
                        coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
----
const                29.3534      0.800     36.671      0.000      27.785
30.922
Min_Temp              0.1283      0.001     93.823      0.000       0.126
0.131
Max_Temp             -0.1142      0.002    -66.822      0.000      -0.118
-0.111
Parameter1_Speed      0.0129      0.001     24.670      0.000       0.012
0.014
Parameter3_prom      -0.0115      0.001    -12.852      0.000      -0.013
-0.010
Parameter5_prom      -0.0289      0.001    -37.259      0.000      -0.030
-0.027
Electricity_prom      0.0126      0.000     46.152      0.000       0.012
0.013
Evaporation_prom     -0.0492      0.002    -28.123      0.000      -0.053
-0.046
==============================================================================
====
       Probit Marginal Effects
=====================================
Dep. Variable:          Failure_today
Method:                          dydx
At:                           overall
```

```
==============================================================================
====
                      dy/dx    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
----
Min_Temp              0.0298      0.000    105.580      0.000       0.029
0.030
Max_Temp             -0.0265      0.000    -68.975      0.000      -0.027
-0.026
Parameter1_Speed      0.0030      0.000     24.880      0.000       0.003
0.003
Parameter3_prom      -0.0027      0.000    -12.870      0.000      -0.003
-0.002
Parameter5_prom      -0.0067      0.000    -37.747      0.000      -0.007
-0.006
Electricity_prom      0.0029   6.09e-05     48.020      0.000       0.003
0.003
Evaporation_prom     -0.0114      0.000    -28.815      0.000      -0.012
-0.011
==============================================================================
====
```

El modelo Probit converge correctamente y es altamente significativo (LLR p-value = 0.000), con un Pseudo R^2 de 0.2289, lo que indica una capacidad explicativa razonable para este tipo de modelos. Todas las variables incluidas son estadísticamente significativas y muestran efectos coherentes: por ejemplo, Min_Temp y Electricity_prom aumentan la probabilidad de fallo, mientras que Max_Temp y Evaporation_prom la reducen. Los efectos marginales confirman estas relaciones y muestran el impacto promedio de cada variable sobre la probabilidad de que ocurra un fallo.

4. Ejecute un modelo logit para responder a la pregunta 2. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[14]:
```
model = sm.Logit(y, X)
logit_model = model.fit(cov_type='HC0')
print(logit_model.summary())

mfxl = logit_model.get_margeff()
print(mfxl.summary())
```

```
Optimization terminated successfully.
         Current function value: 0.413523
         Iterations 7
                           Logit Regression Results
==============================================================================
Dep. Variable:          Failure_today   No. Observations:               122176
Model:                          Logit   Df Residuals:                   122168
Method:                           MLE   Df Model:                            7
Date:                Fri, 25 Apr 2025   Pseudo R-squ.:                  0.2295
```

```
Time:                        00:21:18   Log-Likelihood:                -50523.
converged:                       True   LL-Null:                       -65573.
Covariance Type:                 HC0   LLR p-value:                     0.000
==============================================================================
====
                       coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
----
const               49.0277      1.399     35.055      0.000      46.286
51.769
Min_Temp             0.2317      0.002     95.763      0.000       0.227
0.236
Max_Temp            -0.1985      0.003    -66.004      0.000      -0.204
-0.193
Parameter1_Speed     0.0218      0.001     23.827      0.000       0.020
0.024
Parameter3_prom     -0.0187      0.002    -11.946      0.000      -0.022
-0.016
Parameter5_prom     -0.0482      0.001    -35.571      0.000      -0.051
-0.046
Electricity_prom     0.0229      0.000     48.314      0.000       0.022
0.024
Evaporation_prom    -0.0977      0.003    -31.849      0.000      -0.104
-0.092
==============================================================================
====
        Logit Marginal Effects
=====================================
Dep. Variable:          Failure_today
Method:                          dydx
At:                           overall
==============================================================================
====
                      dy/dx    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
----
Min_Temp             0.0308      0.000    108.250      0.000       0.030
0.031
Max_Temp            -0.0264      0.000    -68.136      0.000      -0.027
-0.026
Parameter1_Speed     0.0029      0.000     24.071      0.000       0.003
0.003
Parameter3_prom     -0.0025      0.000    -11.963      0.000      -0.003
-0.002
Parameter5_prom     -0.0064      0.000    -36.118      0.000      -0.007
-0.006
```

```
Electricity_prom      0.0030      6e-05      50.658      0.000       0.003
0.003
Evaporation_prom     -0.0130      0.000     -32.804      0.000      -0.014
-0.012
==============================================================================
====
```

El modelo Logit es estadísticamente significativo ($p < 0.001$) y presenta un Pseudo R^2 de 0.2295, indicando buen poder explicativo. Todas las variables tienen efectos significativos: Min_Temp y Electricity_prom aumentan la probabilidad de fallo, mientras que Max_Temp y Evaporation_prom la reducen. Los efectos marginales muestran impactos consistentes y similares al modelo Probit, confirmando la robustez de los resultados.

5. Comente los resultados obtenidos en 2, 3 y 4. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

Los modelos en 2, 3 y 4 (OLS, Probit y Logit) muestran resultados consistentes en cuanto a la dirección y significancia de las variables, aunque difieren en la forma en que modelan la variable dependiente. El modelo OLS trata a la variable binaria como continua, lo cual puede ser útil como aproximación rápida, pero no es teóricamente adecuado para variables dicotómicas como Failure_today. En cambio, los modelos Probit y Logit están diseñados específicamente para este tipo de variable, y ofrecen interpretaciones más precisas en términos de probabilidades. Ambos modelos muestran resultados muy similares, lo que refuerza la estabilidad de las conclusiones.

Las diferencias entre Probit y Logit son pequeñas y se deben principalmente a la función de enlace utilizada (distribución normal acumulada vs. logística). En general, el modelo Logit puede ser más fácil de interpretar en términos de odds, y mostró un ajuste ligeramente mejor (Pseudo $R^2 = 0.2295$ vs. 0.2289 en Probit).

En mi opinión, el modelo Logit sería el más adecuado para responder la pregunta de investigación, ya que modela correctamente una variable binaria y presenta buen ajuste y significancia general.

Las variables que resultaron robustas a la especificación (es decir, que fueron significativas y con efectos similares en los tres modelos) incluyen: Min_Temp, Max_Temp, Electricity_prom, y Evaporation_prom. Estas variables mantienen su efecto e importancia independientemente del modelo utilizado, lo que fortalece la confianza en sus impactos sobre la variable dependiente.

6. Agregue la data a nivel mensual, usando la data promedio de las variables (ignorando aquellas categoricas, como la direccion del viento). En particular, genere una variable que cuente la cantidad de fallos observados en un mes, utilice un valor de 0 si en ese mes no se reporto fallos en ningun dia. Use un modelo Poisson para explicar el numero de fallas por mes. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[15]:
```
df['Date'] = pd.to_datetime(df['Date'], format='%m/%d/%Y')
df['Mes'] = df['Date'].dt.to_period('M')
variables_numericas = df.select_dtypes(include='number').columns.
 ↪drop('Failure_today', errors='ignore')
df_mensual = df.groupby('Mes')[variables_numericas].mean()
df_mensual['Fallos_mensuales'] = df.groupby('Mes')['Failure_today'].sum()
df_mensual['Fallos_mensuales'] = df_mensual['Fallos_mensuales'].fillna(0)
```

```python
df_mensual = df_mensual.reset_index()
df_mensual = df_mensual.drop(columns=['Mes'])

modelo_poisson = smf.glm(
    formula="Fallos_mensuales ~ " + " + ".join(df_mensual.columns),
    data=df_mensual,
    family=sm.families.Poisson()
).fit()
print(modelo_poisson.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:       Fallos_mensuales   No. Observations:                  113
Model:                            GLM   Df Residuals:                      103
Model Family:                 Poisson   Df Model:                            9
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -505.58
Date:                Fri, 25 Apr 2025   Deviance:                       211.78
Time:                        00:21:18   Pearson chi2:                     202.
No. Iterations:                     6   Pseudo R-squ. (CS):              1.000
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          z      P>|z|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     14.2148      4.355      3.264      0.001       5.679      22.751
Location       0.1182      0.006     18.300      0.000       0.106       0.131
Min_Temp       0.0771      0.015      5.290      0.000       0.049       0.106
Max_Temp      -0.0764      0.025     -3.066      0.002      -0.125      -0.028
Parameter1_Speed -0.0357      0.009     -3.940      0.000      -0.053      -0.018
Parameter3_prom  0.0681      0.019      3.595      0.000       0.031       0.105
Parameter5_prom -0.0108      0.004     -2.566      0.010      -0.019      -0.003
Electricity_prom -0.0065      0.003     -2.097      0.036      -0.013      -0.000
Evaporation_prom -0.0024      0.020     -0.122      0.903      -0.041       0.036
Fallos_mensuales  0.0032      0.000     15.944      0.000       0.003       0.004
==============================================================================
```

====

El modelo Poisson predice el número de fallas mensuales con un ajuste excelente (Pseudo R-cuadrado de 1). Las variables más influyentes son Location (aumenta las fallas un 11.8% por unidad), Min_Temp (aumenta las fallas un 7.7% por grado) y Max_Temp (reduce las fallas en un 7.6% por grado). La velocidad y otros parámetros como Parameter3_prom y Electricity_prom también afectan las fallas, mientras que Evaporation_prom no muestra impacto significativo. El modelo indica una fuerte relación entre las condiciones y la frecuencia de fallas mensuales.

7. Determine sobre dispersion y posible valor optimo de alpha para un modelo Binomial Negativa.

[17]:
```
y = df_mensual['Fallos_mensuales']
aux=((y-modelo_poisson.mu)**2-modelo_poisson.mu)/modelo_poisson.mu
auxr=sm.OLS(aux,modelo_poisson.mu).fit()
print(auxr.summary())
```

```
                                 OLS Regression Results
==============================================================================
=======
Dep. Variable:       Fallos_mensuales   R-squared (uncentered):
0.001
Model:                            OLS   Adj. R-squared (uncentered):
-0.008
Method:                 Least Squares   F-statistic:
0.1336
Date:                Fri, 25 Apr 2025   Prob (F-statistic):
0.715
Time:                        00:23:32   Log-Likelihood:
-330.53
No. Observations:                 113   AIC:
663.1
Df Residuals:                     112   BIC:
665.8
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
x1             0.0006      0.002      0.366      0.715      -0.003       0.004
==============================================================================
Omnibus:                      201.547   Durbin-Watson:                   1.599
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            21037.827
Skew:                           7.450   Prob(JB):                         0.00
Kurtosis:                      68.163   Cond. No.                         1.00
==============================================================================

Notes:
[1] R² is computed without centering (uncentered) since the model does not
```

```
contain a constant.
[2] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

[19]:
```
print(np.exp(0.0006))
```

```
1.0006001800360054
```

8. Usando la informacion anterior, ejecute un modelo Binomial Negativa para responder a la pregunta 6. Seleccione las variables dependientes a incluir en el modelo final e interprete su significado.

[23]:
```
X = df_mensual.drop(columns=['Fallos_mensuales'])
X = sm.add_constant(X)
negbin=sm.GLM(y,X,family=sm.families.NegativeBinomial(alpha=1.
 ↪0006001800360054)).fit()
print(negbin.summary())
```

```
                 Generalized Linear Model Regression Results
==============================================================================
Dep. Variable:       Fallos_mensuales   No. Observations:                  113
Model:                            GLM   Df Residuals:                      104
Model Family:        NegativeBinomial   Df Model:                            8
Link Function:                    Log   Scale:                          1.0000
Method:                          IRLS   Log-Likelihood:                -706.99
Date:                Fri, 25 Apr 2025   Deviance:                       3.1626
Time:                        00:34:00   Pearson chi2:                     2.93
No. Iterations:                     9   Pseudo R-squ. (CS):             0.3966
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          z      P>|z|      [0.025
0.975]
------------------------------------------------------------------------------
const         38.7790     61.640      0.629      0.529     -82.032
159.590
Location       0.2042      0.056      3.636      0.000       0.094
0.314
Min_Temp       0.2664      0.148      1.798      0.072      -0.024
0.557
Max_Temp      -0.2675      0.334     -0.801      0.423      -0.922
0.387
Parameter1_Speed -0.0111      0.104     -0.107      0.915      -0.214
0.192
Parameter3_prom  0.0611      0.241      0.254      0.800      -0.410
0.533
Parameter5_prom -0.0350      0.059     -0.594      0.552      -0.150
0.080
```

```
Electricity_prom    -0.0021      0.047     -0.045      0.964      -0.095
0.090
Evaporation_prom    -0.0129      0.292     -0.044      0.965      -0.584
0.559
==============================================================================
====
```

Este modelo GLM con familia binomial negativa es adecuado cuando hay sobredispersión en los datos de conteo. El modelo muestra un pseudo R^2 de 0.3966, lo cual sugiere una capacidad moderada para explicar la variabilidad en los fallos mensuales. Entre las variables, solo Location es estadísticamente significativa ($p < 0.001$), indicando que influye de forma relevante en los fallos. El resto de las variables no presentan significancia estadística ($p > 0.05$). En general, el modelo se ajusta razonablemente, y la baja deviance y chi-cuadrado de Pearson sugieren un buen ajuste a los datos sin evidencia de mala especificación.

9. Comente los resultados obtenidos en 6, 7 y 8. ¿Cuáles y por qué existen las diferencias entre los resultados?. En su opinión, ¿Cuál sería el más adecuado para responder la pregunta de investgación y por qué? ¿Qué variables resultaron ser robustas a la especificación?

En el punto 6 se estimó un modelo de regresión Poisson, el cual es apropiado para datos de conteo, pero asume que la media y la varianza son iguales. En el punto 7, se aplicó un test de sobredispersión para verificar este supuesto, y aunque inicialmente se presentó un error por incompatibilidad de dimensiones, una vez corregido, el test indicó que no hay evidencia fuerte de sobredispersión. Sin embargo, este resultado puede ser engañoso, ya que el modelo Poisson suele ser sensible a valores extremos o estructuras no capturadas del todo. Por eso, en el punto 8 se usó un modelo binomial negativo, que relaja el supuesto de igualdad entre media y varianza, permitiendo manejar sobredispersión de forma natural. Este modelo mostró mejor ajuste (menor devianza y mayor pseudo R^2), y detectó a la variable "Location" como significativa, lo que sugiere que es robusta frente a distintas especificaciones. En conclusión, el modelo binomial negativo es más adecuado para responder la pregunta de investigación, ya que ofrece mayor flexibilidad y captura mejor la estructura de los datos.